Общая информация

Каждый год наша магистратура предоставляет студентом список тем для проектов - по
большей части это программные проекты.

В списке проектов ниже есть градация по уровням сложности: BASE, MIDDLE, PRO.

- Для ВКР мы рекомендуем брать задачу не ниже уровня MIDDLE (сложность выделена желтым или красным цветом)
- Вы можете взять задачу уровня BASE или BASE/MIDDLE, но в этом случае основной акцент в проекте должен быть на сервис (распределенный, высоконагруженный, отказоустойчивый) и другие инструменты промышленной разработки.

У каждого проекта есть трек, содержание чекпойнтов для различных треков будет различаться с учетом особенностей трека:

- ML, классический ML (с обязательным ML и затем внедрением DL)
- DL, глубинное обучение (проекты, где ML не предусмотрен - они обязательно имеют градацию MIDDLE или PRO
- RESEARCH, research (упор на исследования, нет жестких требований к программной части).

---

1. Требования к исследовательским задачам:

- Задача по и, требующая изучения и/или разработки собственных архитектур
- В исследовательской задаче не требуется доведение разработки до production-вида (сервис/бот и тд)
- Плюсом будет написание статьи по результатам ВКР

2. Требования к программным проектам:

- Сервис (ниже минимальные требования)
- Инструменты highload / оркестрации и тд

Каждый программный проект - это полноценная задача, содержащая в себе как часть по анализу данных, так и инфраструктурную часть.

Минимальные требования к инфраструктурной части, общие для всех программных проектов.

- Язык разработки: Python 3.10.4
- Менеджмент зависимостей: pip, conda
- Менеджмент версий python: pyenv, poetry
- Управление виртуальными окружениями: pyenv-virtualenv
- Система контроля версий: git (gitlab)
- Система контроля версий данных, менеджмент workflow: dvc, google drive
- Шаблонизатор: coockiecutter
- Линтер: flake8
- Автоформаттер: black
- CLI: click, argparse
- Мониторинг: MLflow
- ML-стэк: catboost, sklearn, pandas, numpy, pytorch
- Parsing-стэк: pyautogui
- Тестирование: pytest

Необходимые общие комментарии:

Перечисленные “Возможные задачи” в описаниях проектов являются рекомендациями и ориентиром, участники проекта имеют право расширить задачу по своему усмотрению или реализовать пункты другими способами, если предложенные не позволяют добиться приемлемого качества. Однако изменения в роадмэп проекта требуется согласовать с куратором и академруком.

Кураторы и их краткие Bio

Захаров Андрей (@and_rei_z)

Bio: *Кандидат физико-математических наук. Постдокторские исследовательские позиции в Израильском технологическом институте (Технион, Израиль), Калифорнийском университете в Мерседе (США) и Пенсильванском университете (США). В настоящее время является ведущим научным сотрудником и руководителем проектов группы Industrial AI в Институте искусственного интеллекта AIRI (Москва).*
Научные интересы находятся на стыке машинного обучения, физики и биомедицины, с особым акцентом на проектирование и разработку моделей для промышленных приложений: физически-информированные нейронные сети и нейронные операторы, генеративный ИИ с физической согласованностью, ИИ-моделирование живых тканей, мультиагентное обучение с подкреплением (роевая робототехника), предиктивное обслуживание в промышленности и энергетике, ИИ для науки об аккумуляторах и другие проекты.
Что дает участие в моих проектах: соавторство в публикациях Q1 и A/A (NeurIPS, ICML, ICLR), менторство от исследователей AIRI, участие в создании открытых бенчмарков, разработка прототипов и продуктов для индустриальных и финтех-партнеров (реальный индустриальный след).*
Интересы по темам: физика и научные вычисления в ИИ, генеративные модели, RL и MARL, временные ряды и сигналы с промышленных датчиков, графовые нейронные сети, self-supervised learning. Особенно приветствуются студенты, ориентированные на трек RESEARCH и публикацию статьи по итогам работы.
(a.zakharov@airi.net, Google Scholar куратора, Карточки проектов) проекты **143**-**148** в списке ниже.

Ляпин Данила (@danila_lyapin)

***Bio**:*

Лидирую команду по рексису и поиску во Вкусвилле (ex-Яндекс, Самокат и ЦБ). Прошел путь от "самоучки" до ШАДа. Окончил магистратуру ИИ.

Много строил моделей классического ML в продакшне (от сегментаций всех клиентов Самоката до прогнозирования временных рядов). В Яндексе активно развивал рекомендательную систему для финтеха с нуля. В свободное время преподаю и выступаю автором курса по DS в Яндекс Практикуме.

Также интересен CV в направлении face recognition (детекция лиц, распознавание ключевых точек, классификация изображений), классический ML (любую задачку регрессии, классификации, кластеризации и тд), RAG.

Наука: предсказание стоимости ценных бумаг, рекомендательные системы.

Бобылев Денис (@DenisMB)

Bio:

Работаю Team Lead MLOps в онлайн-кинотеатре ИВИ, где отвечаю за MLOps-направление рекомендательной системы и компьютерного зрения. Выпускник магистерской программы «Искусственный интеллект» 2026.

За профессиональный путь успел поработать в разных ролях: от JavaScript-разработчика в AT Consulting до Team Lead DevOps в MTC Big Data. Благодаря

опыту в разработке, инфраструктуре и машинном обучении могу помочь с реализацией проекта на всех этапах — от постановки задачи и работы с данными до внедрения готового решения. Есть успешный опыт курирования годовых проектов студентов (5 команд).

Интересы: классический ML, временные ряды, RecSys, CV.
Особенно приветствуются новички. С удовольствием рассмотрю и вашу тему.

Махров Иван (@MakhrovIvan)

Bio:
Выпускник ФКН ВШЭ (Магистратура “Искусственный интеллект” 2026). Сейчас работаю Data Analyst в Rolf Tech, где лидирую команду и выстраиваю DWH-архитектуру. До этого 3 года развивал аналитику в крупном ритейле (Familia, Gloria Jeans). Прошел путь от автоматизации отчетов до управления дата-инженерными проектами.

Мой бэкграунд лежит на стыке Data Engineering и Machine Learning. Умею не только обучать модели, но и выстраивать под них надежный инженерный фундамент: от проектирования ETL и DWH до деплоя сервисов в Docker и написания API на FastAPI. В NLP и LLM есть опыт проектирования и внедрения RAG-систем.

Интересны любые задачи и темы на стыке NLP, LLM, RAG. Также, интересны темы по классическому ML.

Николаев Михаил (@nikolaevmikk)

Bio: BizDev Sber, направление AI в спорте. Упаковываю в бизнес-продукты исследования применения ИИ в спортивной индустрии (CV, ML, LLM)

Знаю, как создать коммерчески успешный продукт из технологии/исследования, провести через этап MVP до этапа первой выручки.

— Product Owner в AI-стартапе (сферы real estate и travel). Первая на рынке аналитическая система для скаутинга земельных участков под инвестиции + ИИ-консьерж для отелей (мультиагентная архитектура).
— AI Product Manager (Иннотех). С нуля создал методологию скаутинга и скоринга стартапов на рынке РФ, автор исследования стартап-ландшафта DGCompass
— Associate в сообществе бизнес-ангелов и венчурном фонде Виталия Полехина. С нуля отбирал стартапы для сделок, менторил их и проводил по всем этапам вплоть до получения инвестиций
— Фаундер traveltech стартапа, победитель преакселератора и акселератора MGIMO Ventures, победитель акселератора РСХБ x Startech
Глубоко погружен в российский венчурный контекст, разбираюсь в методологии оценки инвестиционной пригодности и привлекательности стартапа. В качестве участника прошел несколько российских акселераторов, позднее выступал в них в качестве спикера и ментора.
Член жюри конкурсов стартапов.

Кузнецов Виктор (@vkuz_2302)

Bio:

Студент 2ого курса ИИ. Бэкграунд в химии и биотехнологиях, инженерный опыт в фарме, анализе промышленных данных, хемоинформатике.

Сейчас работаю в исследовательском институте, проекты на стыке ML и химической технологии. Ключевые задачи области: энергоэффективность, раннее предсказание отклонений, сбои и износ оборудования. Также очень важна оценка рисков, связанных с качеством продукции.

Интересы: классический ML, LLM, рекомендательные системы, цифровые двойники, промышленная аналитика, оптимизация процессов, устойчивое развитие. 2 предложенные мной темы могут быть интересны тем, кто хочет работать в DS отделах фармацевтических, пищевых и химических компаний (в частности, Биокад или СИБУР).

На первом курсе успешно сдал 65-ю (сфера образования, ИИ-тьютор), так что буду рад помочь с ней, и с похожими (64, 99). ***Также предлагаю две собственные темы: 116*** *- создание инструмента* ***ретросинтеза*** *(для тех, кто интересуется химией), и более сложная/креативная* ***171*** *по* ***цифровым двойникам*** *(хим технология, промышленность)*

Белый Роман (@rbyelyy)

Bio:

Выпускник ИИ (бывш. МОВС). Руководитель ML/AI отдела в компании ***Align Technology.***
Не наука: OCR (изображений на производстве), CV-автоматический контроль качества (по 2D), суррогатные модели (аппроксимации физ. процессов) и конечно же LLM + RAG (куда без них) для ускорения процессов.
Наука: предсказание стоимости ценных бумаг и предиктивная аналитика для производства. Будут интересны задачи (CV/OCR - детекция/классификация & кластеризация) + классически ML.

Ковалева Александра (@ak0va)

Bio:

Работаю ресерчером в британской AI-компании ***GreenJinn****, где занимаюсь задачами компьютерного зрения, NLP и рекомендательных систем. Параллельно учусь на 2 курсе магистратуры* ***Bocconi University*** *по направлению Cybersecurity and Risk Governance, где исследую применение ИИ и машинного обучения в задачах безопасности и анализа данных. До этого участвовала в проектах Сколково, VK и Яндекса (с некоторыми из этих проектов предложу поработать и вам 😀).*

ИИ и алгоритмы для меня — не только работа, но и хобби :) Поэтому последние несколько лет занимаюсь исследованиями в области машинного обучения, публикую научные статьи и постоянно тестирую новые подходы. Будут особенно интересны задачи классического ML, NLP, рекомендательных систем, компьютерного зрения, а также всё-всё-всё, что связано с временными рядами (от макроэкономики до звуковых дорожек).

Янышев Дмитрий (@yanyshev_dima)

Bio:
Выпускник ИИ (бывш. МОВС). Работаю в Яндексе.Облаке, занимаюсь внедрением ML/AI в процессы бизнес-команд. Внедрял RAG, модели классификации, регрессии, прогнозирования временных рядов, uplift. До Яндекса работал в ЦБ РФ, занимался прогнозированием и моделированием, много работал с временными рядами

Сулейманов Нихат(@Nikhat_S)

Bio:
*Работаю в Будапеште Data Scientisom в европейском стартапе **sight-E**. В работе — фокус на classical ML, временных рядах и компьютерном зрении.*

*Закончил магистратуру в одном из ведущих вузов Европы - **University of Szeged** с фокусом на ИИ (стипендия Stipendium Hungaricum), после - исследовательская работа на стыке медицинского ИИ и надёжности ИИ.*

Наука: есть научные публикации, участвовал в международных академических программах, одним из которых является по направлению AI & Global Health. В прошлом году довёл дипломника из ВШЭ до защиты на максимальный балл - работа попала в топ-5% и была отобрана для публикации.
Интересы: Computer Vision, Medical AI, надёжность ИИ(robust AI), классический ML, временные ряды, out-of-distribution detection, адверсариальный ИИ.

> *И не переживайте, если тема кажется сложной — вместе разберёмся. Нужно ваше усердие и интерес*

Скворцов Илья (@ilyaSk91)

Bio:

К.ф.-м.н., больше 5 лет работаю в индустрии и исследовательских проектах. Занимаюсь анализом данных, классическим ML, компьютерным зрением и обработкой речи.

Папулов Олег (@Olegiy)

Bio:
В процессе получения магистратуры по ИИ. Работал в Сбере (классический ML + агенты) и Альфе (распознавание документов + агенты) - занимался разработкой ИИ-моделей и пайплайнов для различных бизнес-процессов. Разрабатывал модели

классификации/регрессии, временные ряды, аплифт, “бандиты” и тп. Были проекты с DL. Лидировал команды стажёров и джунов.
Интересы: проекты из разных доменов с прикольным/неожиданным ресерчем.

Рудеев Кирилл (@kiril_rud)

Bio:
Работаю ML Engineer / Data Scientist в Axenix(ex. Accenture), занимаюсь разработкой ML-решений для бизнеса. Основной фокус — прогнозирование временных рядов (область спроса), классический ML и математическая оптимизация (MINLP/LP). Есть опыт полного цикла разработки ML-решений — от исследования и PoC до production. Выпускник ИИ (бывш. МОВС)
Интересы: временные ряды, классический ML, математическая оптимизация, RAG и LLM.

Гераськина Надежда (@Nadya_Gera)

Bio:
На данный момент работаю в VK антироботе, делаю модели для детекции различного бот-трафика. До этого занималась антифродом в Яндекс ID, что также предполагало работу над полным циклом внедрения ML моделей в продакшн. Для магистерской работы создавала VAE для поиска аномалий в потоке регистраций. За 6 лет учебы на прикладной математике написала 3 работы по графам, в том числе социальным, а также с привязкой к NLP

Выпускница ИИ (бывш. МОВС) 2025, уже третий год буду куратором, мои студенты успешно сдали на высшие баллы проекты по темам 5, 15, 37 (классический ML, NLP и графы)
Хочу попробовать также новые темы по RAG, агентам и LLM темам)

Интересы: классический ML, особенно с интересными кластеризациями, графовые алгоритмы, агенты, RAG, NLP

Чепиков Иван (@p0xwave)

Bio:
Работаю в компании «Аналитические программные решения», которая развивает ML-решения для бизнеса и платформу для их внедрения. Уже более трёх лет участвую в разработке крупных коммерческих проектов; сейчас занимаюсь платформой монетизации данных с использованием ML. Работаю на стыке инженерии, архитектурных решений и машинного обучения.

Учусь на втором курсе магистратуры «Искусственный интеллект». Интересы: LLM-агенты, RAG-системы, а также ML на стыке с высоконагруженными системами, наблюдаемостью и голосовыми ассистентами. Особенно интересны практические способы делать такие решения надёжными и полезными в реальных продуктах.
Также активно участвую и в академической деятельности - есть научные публикации, включая работы, представленные на конференциях уровня A и A.*

Мовсумов Денис (@Denji_TensAI)

Bio:
Работаю в Сбере, разрабатываю ML/NLP решения для бизнес процессов. Суммарный опыт работы около 5 лет. Работаю на стыке инженерии, архитектурных решений и машинного обучения.

Учусь на втором курсе магистратуры «Искусственный интеллект». Участвую в написании научной статьи.
Интересы: классический МЛ, NLP, LLM, RAG-системы, графовые алгоритмы, агенты.

Усов Александр (@Alexander_Usoff)

Bio:
Работаю Lead ML Engineer в 85Tech, лидирую команду из ML инженеров и дата аналитиков. Занимаемся внедрением и улучшением рекомендательных систем, RAG инструментов, прогнозированием временных рядов, uplift моделями. В индустрии более 5 лет, начинал в роли дата аналитика и постепенно погружался в мир Машинного и Глубинного обучения.
Инетерсы: RecSys, RAG, LLM, Time series, Uplift, любые виды классификации и регрессии.

Сысоев Сергей (@yegerless)

Bio:

Закончил магистратуру ИИ в этого году, а до этого закончил медицинский. Руковожу аналитическим отделом в крупном федеральном медицинском центре, в своей работе совмещаю анализ данных, бэкенд разработку и машинное обучение. Есть большой опыт работы с медицинскими данными, хорошо умею в классический табличный ML и увлекаюсь NLP.

Павлов Игорь (@ispavlov)

Bio:

Закончил ИИ, есть химический бекграунд. Работаю DS в Ростелекоме, занимаюсь разработкой моделей рекомендательных систем. Research исследования приветствуются. Основной стек: классический ML, RecSys, Reinforcement Learning. Фокусируюсь на построении эффективных алгоритмов ранжирования, подборе персонального контента и оптимизации бизнес-метрик.

Абакумов Юрий (@fluloeo)

Bio:

Учусь на втором курсе магистратуры ИИ, участвую в 2-х research проектах. Бэкграунд - лазерная физика и моделирование физических процессов (в том числе с помощью DL). Интересы: классический ML, NLP, LLM/VLM, RAG

Жаботинский Кирилл (@jk1rill)

Bio:

R&D в области perception для беспилотного транспорта. Сейчас развиваю perception для беспилотного трамвая: 3D-детекция объектов по LiDAR (CenterPoint / PointPillars), multi-sweep fusion, оценка скорости объектов, метрики и валидация на городских сценах, подготовка моделей к onboard-инференсу.

Соборнов Тимофей (@saintedts)

Bio:

Выпускник Бауманки и нашей магистратуры с отличием.

Писал бакалаврскую ВКР по NLP, а магистерскую по диффузионкам. ТОП-3 на хакатоне по NLP, работаю MLE, не инфоцыган, но опыт наставничества имею. Почти всегда на связи, приду на помощь и дам совет.

Интересны CV и NLP.

Архипов Максим (@pirici_pip)

Bio:

Работаю в VK. Занимаюсь построением скоринговых моделей и research в этой и смежных областях . Имею опыт работы с большими данными и кросс-доменной адаптацией эмбеддингов.
Закончил ИИ на красный диплом. Готов брать в проект студентов любого уровня при наличии интереса. Будем работать как с классическим ML, так и DL. При наличии желания и времени уйдем в research.
Мои темы:

- *Классификатор/детектор изображений из специальных доменов;*
- *Детектирование аномалий в данных;*
- *Сервис для определения похожести на известного актера или актрису;*
- *Обнаружение аномалий / фрод-детекция;*
- *Цифровые двойники пользователей (синтетические двойники LLM).*

По любым вопросам можете писать в указанный телеграмм.

Мустафин Фарид (@lanarich)

Bio: *Руковожу разработкой AI-продуктов в Fast Sechenov (Сеченовский университет), выпускник ИИ (бывш. МОВС). С командой занимаюсь проектированием и реализацией*

AI-систем и продуктов для образования и медицины, до этого разрабатывал систему выявления биологических угроз для Минздрава. Время от времени преподаю в ФСН ВШЭ.

Интересы: все что касается прикладного использование ML и LLM для решения задач бизнеса, классический ML, NLP, RAG, агенты, LLM Ops, evaluation & alignment.

Если у вас есть свои идеи, буду рад помочь реализовать!

Залесинский Роман (@roman_public)

Bio: В основном занимаюсь NLP и немного TTS/ASR и другими голосовыми фичами в команде RnD плюс иногда подрабатываю в стартапах за долю малую.
Закончил эту программу год назад и курировал несколько команд, так что знаю все подводные камни в ведении годового проекта. Со мной упор будет на практику и живой продукт. Научимся ставить эксперименты, считать метрики, настраивать мониторинг и тд
Заодно прокачаем скиллы работы с нейросетями и кодинг-ассистентами (в широком смысле, а не только для генерации кода).

Ильинский Андрей (@tatikom)

Bio: *Технический директор и главный архитектор, 11 лет в разработке распределённых высоконагруженных систем. Выпускник "Аналитики больших данных" НИУ ВШЭ (диплом с отличием, 10/10 по всем дисциплинам и за ВКР). Автор курса MLOps на этой же программе.*

Веду проекты на стыке машинного обучения и инженерии: там, где мало обучить модель — нужно довести её до работающей воспроизводимой системы.

Что я даю:
- задачи на реальных данных, а не на учебных датасетах;
- разбор постановки до того, как вы потратите месяц не туда;
- быструю обратную связь: отвечаю в течение дня, встречаемся раз в неделю;
- я был в комиссии по защите десятков проектов и знаю, за что реально снижают баллы.

Что я жду: что вы будете писать код и показывать промежуточные результаты, а не появитесь за две недели до защиты. Тему можно предложить свою - готов работать с любыми инициативными темами. После завершения проекта готов продолжить работу в рамках ВКР, публикаций и конференций.

Направления: MLOps и воспроизводимость, ранжирование и рекомендации, потоковая обработка данных, NLP, поиск аномалий, веб, телеком, стартапы.

Андреев Дмитрий (@immortaldesignerr)

Учусь на втором курсе магистратуры «Искусственный интеллект».

Готов брать в проект студентов любого уровня.
При наличии желания и времени можно углубиться в исследовательскую работу: изучить статьи, воспроизвести существующие методы, проверить собственные гипотезы и подготовить результаты к публикации.
Каждый проект доведем от постановки задачи и сбора данных до готовой реализации, которую можно добавить в портфолио или использовать как основу для кейса на собеседованиях (завершил множество собеседований на позиции) или выпускной работы.
Можете закидывать темы в лс, обсудим)

Юдайкин Кирилл (@ample_margin)

Bio: *Закончил РЭШ, магистратуру ИИ, сейчас я аспирант ВШЭ (экономика) и работаю в ЦБ РФ. Занимаюсь ML (AML и KYC), аналитикой и инженерией данных. Имею опыт разработки ML-пайплайнов, работы с графовыми нейронными сетями, временными рядами и табличными моделями. Интересуюсь задачами прикладного машинного обучения и прогнозирования.*

Интересы: задачи на стыке ML и экономики.

Цуриков Виталий (@tsurikow)

Bio: *Закончил магистратуру ИИ ФКН ВШЭ. AI Engineer - занимаюсь разработкой продуктов на базе LLM и VLM, в частности решений по распознаванию и обработке больших объемов документации, агентских решений для 1С и SAP.*
Интересуюсь различными NLP/LLM/AI-задачами прикладного характера, в частности решающих проблемы бизнеса. Очень интересны области AI in Education (AIEd), EGov, AI for Social/Public Good.

Направления: MLOps, LLMOps, NLP, RAG, Agents, Applied AI, LLM, VLM.
Открыт с различным интересным темам, смело предлагайте свои идеи.

Качкин Дмитрий (@KachkinDmitrii)

Bio:
Закончил магистратуру ИИ (бывш. МОВС). Работаю главным инженером в MonCloud — лаборатории облачных вычислений ИСП РАН. Занимаюсь разработкой и архитектурой облачных сервисов и распределённых систем на базе OpenStack и Kubernetes. Основной бэкграунд — backend, облачная инфраструктура и распределённые системы.

Сейчас основной фокус — разработка и ИИ-систем поддержки пользователей и применение DL/AI для анализа и поиска аномалий в распределённых системах. В целом особенно интересны направления на стыке AI и сложных программных систем.

Интересы: RAG, LLM, AI в распределённых системах, поиск аномалий и observability. Отдельно интересуюсь современным инференсом LLM , оптимизацией и развёртыванием моделей, NVIDIA ИИ-инфраструктурой.Буду рад как прикладным, так и исследовательским проектам.

Ширнин Алесандр (@icecreamflavors)

Bio: AI researcher @ MMCP Lab HSE

Окончил бакалавр ПМИ ФКН и магистратуру по бизнес информатике. Сейчас продолжаю работать над исследованиями в аспирантуре ФКН. Занимаюсь в основном NLP. Преподавал и занимался научным руководством в ВШЭ. Участвовал в kaggle и в научных соревнованиях. В прошлые годы мои студенты участвовали в соревнованиях от воркшопа SemEval, где опубликовали статьи. Google scholar с моими статьями.

Направления: В основном мне нравятся исследовательские темы про прикладное применение LLM/VLM, их безопасность, взломы, инъекции, устойчивость (robustness), создание бенчмарков. Под прикладным применением я подразумеваю LLM для креатива, применение в каких-то других сферах, AI for public good. Можно также что-то связанное с computer vision, но у меня нет глубокого понимания в диффузиях.

Тип ВКР: Я открыт к инициативным исследовательским темам, готов обсудить различные модификации текущих тем. Также было бы интересно поработать с темами из различных соревнований (включая текущие, например, https://semeval.github.io/SemEval2027/tasks). Можем также рассмотреть программные проекты, которые включают в себя области, перечисленные выше.

Опыт именно в NLP не обязателен, но я ожидаю самостоятельность и ответственность за результат, а также заинтересованность, энтузиазм по теме. При этом, если будет необходимо, я могу поделиться рекомендациями по статьям, курсам и другим материалам, которые помогут быстрее углубиться в тему. Готов поделиться опытом исследований, написания научных статей, участия в соревнованиях, а также консультировать по самому ML.

Хамрин Роман (@roman_khamrin)

Bio:

Окончил магистратуру “Искусственный Интеллект”, работаю DS в Яндекс Картах – занимаюсь ранжированием сущностей, ращу социальный граф пользователей за счет различных инициатив. До этого работал в MWS в финтехе – занимался моделями склонности. Помимо этого был ассистентом на курсах по программированию и на ИАДе; работал с графовыми нейронными сетями, рекомендательными системами, занимался поиском аномалий

Направления: в основном заинтересован именно в любых рекомендательных системах и самых разных способах объяснения их выдач с помощью LLM. Готов работать с любой темы из этой сферы, открыт к новым предложениям

Родионов Никита (@white_shpengler)

Bio: *Закончил ИИ, работаю в Constructor nlp инженером, до этого занимался cv детекцией для оптимизации использования коммерческих помещений и стажировался в вышкинской лабе по CV в медицине. Сейчас пишу статью о возможности каузальной интерпретации диффузионных трансформеров. Интересен широкий круг тем по nlp. Приходите например “стирить” небольшие модели (~~учить их обходить цензуру~~).*

Алексеев Леонид (@anonezey)

Закончил ИИ + МИСИС ИИ. Руковожу антифрод направлением в ПС. Имею большой финансовый бэкграунд, работы с любыми биржевыми и внебиржевыми инструмента рынка РФ/США, балансировкой портфелей. Отдельно можно обсудить темы по криптовлюте, и вообще разные направления.

Поспелов Артем (@posptem)

Bio: Выпускник магистратуры ИИ (ex-МОВС).

В настоящее время занимаю позицию ML-инженера в VK Музыке, где отвечаю за разработку и развитие высоконагруженных рекомендательных систем — от проектирования архитектуры до реализации отдельных ML-компонентов: мета-рекомендательных сервисов, алгоритмов коллаборативной фильтрациии систем A/B-аналитики.

Ранее занимался разработкой решений в сфере финансовых технологий и инвестиций, включая построение моделей классического ML-скоринга и агентных систем различной степени автономности. Имею опыт руководства DS команд.

Также являюсь преподавателем Data Culture в НИУ ВШЭ

Направления: рекомендательные системы; применение методов машинного обучения в задачах финансов и инвестиционного анализа.

Садулаев Идрис (@idrisadx)

Bio: Учусь на втором курсе магистратуры «Искусственный интеллект». Есть химтех бэкграунд (бакалавриат РГУ нефти и газа). Работал в Роснефти ML-инженером, в

основном занимался Classic ML, также участвовал в разработке корпоративного ИИ-ассистента.
Направления: Classic ML, NLP, RAG, LLM, агенты.
Готов брать в проект студентов любого уровня, сам в прошлом году защитил проект на 10.
Проект доведем от постановки задачи и сбора данных до готовой реализации, которую можно добавить в резюме и использовать как основу для кейса на собеседованиях.
Пишите в ЛС по любым вопросам)

Панчук Георгий (@jmzzomg)

Bio: ML Ecosystem team lead @ Qdrant, а еще заканчивал первый набор магистратуры ИИ (МОВС).

Руковожу небольшой командой, которая занимается qdrant-client, fastembed и другими библиотеками, которые делают жизнь пользователей немного приятнее (или неприятнее). Там же иногда занимаюсь исследовательскими проектами, чтобы найти новые способы применения векторного поиска.

С вами мне было бы интересно поделать любые проекты, которые связаны с векторным поиском - RAG, мультимодальный/унимодальный поиск и так далее. Также можно и другие NLP/CV темы.

В основном, занимаюсь практическими темами, но могу помочь и с исследовательскими, например, ускорение KV cache с использованием векторного поиска и другими похожими текстами. (Готовить работу к публикации в журнале и тд - неинтересно).

Блуменау Марк (@markblumenau)

Bio:

Выпускник ИИ (бывш. МОВС) и Факультета Физики НИУ ВШЭ. ***Академрук магистратуры Умных устройств в Вышке, руководитель направления DL и CV на магистратуре ИИ.***
Не наука: OCR (мед документов), CV (определение молний, Останкино) и куча всякой всячины, подробности если надо в ЛС.
Наука: PINN (Физически-Информированные нейронные сети), CV, Астрофизика, Гидродинамика, Квантовые материалы.

TLDR: почти любое CV / Физику (и в целом естественные науки) / ресерч можно ко мне :)

Мария Герасимова(@mariya_math)

Bio:

Образование: мехмат МГУ, фкн ВШЭ, TU Dresden (PhD).

Работа: работаю в области машинного обучения с фокусом на анализ медицинских данных и медицинских изображений.

Беру как **программные**, так и **исследовательские проекты**.

Предложила список своих тем, но буду рада обсудить и другие. Ко мне можно приходить и с уже сформулированной задачей, и просто с желанием хорошо погрузиться в интересующее направление — даже если поначалу это скорее исследовательский пет-проект. Помогу уточнить тему, подобрать данные и методы и сделать из идеи полноценную дипломную работу.

Исследовательские проекты при наличии хороших результатов постараемся подготовить к публикации.

Александр Голубев (@golubevofficial)

Bio: ПМИ НИУ ВШЭ, диплом с отличием, ШАД

Более трех лет в индустрии DS/ML, сейчас работаю в Яндексе, занимаюсь полным циклом разработки ML-моделей для предсказания кликов/конверсий в рекламе - от сбора бизнес-требований до выкатки в прод, до этого занимался развитием и ускорением собственной A/B платформы. Стипендиат Тинькофф, обладатель Гранта Министерства образования за выдающиеся способности в математике и информатике

В прошлом году вел выпускников-магистров, все студенты защитились на отлично

Карагодин Никита (@Einstein_30)

Bio: Магистр МОВС (ИИ) и бакалавр в физике. В настоящее время работаю в SberDevices, где занимаюсь синтезом\клонированием речи для голосовых ассистентов. Читаю курсы по генеративным моделям и DL в аудио в нашей магистратуре.

Если вас интересует темы распознавания\синтеза\клонирования речи или музыки или генерации картинок, то смело пишите мне. Особо ценятся инициативные проекты!

Михаил Сахаров

(tg: @mcccc email: mc@saharov.net)

Магистр МОВС ИИ. Работаю в проекте windy.app (https:/eindy.app). В основном занимаюсь backend и devops задачами. Работа тесно связана с R&D погоде. У нас небольшой стартап, но иногда пробуем считать что-то сами. На данный момент основное направление исследования - наукастинг радарных данных.

Влад Дубровин (@vladospb)

Bio:

Выпускник магистратуры «Искусственный интеллект» ФКН ВШЭ 2026 года. Работаю LLM/NLP Engineer в Газпром нефти, занимаюсь разработкой внутренних сервисов на базе языковых моделей: RAG, evaluation, локальные LLM и прикладные NLP-задачи.

До этого разрабатывал AI-ассистентов и системы семантического поиска в HR-стартапе, а также мультиагентную систему для поиска, анализа и отбора научных публикаций.

Своя тема: детекция автоматизированного ввода текста по поведенческой телеметрии пользователя.

Надежда Шатило (@trinetey)

Bio: Красный диплом магистратуры «Аналитика больших данных» ФКН НИУ ВШЭ (2026). Работаю Marketing Analyst в Beget. До аналитики был внушительный опыт в маркетинге. Ныне строю ETL-пайплайны и дашборды в Superset, использую causal inference и машинное обучение для оценки эффективности акций и юнит-экономики (LTV, ARPPU, когорты).

Автоматизирую отчетность, люблю сложное делать простым и надежно работающим, а также превращать сырые данные в бизнес-инсайты. Ценю практический смысл в задачах, а не таски ради тасок.

Александр Карушев (@sochse)

Bio: выпускник ОП “Социология” ФСН НИУ ВШЭ (2024, с отличием), выпускник ОП “Аналитика больших данных” ФКН НИУ ВШЭ (2026, с отличием), лауреат конкурса научно-исследовательских работ студентов (2023, 2 место) по направлению “Интегрированные коммуникации”, соавтор двух публикаций, индексируемых в Scopus: https://orcid.org/0009-0006-7298-1671, приглашенный преподаватель ФКН НИУ ВШЭ в 2025/2026 году

Research Interests: Computational Social Science, Applied Machine Learning in the Social Sciences, Economic Sociology, Gender Sociology, Sociology of Emotions

Project Topics: темы 210, 211, 212, 213. В приоритете доведение проекта до публикации. Кроме базовых пререквизитов, потребуется готовность разбираться в предметной области

Арина Неволина (@nevolinaa)

Bio: Data Scientist в Lamoda, отвечаю за развитие AutoML-трека: от экспериментов и обучения моделей до вывода в прод и мониторинга качества. Ранее развивала AutoML-направление в Альфа-Банке. Преподаю машинное обучение в НИУ ВШЭ, разрабатываю учебные и проектные треки, третий год курирую курсовые и ВКР по ML. Окончила магистратуру «Искусственный интеллект» НИУ ВШЭ.

Темы: AutoML, классический ML на табличных данных, NLP, рекомендательные системы и uplift-моделирование. Подойдут как прикладные сервисы, так и исследовательские работы с сильной экспериментальной частью

Описания проектов

1. Предсказание качества воздуха / предсказание аллергенов *

Трек: ML
Уровень сложности: base

Руководители: Бобылев Денис, Сулейманов Нихат, Гераськина Надежда, Скворцов Илья, Махров Иван, Ковалева Александра, Ширнин Александр, Садулаев Идрис, Блуменау Марк, Александр Голубев, Шатило Надежда

Пререквизиты: основы анализа данных и машинного обучения, методы работы с временными рядами

Вам предлагается построить модель, предсказывающую индекс качества воздуха по данным загрязнителей со станций выбранного района (области). Предлагается использовать для исследования загрязнители, которые официально входят в состав индекса качества воздуха. Это озон, SO2, NO2, CO и PM10, PM2.5 (твердые частицы соответствующего диаметра).

Color Code	AQI Value	Actions to Protect Your Health
Green	Good (0-50)	None.
Yellow	Moderate (51-100)	Unusually sensitive people should reduce prolonged or heavy exertion outdoors.
Orange	Unhealthy for Sensitive Groups (101-150)	Sensitive groups should reduce prolonged or heavy exertion outdoors: People with heart and lung disease Children and older adults People that are active outdoors
Red	Unhealthy (151-200)	Sensitive groups should avoid prolonged or heavy exertion outdoors. Everyone should reduce prolonged or heavy exertion outdoors.
Purple	Very Unhealthy (201-300)	Sensitive groups should avoid all physical activity outdoors. Everyone should avoid prolonged or heavy exertion outdoors.

Данные можно взять с сайта http://discomap.eea.europa.eu/ , предоставляющего информацию о загрязнителях, как исторических, так и актуальных. Регулярно проводится обновление данных.

Возможные задачи:
- Сбор и анализ данных. Выбор страны или стран, по которым проводится анализ
- Агрегация и визуализация данных (доля каждого из загрязнителей, влияние каждого из загрязнителей ит.д.)
- Построение простой предсказательной модели (на основе формул, экспертного мнения), оценка метрик

ML задачи:
- Использование ML-моделей для получения прогнозов
- Поиск и удаление аномалий
- Кластеризация стран по составу воздуха

Улучшение прогноза:

- Сбор внешних дополнительных данных (новости, показатели другой природы и/или из других источников)

DL задачи:

Использование DL-моделей для получения прогнозов

Адаптивная селекция и/или композиция моделей

2. Классификатор/детектор изображений из специальных доменов (классификация покемонов, определение языка, на котором написан текст на картинке итд).

Руководители: Архипов Максим, Белый Роман, Цуриков Виталий, Ширнин Александр, Блуменау Марк, Александр Голубев

Трек: ML
Уровень сложности: base/middle

Задача классификации изображений - одна из классических задач компьютерного зрения, которая не теряет своей актуальности, поскольку в различных приложениях и сервисах требуется классифицировать объекты, изображенные на фотографии (определение пользователя, марки машины и т.д.).
Можно выбрать свою тематику для классификации. Если решать задачу классификации овощей, то можно воспользоваться этим открытым датасетом.

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

Возможные задачи:
- Скачать датасет и провести разведочный анализ данных
- Создать веб-сервис, который по запросу выводит фотографии. Виды запросов:
  - Выводить по запросу ответ. Например, на запрос “3 фотографии огурцов” вывести на экран 3 произвольных фотографии огурцов из датасета
  - Создать алгоритм определения цвета овоща и по запросу “выведи зеленый овощ” выводить несколько фотографий зеленых овощей
  - Реализовать *поиск похожих* среди фотографий в датасете. Сервис должен уметь принимать на вход новую фотографию (фотографию пользователя) и находить наиболее похожую/похожие на неё фотографии в датасете.
- ML-задача: решить задачу классификации овощей по имеющимся данным с помощью линейной модели. Сервис должен реализовывать часть, связанную с применением готовой модели: пользователь загружает фотографию овоща, и модель определяет вид овоща.
- Также можно кластеризовать фотографии.
- DL-задача: см. ML-задачу, но с применением нейронных сетей.
- Продвинутая задача: по датасету обучить генератор новых фотографий овощей. По запросу “сгенерировать фотографию помидора” применяется обученная модель генерации и выдает сгенерированную фотографию.

В случае решения аналогичной задачи, но на другом датасете необходимо обсудить с куратором проекта возможные задачи.

Возможные модификации задачи:

- распознавание повреждений на фото автомобиля с локализацией их расположения (дверь//крыло//крыло…) и вида (вмятина//царапина//прочее)
- работа со спутниковыми снимками (например, для прогнозирования лесных пожаров и прочих катаклизмов)

3. Задача определения специальных видов тональности текста (многоклассовая тональность / тональность мультиязычных текстов / аспектная тональность и другие)

Руководители: Бобылев Денис, Гераськина Надежда, Сысоев Сергей, Ширнин Александр, Садулаев Идрис, Александр Голубев, Арина Неволина

Уровень сложности: base/middle

Задача быстрого определения тональности и темы, на которую написана заметка или новость в интернете постоянно решается различными компаниями. Перед вами стоит аналогичная задача, которую можно адаптировать к любой другой тематике, а не только к текстам новостей.

Пререквизиты: основы ML/DL(модели классификации), NLP (представления текста в виде векторов (BOW, Tf-idf, word2vec итд)), BERT для выделения текстовых эмбеддингов

Возможные задачи:
- Собрать данные (скачать новости или другие тексты) с какого-либо/каких-либо источников. Разметить данные.
- Собрать список самых частотных слов
- Использовать приложение “облако тегов” по скачанным за определенную дату новостям.
- Создать словарь позитивных и негативных ключевых слов, по ним вручную сделать классификацию на positive/negative новости, оценить значение метрик качества.

ML задачи:
- Классификация новостей на postitive/negative с помощью ML-моделей + интерпретация результата, оценка метрик
- Кластеризация новостей
- Как изменяется основная тематика новостей со временем? Модель, с использованием временного признака

DL задачи:
- Классификация новостей с помощью DL-моделей
- Тематическое моделирование
- Применение библиотек для морфологического, синтаксического и семантического анализа текстов
- Выделение именованных сущностей + выводы

4. Определение авторства текстов

Руководители: Бобылев Денис, Гераськина Надежда, Сысоев Сергей, Абакумов Юрий, Ширнин Александр, Александр Голубев, Шатило Надежда, Арина Неволина

Уровень сложности: base/middle

Предположим, у нас есть эталонные тексты, написанные некоторыми лицами (пусть современными писателями-затворниками). Некоторое гипотетическое издательство хотело бы по предоставленным ей текстам планирующихся к изданию книг определить, действительно ли произведение написано писателем-затворником, а не лицом, выдающим себя за него.

Пререквизиты: основы ML/DL(модели классификации), NLP (представления текста в виде векторов (BOW, Tf-idf, word2vec итд)), BERT для выделения текстовых эмбеддингов

Возможные задачи:
- Сбор данных (выбор за участниками проекта; база – русскоязычные писатели-классики)
- Визуализация данных (допустим, облако наиболее часто употребляемые уни- и биграмм для каждого из писателей в собранном датасете; любые другие информативные способы отображения инфы о текстах только приветствуются)

ML-задачи:
- Многоклассовый классификатор автора на основе простых текстовых эмбеддингов
- Визуализация близости авторов (лейблов) из корпусов (Толстой к Достоевскому статистически значимо ближе, чем Ильф и Петров)
- Определение для каждого текста степени его похожести на тех или иных авторов (например, выводим топ-3 самых похожих авторов с %, насколько похожи)

Улучшение прогноза:
- Используем композицию разноплановых моделей; возможно с разной предобработкой исходных текстов

DL-задачи:
- Построение нейросетевого эмбеддинга автора текста (своеобразный TextSample2AuthorVec)

5. Детектирование аномалий в данных

Руководители: Бобылев Денис, Гераськина Надежда, Архипов Максим,Скворцов Илья, Ковалева Александра, Хамрин Роман, Качкин Дмитрий, Алексеев Леонид, Блуменау Марк, Александр Голубев

Уровень сложности: base/middle

Пререквизиты: основы ML/DL(модели классификации и кластеризации), методы понижения размерности данных для их визуализации

Для тех, кто работал с реальными данными, не является секретом тот факт, что для построения хороших моделей данные требуются тщательно предобработать. В том числе избавиться от аномалий (лучше, но сложнее – их объяснить). Выдуманный банк хотел бы по транзакциям клиентов определять, является ли конкретная транзакция (или группа транзакций) подозрительной(-ными).

Возможные задачи:
- Сбор и/или поиск подходящего датасета
- EDA подозрительных транзакций (пытаемся найти ответ на вопрос, в проведение каких именно транзакций банку стоит дополнительно вмешаться)

ML-задачи:
- Построение классификатора аномальных транзакций
- Балансировка данных
- Статистические подходы к поиску аномалий
- Подход без учителя (кластеризация, ML-методы поиска аномалий)
- Объединение двух подходов

Улучшение прогноза:
- Объединение подходов обучения с и без учителя в semi-supervised способ

DL-задачи:
- GAN сеть для генерации неподозрительных транзакций (прогоняем транзакцию через дискриминатор)
- Использование VAE для определения подозрительных транзакций (отсечка по ошибке реконструкции на отдельных транзакциях)
- Обучение bert-like модели для классификации транзакций.

6. Определение популярности геолокации для размещения банкомата / магазина / точки продаж.

Руководители: Бобылев Денис, Ковалева Александра, Ширнин Александр, Александр Голубев

Уровень сложности: base/middle

Пререквизиты: основные алгоритмы машинного обучения, методы работы с геоданными

Решаем задачу по определению популярности места размещения банкомата из соревнования Happy Data Year.

> В рамках данного проекта вам предстоит построить модель, которая по географическим координатам и адресу точки выдаст оценку индекса популярности банкомата в этой самой локации. Эта задача интересна тем, что имеющиеся данные вовсе не являются избыточными и у вас может быть много эвристик к тому, какие признаки стоит добавить

В рамках этой задачи у вас есть возможность поработать с сервисом OSM (OpenStreetMaps) для извлечения и анализа полезной в контексте решаемой задачи информации.

Возможные задачи:

- Анализ данных: визуализация банкоматов на карте
- Выделение самых популярных районов с банкоматами, поиск районов, где нет банкоматов - с визуализацией на карте (в разрезе выбранного банка или по всем банкам в совокупности)
- Работа с OpenStreetMaps: поиск выбранных объектов в заданном радиусе от конкретного банкомата (например, поиск остановок общественного транспорта в 300 метрах от банкомата).

ML-задачи:

- Решение задачи прогнозирования индекса популярности банкомата
- Кластеризация банкоматов с последующей визуализацией и анализом кластеров

DL-задачи:

- Применение нейросетевых подходов для решения описанных выше задач

Возможные улучшения:

- Подумать, какие еще внешние данные могут пригодиться для улучшения качества предсказательной модели.

7. Классификатор пресс-релизов ЦБ с предсказанием будущей ключевой ставки

Руководители: Бобылев Денис, Поспелов Артем, Махров Иван, Павлов Игорь, Янышев Дмитрий, Ковалева Александра, Александр Голубев

Уровень сложности: base/middle

Введение: ЦБ каждый раз после заседания по ключевой ставке на сайте публикует пресс-релизы, в которых рассказывается про состояние экономики/инфляцию/спрос на продукты и услуги итд и объясняет причину изменения/не изменения ставки. Задача состоит в том, чтобы по семантике текста понять, что будет происходить с ключевой ставкой после на следующем заседании: ЦБ ее поднимет, опустит или оставит неизменной. По сути нужно написать классификатор, который сможет определить тексты на 3 класса: -1 (ставка опустится), 0 (останется неизменной), 1 (ставку повысят)

Базовая часть проекта:

1. **Сбор данных**: С сайта ЦБ надо будет спарсить все пресс-релизы. Также дополнительно можно использовать данные Росстата с макростатистикой: уровень безработицы, рост ВВП, ИПЦ, итд
    -
2. **Предобработка данных**: Создания эмбеддингов из текстов

3. **Разработка классификатора**:
    - От простых базовых моделей TF-IDF до трансформеров. Приветствуется все!!! :)

Задачи ML & DL:

1. **Обучение и валидация моделей**:
    - Сравнение точности различных моделей на тестовом датасете.
    - Использование различных техник обучения, таких как BERT.
2. **Настройка гиперпараметров**:
    - Оптимизация параметров моделей для повышения точности детекции.
    - Настройка гиперпараметров на основе солидного кросс-валидационного (CV) анализа.
3. **Разработка веб-приложения / бота**:
    - Создание интерфейса для демонстрации работы классификатора в реальном времени.

Пререквизиты:

Проект будет интересен тем, кто уже знаком с основами машинного обучения и NLP. В случае недостатка знаний в этих областях, участникам потребуется самостоятельное изучение материалов с поддержкой куратора.

8. Классификатор вопросов экзамена A-level по темам

Руководители: Бобылев Денис, Сысоев Сергей, Ковалева Александра, Гераськина Надежда, Абакумов Юрий, Александр Голубев

Уровень сложности: base/middle

Введение: Как и в России, любому Британскому школьнику не удается избежать своей участи написания ЕГЭ… А точнее A-level. Например, у экзамена Business Studies, который должны написать все студенты, планирующие поступления в экономические вузы, есть 5 разделов: marketing, market, characteristics of entrepreneur, итд. Задача следующая: написать классификатор, который мог бы определить вопросы экзамена к одной из тем. То есть, например, если вопрос звучит так «Explain what factors can affect demand of Amazon, Inc», то наш классификатор должен определить его к разделу «Market». Это был бы отличный тул для преподавателей, чтобы по мере прохождения тем давать студентам вопросы, которые бы хранились не хаотично в пдф файлах экзаменов разных лет, а где-то в одном месте, да еще и вопросы можно было бы быстро предсказывать при подгрузке новых экзаменов.

Базовая часть проекта:

4. **Сбор данных**: С сайта EDEXCEL надо будет спарсить все экзамены в формате pdf.

5. **Предобработка данных**: Создания эмбеддингов из текстов

6. **Разработка классификатора**:
    - От простых базовых моделей TF-IDF до трансформеров. Приветствуется все!!! :)

Задачи ML & DL:

4. **Обучение и валидация моделей**:
    - Сравнение точности различных моделей на тестовом датасете.
    - Использование различных техник обучения, таких как BERT.
5. **Настройка гиперпараметров**:
    - Оптимизация параметров моделей для повышения точности детекции.
    - Настройка гиперпараметров на основе солидного кросс-валидационного (CV) анализа.
6. **Разработка веб-приложения / бота**:
    - Создание интерфейса для демонстрации работы классификатора в реальном времени.

Пререквизиты:

Проект будет интересен тем, кто уже знаком с основами машинного обучения и NLP. В случае недостатка знаний в этих областях, участникам потребуется самостоятельное изучение материалов с поддержкой куратора.

9. Анализ медицинских данных

Руководители: Бобылев Денис, Сулейманов Нихат, Скворцов Илья, Белый Роман, Ширнин Александр, Блуменау Марк, Герасимова Мария, Александр Голубев

Уровень сложности: base/middle

Введение

В данном проекте предлагается использовать открытые данные ЭКГ или сигналов акселерометра для анализа здоровья человека или его активности.

Цель проекта:

Разработка системы классификации физиологических сигналов (ЭКГ, акселерометр, речь) для определения состояния здоровья и активности человека.

Задачи:

- Сбор и предварительная обработка данных.
- Извлечение и поиск релевантных признаков.
- Выбор и обучение ML моделей.
- Оценка производительности моделей.
- обучение DL моделей.

Примерный план решения:

1. Извлечение и поиск релевантных признаков:
    a. Среднее, медиана
    b. Коэффициенты Фурье
    c. MFCC
    d. Другие статистические и частотные признаки
2. Обучение классических ML моделей:
    a. Градиентный бустинг
    b. Случайные леса
    c. K-ближайших соседей (KNN)
3. Построение спектрограмм сигналов:
    a. Преобразование сигналов в спектрограммы
    b. Обучение сверточных нейронных сетей (CNN)
    c. Обучение комбинированных моделей (CNN + RNN)

Пререквизиты:

Для выполнения проекта необходимы знания Python и базовые знания ML/DL.

Другие варианты:

Эту же стратегию можно использовать для речевых сигналов, чтобы предсказывать, например, эмоции человека.

10. Добавление планинга в агента для майнкрафта

Руководители:

Уровень сложности: middle/hard

Текущие работы не умеют в сложные задачи по промпту (добыть железо, сделать броню и тд), потому что обучены только на 16 секундах. Поэтому предлагается взять уже обученного агента для игры в майнкрафт и добавить к нему планинг действий. Например, граф из действий или во few-shot через llm модели и посчитать success rate для задач.

Пререквизиты:

Для выполнения проекта необходимы знания Python, базовые знания ML/DL и большое желание разбираться в коде :)

11. Прогнозирование токсичности химических соединений

Руководители: Бобылев Денис, Сулейманов Нихат, Скворцов Илья, Павлов Игорь, Рудеев Кирилл, Блуменау Марк

Уровень сложности: base/middle

Проект в основном подразумевает использование навыков и инструментов, которые широко применимы за пределами химической области, но данный проект является уникальной возможностью взглянуть на мир анализа данных через призму ественно-научной доменной области.

Введение
На сегодняшний день химическое пространство оценивается уже в 10^60 малых молекул. Поиск химических структур, обладающих целевыми показателями, в таком огромном массиве довольно затруднителен. Химикам необходимы новые **методы навигации и фильтрации** химического пространства.

Цель работы
Разработка группы моделей классификации и регрессии для прогнозирования различных метрик токсичности химических соединений.

Задачи:

- Сбор и предварительная обработка данных.
- Извлечение и поиск релевантных признаков.
- Выбор и обучение ML моделей.
- Оценка производительности моделей.
- Применение (обучение?) DL моделей.

Примерный план решения:

1. Парсинг и сбор данных из открытых баз данных (есть порядка 20 БД).
2. Генерация и отбор признаков:
    - Физико-химические характеристики молекул
    - Молекулярные фингерпринты
    - 3d - эмбединги
3. Обучение классических ML моделей:
    - Градиентный бустинг
    - Случайные леса
    - K-ближайших соседей (KNN)
4. Ансамбли моделей и неклассические подходы:
    - Ансамблирование прогнозов на разные таргеты
    - Мультитаргет обучение
5. DL:
    - Генерация признаков нейросетевыми моделями
    - Обучение AE для сжимания признакового пространства

6. Реализация сервиса с инференсом модели (опционально)

Пререквизиты:
Для выполнения проекта необходимы знания Python и базовые знания ML/DL. Знание химии далеко необязательно, но лишним не будет =)

12. Обработка и анализ медицинских изображений

Руководители: Сулейманов Нихат, Скворцов Илья, Белый Роман, Блуменау Марк, Герасимова Мария, Александр Голубев

Уровень сложности: base/middle

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения

В рамках проекта работа будет проводиться над датасетами отсюда - https://paperswithcode.com/dataset/isic-2018-task-1

Задачи:

- Исследование различных подходов классификации для такого рода задач,
- Изучение готовых статей по данной теме,
- Написание веб-сервиса с возможность обрабатывать загруженные фотографии и выдачи прогноза.

В случае отличных результатов - возможна дальнейшая научная работа и публикация результатов

13. Предсказание движения цен на фьючерсы на основе текстовых данных

Руководители: Бобылев Денис, Поспелов Артем, Махров Иван, Белый Роман, Ковалева Александра , Качкин Дмитрий, Алексеев Леонид, Александр Голубев

Уровень: base/middle

Пререквизиты общие: знакомство с темой трейдинга и тех анализа

Пререквизиты для базового уровня: знакомство или готовность быстро ознакомиться с API

Пререквизиты для среднего уровня: базовые знания NLP

Введение:

Проект будет интересен тем, кто интересуется темой не-TA-трейдинга. Два направления развития темы – это сравнение тех анализа с анализом новостей и сравнение классических новостей с неструктурированными (такими как твиттер/reddit). Готового датасета нет. Предполагаются базовые знания в парсинге и NLP (или желание быстро и самостоятельно их приобрести).

Этапы проекта:

- Сбор данных: из новостных источников через API, а также парсингом с форумов и из соц сетей.
- Предобработка данных: готовим разные способы обработки текстов для дальнейшего сравнения.
- Подготовка эмбеддингов: также интересно сравнить разные методы.
- Разработка ML-классификаторов.
- Разработка DL-классификаторов.
- Обёртка в сервис: зависит от минимальных требований к проекту и ваших возможностей. Готова раскатать сервисы на кубере, но можем обойтись просто телеграм-ботом.

14. Биржевая и внебиржевая торговля, оптимизация портфеля

Руководители: Поспелов Артем, Алексеев Леонид, Янышев Дмитрий, Ковалева Александра, Цуриков Виталий, Качкин Дмитрий, Александр Голубев

Уровень сложности: base/middle

Пререквизиты: понимание специфики работы с финансовыми рядами, понимание отличий от классических табличных данных (структура OHLC,

хронология). Для base интерес к финансовой тематике и готовность осваивать новое.

Описание:

- оптимизация и диверсификация портфелем ценных бумаг (asset management)
- алгоритмы биржевой торговли

15. Детекция токсичных сообщений / Классификация токсичных комментариев (с определением типа токсичности: оскорбление, угроза, сарказм итд)

Руководители: Бобылев Денис, Гераськина Надежда, Сысоев Сергей, Панчук Георгий, Ковалева Александра, Абакумов Юрий, Ильинский Андрей, Ширнин Александра, Садулаев Идрис, Александр Голубев, Шатило Надежда, Арина Неволина

Уровень сложности: base/middle

Пререквизиты: Тема будет интересна тем, кто знаком с основами машинного обучения и NLP.

Введение:

Современные социальные сети и форумы часто сталкиваются с проблемой токсичных комментариев, которые могут негативно влиять на атмосферу общения и приводить к конфликтам. Популярной стала технология в дейтинг-мессенджерах по проверке партнера на “токсичность”. Данная работа направлена на создание системы детекции токсичных сообщений с использованием методов машинного обучения и обработки естественного языка (NLP).

Базовая часть проекта:

7. **Сбор данных**:
    - Парсинг комментариев с различных платформ (например, Reddit, Twitter) и создание датасета токсичных и нейтральных сообщений.
8. **Предобработка данных**:
    - Очистка текста, нормализация, удаление стоп-слов и лемматизация.
    - Добавление пробелов вокруг символов, кроме букв и цифр.
    - Применение токенизации и коррекции ошибок для слов, отсутствующих в словаре (OOV).
9. **Разработка классификатора**:
    - Использование классических алгоритмов машинного обучения (логистическая регрессия, SVM) и современных нейросетевых моделей (например, BERT, Bi-GRU, Bi-LSTM) для классификации сообщений на токсичные и нетоксичные.
    - Интеграция статистических признаков (количество слов, уникальных слов, символов и заглавных букв) в модель.

Задачи ML & DL:

7. **Обучение и валидация моделей**:
    - Сравнение точности различных моделей на тестовом датасете.

    - Использование различных техник обучения, таких как адаптивная длина последовательностей для RNN на каждом батче, и усреднение предсказаний нескольких моделей.
8. **Настройка гиперпараметров**:
    - Оптимизация параметров моделей для повышения точности детекции.
    - Настройка гиперпараметров на основе солидного кросс-валидационного (CV) анализа.
9. **Разработка веб-приложения**:
    - Создание интерфейса для демонстрации работы классификатора в реальном времени.

Ключевая фраза:

Работа по созданию системы детекции токсичных комментариев, востребованной для улучшения атмосферы общения в социальных сетях.

16. Система анализа задач службы технической поддержки с авторекомендациями

Руководители: Бобылев Денис, Гераськина Надежда,Качкин Дмитрий, Александр Голубев

Уровень сложности: base/middle (зависит от взятых задач)

Пререквизиты: интерес к ML и готовность к изучению. Большой спектр задач позволяет варьировать уровень сложности и порог входа.

Основываться на данных:
- инциденты и запросы на обслуживание (от пользователей)
- масштабные инциденты и пост-инцидентные обзоры
- проблемы и задания из них
- аварийные оповещения
- запросы на изменения
- конфигурационные единицы

Что система может делать?
- измерять производительность (разные команды делают свои кусочки работы, можно показывать, насколько хорошо) -- большей частью описательная статистика
- рассчитывать нагрузку (требуется людей сейчас / в будущем на основе исторических данных и предполагаемых изменениях)
- кластеризовать обращения (похожие случаи)
- искать особенности (такие-то инциденты похожи, но отличаются тем-то и тем-то)
- корреляция аварийных оповещений на масштабные инциденты
- распределение решений по уровням поддержки, рекомендации по сдвигу влево
- рекомендации по публичным знаниям (что можно вынести в обучающий курс для пользователей, чтобы не чинить)
- понимание, где тратится время
- как коррелируют сущности с базой данных конфигураций
- степени риска запросов на изменение на основе прошлой статистики (такая-то команда много ошибается, а эта конфигурационная единица особо важна и т.п.)
- риск возникновения масштабного инцидента на основе всех данных

17. Предсказание стоимости акций

Руководители: Ляпин Данила, Поспелов Артем, Алексеев Леонид, Павлов Игорь, Янышев Дмитрий, Ковалева Александра,Качкин Дмитрий, Александр Голубев

Трек: ML
Уровень сложности: middle

Пререквизиты: прогнозирование временных рядов, понимание специфики и структуры финансовых данных (OHLC, Volume, таймфрейм), SARIMA(X) в качестве начальной теории (посмотреть видео Рябенко - если понятно, чем отличается от таблиц, есть интерес к рынкам, то можно приступать)

Описание:
Инструментов для предсказания цены на ценные бумаги существует достаточно много - как классические статистические и эмпирические подходы, так и подходы с применением машинного обучения.

Возможные задачи:
- сбор данных
- анализ и визуализация собранных данных, агрегированная информация (средняя стоимость акции за указанный период, тренд за выбранный период и т.д.)
- Предсказание стоимости акции на основе формул (среднее за последний период), эмпирические формулы, оценка качества

ML задачи:
- Использование ML-моделей для получения прогнозов
- Использование эконометрических моделей
- Использование адаптивных моделей
- Поиск и удаление аномалий
- Поиск похожих по поведению акций

Улучшение прогноза:
- Сбор внешних дополнительных данных (новости, показатели другой природы и/или из других источников)

DL задачи:

- Использование DL-моделей для получения прогнозов
- Адаптивная селекция и/или композиция моделей

18. Предсказательные модели для игроков NBA (NHL и т.д.)

Руководители: Скворцов Илья, Махров Иван, Ковалева Александра, Хамрин Роман,
Рудеев Кирилл, Александр Голубев

Уровень сложности: middle

Пререквизиты: Основы ML, библиотеки для парсинга данных (Beautiful Soup, Selenium)

На официальных ресурсах (например, www.nba.com) есть много открытой статистики по игрокам и матчам. Имея эту статистику, можно делать как простейший анализ данных, так и искать скрытые закономерности и предсказывать нетривиальные вещи.

Возможные задачи:
- Сбор и/или поиск подходящего датасета
- По запросу выводить статистику по игроку / команде за выбранный период
- Выводить топ-N игроков / команд по заданному параметру за выбранный период
- Построение графиков в зависимости от времени

ML-задачи:
- Прогноз на результат матча
- Прогноз трансферной стоимости игрока
- Поиск талантливых игроков из низших лиг и прогноз их трансферной стоимости
- Кластеризация игроков / команд
- Применение методов анализа временных рядов к задаче

DL-задачи:

- Использование нейронных сетей для решения задач выше
- Для анализа временных рядов использование рекуррентных сетей, сравнение их результатов с ML-подходом

19. Определение тематики и суммаризация статей на habr.ru

Руководители: Бобылев Денис, Гераськина Надежда, Сысоев Сергей, Белый Роман, Абакумов Юрий, Рудеев Кирилл, Александр Голубев, Арина Неволина

Уровень сложности: middle

Пререквизиты: основы ML/DL(модели классификации и регрессии), библиотеки для парсинга данных (Beautiful Soup, Selenium)

Проект заключается в том, чтобы собрать различного рода данные с сайта habr.ru (тексты статей, рейтинг, изображения внутри текста и т д) и построить на основе них ML/DL-модели, решающие различные задачи. Проект нацелен на проработку навыков парсинга, применения моделей машинного и глубинного обучения, а также разработки полноценного сервиса.

Результатом может быть веб-приложение (сайт) или телеграм-бот, который, например, в ответ на ссылку на статью на хабре выдает список тематик, к которым можно эту статью отнести, или предсказанный рейтинг статьи.

Возможные задачи:
- Парсинг статей с habr.ru
- По тексту статьи выводить список тем, к которым можно отнести статью
- По изображениям в статье выводить тематику статьи
- Предсказание рейтинга статьи

ML-задачи:
- Применение ML-моделей для классификации текстов и изображений
- Применение регрессионных моделей для оценки рейтинга статьи

DL-задачи:
Получение эмбедингов текстов
Получение эмбеддингов изображений
Применение нейронных сетей для решения задач выше

20. Анализ цитируемости статей

Руководители: Гераськина Надежда, Александр Голубев

Уровень сложности: middle

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения, знание графовых методов или желание в них разобраться

Необходимо собрать датасет статей (либо найти готовый, либо распарсить arxiv.org) и ссылок на них, провести анализ и применить методы машинного и глубинного обучения, а также графовые модели для решения различных задач.

Возможные задачи:

- Прогнозирование наиболее развивающихся отраслей
- Определение отрасли исследования по тексту
- Классификация статей
- Анализ цитируемости с помощью графовых методов
- Применение ML/DL-методов, а также классических методов для прогнозирования временных рядов с точки зрения динамики популярности той или иной отрасли

21. Разработка аналитической платформы биржевых событий

Руководители: Поспелов Артем, Алексеев Леонид, Янышев Дмитрий, Ковалева Александра,Качкин Дмитрий, Цуриков Виталий, Качкин Дмитрий, Александр Голубев

Уровень сложности: middle

Пререквизиты: прогнозирование временных рядов, специфика рыночных данных

В этом проекте предлагается создать аналитическую платформу, которая может выступать в роли инвестиционного советника агрегируя различные финансовые и социальные данные, влияющие на стоимость ценных бумаг.
Есть **несколько направлений** в которые можно развивать данные проект:

- аналитика и визуализация данных
- прогнозирование временных рядов
- построение полноценной торговой системы

Примеры данных:

- Тинькофф Пульс
- ТГ - каналы
- Финам - экспорт котировок
- Тематические форумы, например, smartlab
- Новостные сайты
- Англоязычные сайты

Возможные задачи:

- Инженерная часть: сбор, хранение, потоковая обработка данных из различных источников, мониторинг системы, дообучение моделей в проде, развертывание в проде, написание фронта - streamlit или телеграмм бот
- NLP часть: анализ тональности, NER, кластеризация текстов, разметка данных средствами crowd-sourcing
- ML: генерация признаков, кластеризация пользователей по профилю торговли, построение предиктивных моделей, анализ графов
- Проект могут взять несколько команд и соревноваться у кого больше профита 🙂

22. Генерация логотипов бренда по текстовому описанию

Руководители: Ширнин Александр, Блуменау Марк, Александр Голубев

Уровень сложности: middle

Пользователь задает текстовое описание, а модель возвращает изображение - классическая задача text2image.

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

Возможные задачи:

- Применение техник text2image
- Создание тг-бота

23. Детекция номеров объектов методами глубинного обучения (не только номера автомобилей, но и другие номера)

Руководители: Сулейманов Нихат, Скворцов Илья, Белый Роман, Блуменау Марк, Александр Голубев

Уровень сложности: middle

Необходимо собрать датасет изображений номеров автомобилей (или например, домов, телефонов и т д) и обучить нейронную сеть детектировать области с этими номерами на изображении. Если работать с номерами домов, то можно также решить задачу определения самого номера.

Результатом может быть веб-сервис (сайт) или телеграм-бот, который по загруженному изображению выдает результат.

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

24. Классификация транспортного средства по типу кузова (классификация типа корабля / самолета по фото)

Руководители: Сулейманов Нихат, Скворцов Илья, Блуменау Марк, Александр Голубев

Уровень сложности: middle

Необходимо собрать датасет изображений транспортных средств и обучить нейронную сеть решать задачу классификации.

Результатом может быть веб-сервис (сайт) или телеграм-бот, который по загруженному изображению выдает тип транспортного средства.

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

25. Платформа для поиска похожих кроссовок

*Необязательно похожие кроссовки, можно реализовать и поиск других похожих объектов

Руководители: Бобылев Денис, Скворцов Илья, Панчук Георгий, Рудеев Кирилл, Блуменау Марк, Александр Голубев

Уровень сложности: middle

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения

В данном проекте вам предлагается построить систему поиска похожих кроссовок.

Возможные задачи:
- поиск и сбор данных (найти и скачать датасеты / найти и запарсить релевантные сайты, например, stockx)
- EDA

ML задачи:
- Обучить классификатор по брендам / моделям с помощью классического CV

DL:
- Обучить классификатор по брендам / моделям с помощью DL моделей
- Обучить бинарный классификатор, по двум картинкам определяющий, одна и та же ли это пара
- Построить image2image поиск (с использованием faiss или векторных баз данных)
- Обучение моделей с similarity learning
- Добавить text2image и image2text поиск
- Если модели работали на "чистых" изображениях (без фона), попробовать использовать данные из реального мира

26. Детекция, трекинг объектов, pose-detection

Руководители: Скворцов Илья, Цуриков Виталий, Ширнин Александр, Блуменау Марк, Александр Голубев

Уровень сложности: middle

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года, лучше не брать данную тему.

Задачи:

- Выбрать данные для обучения
- Изучение типичного pipeline
- Написание веб-сервиса с возможность обрабатывать загруженные фотографии и выдачи прогноза.

27. Дневник калорий

Руководители: Янышев Дмитрий, Ковалева Александра, Ильинский Андрей

Трек: DL
Уровень сложности: middle/pro (в зависимости от взятых задач)

Пререквизиты:

1. Знания архитектуры основных моделей классификации, детекции (смотрел лекцию, но никогда не реализовывал - ок)
2. Базовые знания SQL, хорошее знание Pytorch, Python.
3. Опыт в prompt engineering, пробовал играться с разными llm, знаешь как файнтьюнить модели в NLP.
4. Опыт работы с hugging face, kaggle.

Мотивация:

Краткое описание: Телеграмм бот/сайт с детекцией и классификацией еды на русском, на фото и ее калораж, используя внутреннюю базу калорий(Основаная часть, в дополнении можно реализовать LLM описанный далее).Реализовать возможность считать любую статистику по внесенной им информации, используя ллм. (Например пользователь спрашивает, как часто в день я совершаю перекусы, llm благодаря промпту должна написать sql запрос к внутренней базе пользователя и выдать запрашиваемую статистику). Необходимые умения (необязательно владеть всеми навыками - в таком случае будете выполнять соответствующую часть проекта)

28. Разработка экспертной системы AutoML

Руководители: Янышев Дмитрий, Александр Голубев, Арина Неволина

Трек: ML
Уровень сложности: middle

Пререквизиты: понимание стадий, через которые проходят задачи ML.

Scikit-learn (очень необходимо), XGBoost, LightGBM, CatBoost (желательно)
Optuna, Pandas, Matplotlib
умение писать оптимальный и PEP-ный код на Python

Мотивация:

Как может выглядеть сервис: пользователь загружает датасет, сервис делает первичный анализ, предлагает свои варианты дальнейших действий (выбор моделей, архитектуры нейросетей, параметров оптимизации, базлайна), проводит по шагам, позволяет вносить коррективы на каждом шаге, учитывает предпочтение на качество или скорость работы. Можно добавить вариацию с временными рядами по нескольким переменным

Интерфейс взаимодействия с пользователем может быть реализован на основе: tg-бота, Streamlit (рекомендуется), Flask и др
Команда: 2-4 человека в зависимости от объема разработки

Задачи:

Разработка системы с модульной структурой (в качестве примера можно изучить код любой open-source библиотеки), включая компоненты для загрузки данных, предобработки, генерации признаков, выбора моделей, оптимизации гиперпараметров и оценки результатов

- Реализация механизма предобработки данных: обработка пропусков, кодирование категориальных переменных, масштабирование числовых признаков и обработка выбросов
- Интеграция алгоритмов ML: поддержка различных алгоритмов для задач классификации, регрессии и прогнозирования временных рядов
- Реализация подбора гиперпараметров
- Создание средств оценки моделей: Accuracy, Precision, Recall, F1-score, AUC-ROC, RMSE и др.
- Разработка сервиса (например, Streamlit)

- Тестирование сервиса: Проверка работы системы на реальных данных (например, из банковской сферы или ритейла) и сравнение с ручным построением моделей

29. Предсказание котировок на криптовалюту

Руководители: Алексеев Леонид, Янышев Дмитрий, Ковалева Александра, Цуриков Виталий, Качкин Дмитрий, Александр Голубев

Трек: ML
Уровень сложности: middle

Пререквизиты: знакомство с темой трейдинга и тех анализа

Введение:

Эта тема скорее исследовательская, чем проектная (обсуждаемо).

Проект будет интересен тем, кто интересуется темой трейдинга. Два направления развития темы – это сравнение тех анализа с анализом новостей и сравнение классических новостей с неструктурированными (такими как твиттер/reddit). Готового датасета нет. Предполагаются базовые знания в парсинге и NLP (или желание быстро и самостоятельно их приобрести).

Возможные задачи:

- Изучение существующих статей и подходов в них.
- Сбор данных о котировках (надо будет писать на биржи/дата-поставщикам и просить данные для исследования)
- Сбор данных, если желаете прикрутить анализ новостей – из новостных источников через API, а также парсингом с форумов и из соц сетей. Это при желании лезть в NLP.
- Эксперименты с аггрегированием данных.
- Time Series Forecasting.
- Классический ML на тех анализе.
- DL

30. Построение вопросно-ответной системы с использованием RAG (retrieval-augmented generation)

Руководители: Бобылев Денис, Ляпин Данила, Чепиков Иван, Усов Александр, Махров Иван, Сысоев Сергей, Алексеев Леонид, Панчук Георгий, Янышев Дмитрий, Белый Роман, Гераськина Надежда,Качкин Дмитрий, Мустафин Фарид, Абакумов Юрий, Рудеев Кирилл, Садулаев Идрис, Александр Голубев, Арина Неволина

Уровень сложности: middle

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения, знание основных аспектов NLP (токенизация, эмбеддинги, опыт обучения моделей)

В данном проекте вам предлагается построить Q&A бота на основе RAG. Его задачей является ответы на вопросы пользователя по частной базе знаний.

Список задач, необходимый для разработки данного приложения:

- Поиск, исследование и разметка датасета (например, можно взять документацию open source проектов, или найти готовый датасет для RAG)
- Построение бейзлайна для обеих частей RAG - поиска релевантных запросам документов и генерации ответов
- Проведение экспериментов по улучшению поиска релевантных запросов. Включает в себя сравнение разных предобработок текста, анализ моделей с dense embeddings (Bert-подобные модели), sparse embeddings (SPLADE), multivector embeddings (ColBERT), гибридных подходов, а также использование re-rankers.
- Проведение экспериментов по улучшению генерации ответов. Включают в себя prompt-tuning, как ручной, так и автоматизированный (например, APO) сравнение разных llm (например, с использованием llm as a judge).
- Построение интерфейса, например, телеграмм бота

Может включать в себя дополнительные шаги, такие как оптимизация инференса, query enhancement, и другие.

31. Рекомендательная система

Руководители: Ляпин Данила, Бобылев Денис, Поспелов Артем, Усов Александр, Павлов Игорь, Ковалева Александра, Хамрин Роман, Ильинский Андрей, Александр Голубев, Арина Неволина

Трек: ML
Уровень сложности: middle/pro

Данный проект может содержать различные домены: можно рекомендовать музыкальные композиции, фильмы, книги, игры, товары и тд. Можно выбрать, что интереснее Вам :)

Один из примеров - рекомендательная систему, которая будет способна предлагать слушателям новые музыкальные композиции. Классическим подходом в рекомендательных системах является коллаборативная фильтрация (по разреженной матрице пользователь-трек, где на пересечении пользователя и трека стоят известные оценки треков юзерами сервиса, восстановить оценки неизвестные и предложить треки с наибольшими предсказанными оценками). Однако вариаций коллаборативной фильтрации весьма немало. Мы предлагаем участникам проекта попробовать несколько существующих подходов (в т.ч. нейросетевой) и сравнить качество моделей. В т.ч. в терминах трудозатрат на реализацию и поддержание, а также гипотетической масштабируемости.

В дополнение, вектор трека можно строить не только по предпочтениям других пользователей, но и брать информацию непосредственно из аудиофайла (пытаться классифицировать жанр, настроение и другие важные слуху параметры). Прочие (возможно куда более удачные) расширения задачи приветствуются, но не являются необходимыми

Пререквизиты: основные подходы и методы решения задачи рекомендации - коллаборативная фильтрация, content-based и гибридные подходы. Понимание матричных факторизаций и умение работать с разреженными матрицами

Возможные задачи:

- Собрать данные для задачи (например, из яндекс.музыки) или поискать готовые датасеты
- Проанализировать треки в разных разрезах: построить гистограмму популярности музыкальных жанров (число прослушиваний / количество минут прослушивания) за выбранный временной период, построить рейтинг популярности треков внутри каждого жанра за выбранный временной период (например, выводить топ-N, где N - заданное число треков) треков внутри каждого жанра;

ML-задачи:

- Построить рекомендательную систему по собранным данным
- Решить задачу классификации: по треку определить его жанр (или вероятности принадлежности к различным жанрам)

- Кластеризовать пользователей по музыкальным предпочтениям

DL-задачи:

- Построить рекомендательную систему с использованием нейросетевого подхода
- Попробовать улучшить качество других решаемых ML-задач при помощи внедрения DL

Дополнения:

- Подумать, каким образом можно улучшить рекомендации: сделать их более разнообразными, более “внезапными” и новыми для пользователя.
- Попробовать построить двухуровневые архитектуры
- Прикрутить к рекомендательной модели внешние признаки о пользователях/айтемах

32. Удаление размытия с изображений

Руководители: Скворцов Илья, Янышев Дмитрий, Блуменау Марк

Уровень сложности: middle/pro

Иногда фотографии получаются смазанными, хочется научиться избавляться от таких эффектов. Пример проекта - https://github.com/KupynOrest/DeblurGAN

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

Возможные задачи:

- Применение GAN и Diffusion
- Создание тг-бота
- Сбор - публикация датасета

33. Перевод жестового языка в текст/речь

Руководители: Блуменау Марк, Александр Голубев

Уровень сложности: middle/pro

Есть два датасета (https://github.com/hukenovs/hagrid, https://github.com/hukenovs/slovo), от SD, используя которые можно создать модели по преобразования фото/видео жестов в речь/аудио.

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

Возможные задачи:

- Применение DL
- Разметка в Толоке
- Создание тг-бота

34. Экстракция объектов и характеристик из текстовых описаний изображений на русском языке с применением методов машинного обучения

Руководители: Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения

Ключевые слова: компьютерное зрение, обработка естественного языка, трансформеры

В текстах содержится огромный опыт и знания других людей, которыми может воспользоваться читатель. С помощью текста можно описать некоторые действия и объекты, их выполняющие. Для определения самых важных моментов данного текста используются ключевые фразы. Они нужны для классификации и категоризации документов, облегчения и ускорения поиска информации. Кроме того, текст воспринимается лучше, когда он сопровождается иллюстрациями, на которых отражено его содержание или важные моменты. Рисование таких иллюстраций затратно по времени и ресурсам, но решением проблемы будет их автоматическое создание. Для того, чтобы автоматически проиллюстрировать текст, нужно понять, что именно должно быть на иллюстрации: объекты, их характеристики и местоположение.
Цель работы: выделить из текста объекты, их описание и положение в пространстве.

Что следует сделать:

- Предобработать текст (лемматизация, стемминг и тд).
- Наивный вариант: Разметить текст на части речи. Определить, какие существительные = объекты, а какие -- их части. Определить, какие прилагательные относятся к каким существительным.
- BiLSTM: использовать указанную модель, чтобы она по тексту предсказывала объекты, по объекту и тексту -- его описание и положение в пространстве, если есть.
- Трансформеры: использовать модель-трансформер.
- Сравнить подходы между собой по разным метрикам (например, семейство ROUGE).

Ожидаемые результаты: сервис. На вход подается строка на русском языке длиной не более 1000 символов, нужно выделить ВСЕ объекты (человек/машина/кошка) и их описание (светлые волосы/красного цвета/серого окраса) методами NLP (например, тут поможет разметка на части речи). Кроме того, можно выделить из текста (если есть) описание фона, на котором объекты располагаются.

Источники:

Про частиречную разметку: https://www.aclweb.org/anthology/P14-5003.pdf

Библиотека pymorphy2 для русского: https://pymorphy2.readthedocs.io/en/stable/

Трансформеры https://arxiv.org/pdf/1910.03771.pdf

BERT, ELMO.

Attention Is All You Need – https://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf



35. Классификация дипфейков

Руководители: Скворцов Илья, Ширнин Александр, Блуменау Марк

Уровень сложности: middle/pro

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения

Популярная задача на протяжении последних 10 лет, сейчас особенно горяча.
Изначально тема делится на 1. Классификацию человеческих лиц 2. Классификацию фейк изображений, созданных обычными условными/безусловными генеративными моделями в любом домене. Первая
задача более прикладная и решаемая, однако для второй есть несколько интересных подходов. Чуть более подробно можно почитать тут https://teletype.in/@atmyre/J6qcyBNcPcw

Вообще тут можно сильно разойтись и заниматься тем, что больше понравится

Возможные задачи:

- Сбор данных. Изучить известные датасеты, проанализировать их. Собрать свои датасеты
- Внедрение ML. Собрать признаки изображений, прогнать их через энкодер. Накрутить сверху любую интересующую модель
- Внедрение DL. Реализовать несколько моделей по статьям с открытым
кодом. Количественно сравнить их результаты

35_1. Голосовая биометрия

Руководитель: Карагодин Никита, Скворцов Илья

Тему дипфейков можно продолжить и в звуковом домене, решая задачу аутентификации пользователя.

35_2. А можно продолжить для любого домейна (текст, картинки, лица, музыка, голос, подписи) + можно совместить с задачей верификации или XAI:

36. Исследование зависимости выбора стартового learning_rate от типа данных, размера батча и прочих параметров

Руководители: Сулейманов Нихат, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения

Предлагается реализовать проект-исследование с автоматизацией процесса экспериментов для выявления зависимости между learning rate и изменением иных параметров обучения, таких как batch size, optimization method или размер и архитектура модели. В процессе работы вы будете обучать много сеток, логировать и анализировать результаты экспериментов, а также автоматизировать весь этот процесс.
Проект для студентов с базовыми навыками разработки на Python и базовыми знаниями в области DL. Если вы знаете, что такое ImageNet и AlexNet, и в чем их отличие, то проект точно для вас!

37. Построение новостного графа и сервисов вокруг него

Руководители: Гераськина Надежда, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты:
Основы теории графов, различные GNN (GCN, GraphSAGE итд), библиотеки для анализа графовых данных и построения GNN (networkx, Pytorch Geometric, stellargraph) библиотеки для парсинга данных (Beautiful Soup, Selenium)

Этот проект про парсинг новостей и про их анализ методами NLP и графовыми сетями (GNN). Почему это интересно:

1) Крупные банки и фонды давно используют модели для прогнозирования экономики и политики на основе новостей (пример BlackRock). А также предсказания влияния каждой новости на рынки/ восприятие рисков / отдельные компании.
2) В мире есть дефицит размеченных и аккуратных данных, а также инструментов анализа новостного потока. (например, GDELT Project)

Базовая часть проекта:

- Парсинг данных: telegram-каналы, базы новостей, социальные сети (Тинькофф.Пульс), отраслевых порталов (metalbulletin.ru) и т.д.
- Настройка эффективного хранения и предобработки данных (извлечение entities, работа с синонимами, классификация по темам и т.д.)
- Настройка платформы экспериментов, запуска моделей
- Создание API & сайта для взаимодействия с базой данных и моделями.

Задачи ML & DL:

- Link prediction (например, насколько связаны сущности из новостей)
- Анализ сентимента новостей, анализ сентимента вокруг entity, прогнозирования влияния / “виральности” новостей.
- Node Classification (классификация статей на темы в новостном графе)
- *Предложите свою тему?*

Если из всего описания вы запомните одну фразу:
Это проект про новости и их применение с помощью NLP и GNN. Востребовано в крупных организациях для анализа рисков.

38. Оценка качества генерации изображений

Руководители: Скворцов Илья, Блуменау Марк, Александр Голубев

Уровень сложности: middle/pro

Для сравнения генеративных моделей в основном используют либо исторически устоявшиеся метрики (FID, IS, Clip Score), либо человеческую оценку. Первые слабо коррелируют с человеческой оценкой, а оценивать все через людей довольно ресурсозатратно.

В рамках проекта предлагается проанализировать различные методы оценки качества сгенерированных изображений, проанализировать их плюсы и недостатки, разработать собственный подход на основе регрессионных / RL моделей, который может позволить из нескольких вариантов генерации выбрать «наилучший».

Пререквизиты: DL, ML, PyTorch, Generative Models

Задачи: сравнительный анализ существующих моделей, обучение/тюнинг моделей, реализация инференса генеративной модели с ранжированием результатов.

39. Прикладные задачи Computer Vision: изображения, видео и мультимодальные модели

Руководители: Сулейманов Нихат(Medical CV only), Панчук Георгий (Vision-Language), Скворцов Илья, Белый Роман (OCR), Цуриков Виталий, Ширнин Александр, Блуменау Марк, Герасимова Мария (Medical CV mainly)

Трек: DL,RESEARCH
Уровень сложности: MIDDLE, PRO

Пререквизиты: знание основных методов Deep Learning

В рамках проекта предлагается выбрать одну из прикладных задач компьютерного зрения:

- **Классификация, детекция, сегментация и трекинг объектов** на изображениях и видео.
- **Анализ видео в реальном времени:** обнаружение, сегментация и отслеживание объектов, в том числе в спортивных трансляциях.
- **OCR / Document AI:** детекция текстовых областей, распознавание русскоязычного текста и анализ структуры документов.
- **Vision-Language модели:** задачи на совместную работу с изображениями и текстом, включая image-text retrieval, zero-shot classification и архитектуры типа CLIP.
- **Другие задачи Computer Vision** в зависимости от интересов студентов и доступных данных.

Конкретная постановка и набор методов определяются совместно со студентами.

40. Идентификация искусственно сгенерированных текстов: разработка методов для обеспечения информационной достоверности

Руководители: Гераськина Надежда, Сысоев Сергей, Ширнин Александр, Александр Голубев, Арина Неволина

Уровень сложности: middle/pro

Введение:

С увеличением использования генеративных моделей, таких как GPT-4 и GPT-4o, появилась необходимость в инструментах, способных отличать текст, написанный человеком, от сгенерированного искусственным интеллектом. Данная работа направлена на создание таких инструментов, чтобы повысить достоверность информации и противостоять злоупотреблениям.

Этапы проекта:

Сбор данных:

- **Датасет:** Создание комплексного датасета, включающего тексты, написанные людьми, и тексты, сгенерированные различными моделями AI (например, Llama, GPT-4, Claude, Cohere и другие).
- **Источники:** Использование данных из различных источников, таких как OpenAI GPT2 output dataset, ELLIPSE corpus, NarrativeQA, Wikipedia, NLTK Brown corpus, IMDB movie reviews и другие.

Предобработка данных:

- **Токенизация:** Разделение текста на слова или другие значимые элементы.
- **Нормализация:** Приведение текста к унифицированному виду (например, удаление специальных символов, приведение всех символов к нижнему регистру).

Разработка классификатора - ML & DL часть:

- **Модели:** Построение и обучение моделей машинного и глубокого обучения для детекции сгенерированного текста. Использование разнообразных моделей, включая Deberta-v3, Mistral 7b и другие.
- **Тонкая настройка:** Оптимизация моделей через настройку гиперпараметров для повышения точности классификации.

Создание интерфейса:

- **Веб-приложение:** Разработка удобного веб-интерфейса для демонстрации и использования классификатора. Приложение позволит пользователям загружать текст и получать информацию о вероятности того, что текст был сгенерирован AI.

Ключевая фраза:

Работа по созданию системы для детекции текста, сгенерированного AI, важный для обеспечения достоверности информации и защиты от злоупотреблений в информационном пространстве.

41. Предсказательные модели для песен

Руководители: Ковалева Александра, Гераськина Надежда, Ильинский Андрей

Уровень сложности: pro

Необходимо собрать датасет песен с текстами, количеством прослушиваний, рейтингов и т д. Например, для этого можно воспользоваться Яндекс.Музыкой, Spotify, VK, Сбер ЗВук и т д. На основе датасета провести анализ и построить предсказательную модель.

Пререквизиты: эту задачу будет интересно решать тем, кто уже знаком с областью deep learning и готов применять нейросети. Если вы не знакомы ни с ML, ни с DL к началу года - тоже можно решать эту задачу, но будьте готовы разбираться самостоятельно (или с помощью куратора) в некоторых алгоритмах.

Возможные задачи:
- Предсказание популярности песни
- Определение тематики песни
- Определение автора песни
- Определение жанра песни

ML-задачи:
- Классификация текстов песен
- Регрессионные модели для определения популярности трека

DL-задачи:
- Применение NLP-подходов для анализа текстов песен
- Применение DL для звука

42. Предсказание динамики физической системы с помощью нейросетей

Руководители: Блуменау Марк

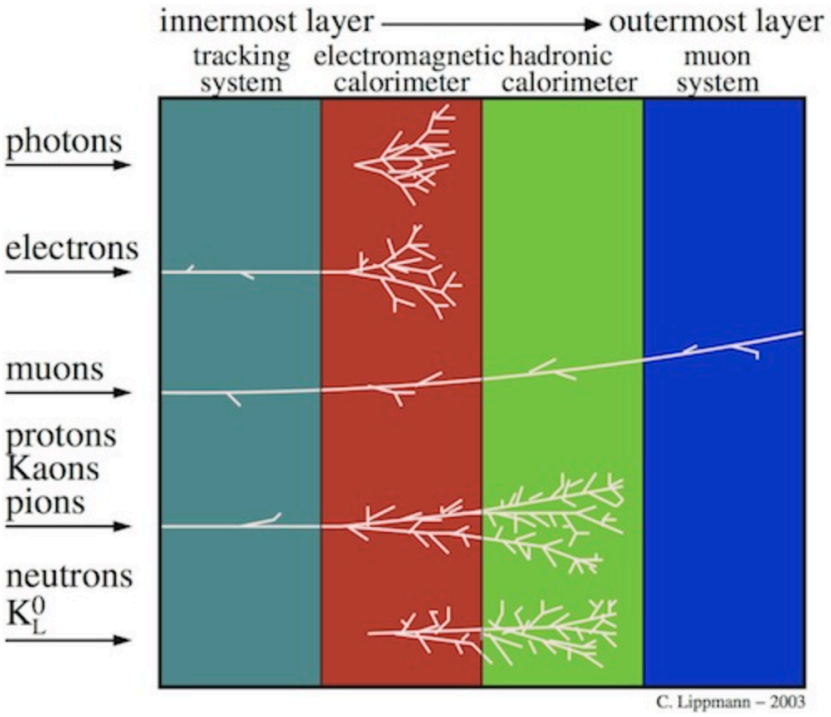
Уровень сложности: pro

Пререквизиты: должен быть опыт обучения DL-моделей

Обычно физический процесс описывается дифференциальным уравнением, в реальной жизни, чтобы предсказать физический процесс, например движение материальной точки, эволюцию энергии системы, решить уравнение не получится, так как имеется шум аппаратуры, неизвестные данные системы, которые входят в дифференциальное уравнение, поэтому актуальна задача с предсказанием динамики по набору данных с эксперимента/ смоделированного процесса с добавлением шума.

Работа с генеративными моделями, основанные на вероятностном подходе
Работа с физической системой (задачей)

Классификация частиц
Предлагается провести многоклассовую классификацию событий (частиц) в эксперименте LHCb. (детектор на адронном коллайдере)
С экспериментом можно ознакомиться здесь :
https://iopscience.iop.org/article/10.1088/1748-0221/3/08/S08005/pdf



43. Сервис для улучшения качества изображения

Руководители: Скворцов Илья, Блуменау Марк

Уровень сложности: pro

Многие интернет-ресурсы, например площадки с объявлениями, размещают контент, загружаемый пользователями. Часто изображения содержат большое количество дефектов, артефакты сжатия, загружаются в низком качестве, что может отталкивать других пользователей.

В рамках проекта предлагается изучить существующие подходы и модели для улучшения качества изображения в разных поддоменах: Low-Light Enhancement, Super-Resolution, Deblurring, Inpainting, Shadow Removal, Restoration, Denoising. В случае командной работы возможно закрепить области за различными участниками.

Итоговое решение должно представлять из себя сервис (веб-приложение / ТГ-бот), позволяющий пользователю улучшить загружаемое им изображение.

Пререквизиты: DL, ML, PyTorch, Generative Models, ONNX/TensorRT (опционально)

Задачи: сравнительный анализ существующих моделей, обучение/тюнинг моделей, ускорение моделей, реализация пайплайна для продуктового инференса моделей.

Проект будет интересен тем, кто хотел бы использовать возможности генеративных моделей в рамках практической задачи.

44. Обучаемые функции активации

Руководители: Сулейманов Нихат

Уровень сложности: pro

Пререквизиты: Знание актуальных подходов, архитектур в различных областях CV / NLP / Classic, читали статьи на arxiv: знаете их структуру +- понимаете топики, которые обсуждаются

Мотивация:

Недавно было сделано немало работ в области обучаемых функций активации, например, KAN, стоит более подробно изучить применение различных вариаций в различных доменах, возможно, улучшить существующие методы. Хочется найти области и методы, где обучаемые функции активации будут давать прирост в метриках, а также, возможно, разработать свой тип обучаемых функций активации

45. Поиск на векторах

Руководители: Панчук Георгий

Уровень сложности: middle/pro

Пререквизиты: Продвинутые знания в CV /+ NLP, желательно - знакомство с SSL методами

Обучение различных SSL методов, Contrastive Learning, Metric Learning, после получения качественных эмбеддингов прикрутить сервис поиска любого домена, который интересен. Сложность в вычислительных ресурсах и, возможно, сборе датасета.

46. SpeechGPT

Руководители:

Уровень сложности: pro

Чем предстоит заниматься:

Последние года активно развивается направление больших языковых моделей (LLM). Во многих задачах они начали превосходить (неподготовленных) людей. Последний год тема LLM получила новый виток развития: тренд пошел на развитие мультимодальных моделей, которые умеют воспринимать звуки и голоса и отвечать. (недавняя презентация GPT-4o)

SpeechGPT — мультимодальная LLM, которая умеет воспринимать текст и звук, отвечать текстом и звуком, решать разные задачи на стыке текста и звука.

В рамках проекта ожидается разрабатывать:

1. SpeechGPT – объединение ASR и LLM в одну единую модель
2. Audio Capturing – определение того, что происходит на аудио (классификация аудио). В частности, такая модель должна уметь работать в режиме ASR
3. Бенчмарк моделей – инструмент для замера моделей на различных датасетах / инференс моделей
4. Тг бот для взаимодействия с моделями. Отправляешь голосовое сообщение, получаешь ответ

В качестве GPU ресурсов:

1. Ожидается доступ к учебному серверу от ВШЭ
2. Я (куратор) готов частично проспонсировать обучение на DataSphere
3. Ресурсы от kaggle (они подойдут для дебага)

Пререквизиты:

ML трек: Вы уже знакомы с основами ML/DL, знакомы с трансформерами и NLP в целом, имеете релевантный опыт работы с DL (проекты, работа, объемные ДЗ на каких-либо курсах). Свободно пишете на Python, использовали PyTorch. **Знания в звуке необязательно знать**

Инфра: если вы не хотите заниматься тренировкой моделей/чтением статей/отбором данных, то можно ограничиться свободным знанием Python

47. Создание игры при помощи LLM с function calling в Streamlit

Руководители: Поспелов Артем, Мустафин Фарид, Абакумов Юрий

Уровень сложности: middle/pro

Чем предстоит заниматься:

- Разработать интерактивную текстовую игру на русском, в которой игроки могут взаимодействовать с сюжетной линией и персонажами, используя естественный язык.
- **Основные задачи**:
  - Реализовать пользовательский интерфейс игры с помощью Streamlit, обеспечивающий интерактивное взаимодействие.
  - Интегрировать API LLM для обработки вводимых пользователем текстовых команд и генерации ответов или действий в игре.
  - Создать базовую логику игры, включая состояние игры, персонажей и сценарные линии.

Пререквизиты:

Ожидается, что вы знаете основные методы дообучения LLM и знаете что такое Hugging Face. И конечно же больше желание разбираться в новых вещах!!)

48. Веб-сервис для автоматического анализа и скоринга кандидатов на работу по резюме и агрегированным данным из различных источников

Руководители: Гераськина Надежда, Усов Александр, Чепиков Иван, Махров Иван, Ковалева Александра,Качкин Дмитрий, Мустафин Фарид, Абакумов Юрий, Садулаев Идрис, Поспелов Артем, Александр Голубев, Арина Неволина

Уровень сложности: middle/pro

Тип: программный

Задачи (любая модификация постановки задачи приветствуется):

1. NER/Суммаризация/итд для резюме.
2. Парсинг и анализ данных с Linkedin/Jobs/Habr, а также данных о статусе учебных заведений и прочих информационных ресурсов для feature engineering.
3. Формирование эмбеддингов и скорингов кандидатов
4. Создание SaaS

49. Веб-сервис, предоставляющий информацию о динамике “настроения” отзывов об игре, а также прогноз этого “настроения” и активности игроков в целом

Руководители: Гераськина Надежда, Александр Голубев

Уровень сложности: middle

Тип: программный

Задачи (любая модификация постановки задачи приветствуется):

1. Парсинг отзывов/патчей/активности по играм со Steam
2. Анализ аудитории (гео/платежеспособность/итд)
3. Sentiment analysis для отзывов
4. Возможно, понадобится обучить эмбеддинги игр, поскольку игры влияют друг на друга
5. Применение классических моделей для временных рядов, а также LLM методов для временных рядов

50. Веб-сервис, анализирующий чаты союзов в игре

Руководители:

Уровень сложности: middle

Тип: программный/исследовательский

Задачи (любая модификация постановки задачи приветствуется):

1. Обработка/очистка данных и поиск аномалий
2. Суммаризация текста
3. Sentiment analysis
4. Прогноз динамики дохода на основе чатов союзов

51. Разработка игры на Web3

Руководители:

Уровень сложности: middle/pro

Тип: программный

Задачи (любая модификация постановки задачи приветствуется):

1. Игра может быть любая. Например, можно сделать что-то в виде квиза, в котором вопросы и ответы используют генеративные сети.
2. Предполагается тюнинг и использование генеративных моделей
3. Нужно будет разобраться с работой с блокчейном TON и экосистемой в целом
4. В качестве сервиса предлагается реализовать mini app в Telegram

52. Применение LLM для извлечения информации из текстов (в том числе с использованием RAG, LLM-агентов).

Руководители: Гераськина Надежда, Чепиков Иван, Алексеев Леонид, Панчук Георгий, Янышев Дмитрий,Качкин Дмитрий, Мустафин Фарид, Абакумов Юрий, Рудеев Кирилл, Цуриков Виталий, Садулаев Идрис, Александр Голубев

Уровень сложности: middle/pro

В настоящее время существует множество LLM, доступных только через API или open-source с возможностью локальной работы, разрабатываются LLM-агенты для решения разнообразных задач от поддержания беседы до управления игровыми персонажами. Одним из вариантов применения LLM яв ляется их использование для ответов на вопросы пользователей по имеющимся документам, базам знаний.

Предлагается на основании различных подходов реализовать решение с использованием open-source LLM по извлечению информации из текстов. Результат можно представить в виде сервиса, например, в телеграмм-боте или streamlit и т.д.

Возможные задачи:

- сравнить качество извлечения информации с использованием open-source LLM с моделями, доступными через API;
- сравнить качество извлечения информации с использованием разных open-source LLM или их комбинаций;
- повысить качество извлечения open-source LLM информации из текста с помощью применения различных методик – от изменения промптов, применения langchain, до применения llm-агентов.

53. Телеграм-бот для трекинга медицинских анализов пользователя по фотографии/файлу

Руководители: Белый Роман, Блуменау Марк

Уровень сложности: middle/pro

Пререквизиты: знание основных методов Deep Learning и Computer Vision

Обычно медицинские анализы хранятся либо на почте в разных письмах, либо в распечатанном виде. В долгосрочной перспективе это уменьшает возможность нормально отслеживать тенденции.

Хочется сделать телеграм-бота, который может вести полную историю медицинских анализов пользователя, предоставленные им с помощью фотографии или файла

Основная задача – это обучить OCR (optical character recognition) модель для работы с документами/фотографиями на русском языке. В данный момент нет доступных открытых моделей на русском. Можно будет обучать на большом количестве разных данных в интернете или как-то самостоятельно их синтезировать, а потом файнтюнить такую модель именно на анализы, ведь надо будет еще сопоставлять результат (численный) названию самого анализа

Можно еще подключить LLM для каких-то рекомендация, подсвечивать пользователю какие-то отклонения от нормы, но это уже после удачной реализации первой части

54. Art Restoration

Руководители: Скворцов Илья, Блуменау Марк

Уровень сложности: middle/pro

Пререквизиты: знание основных методов Deep Learning и Computer Vision

Как мы знаем, со временем картины портятся, от них отваливается краска или она меняет свой цвет. Хочется модель, которая бы работала с арт-объектами (картинами) и объединяла сразу несколько задач: inpainting (восстановление части “пропущенного” изображения, то есть там, где краска совсем отвалилась), colorization (восстановление цветов), image distortion correction (убирать всякие там трещины в красках и тд)

В целом много открытый моделей, которые умеют делать все вышеперечисленное, интересно было бы зафайнтюнить их в art домен и объединить в один полноценный пайплайн. И как-то ускорить, ведь прогонять картинку через несколько моделей последовательно, будет очень долго

Датасет можно собирать синтетический, брать картины из больших открытых датасетов (wikiart) и самостоятельно их портить

55. Video Style Transfer

Руководители: Ильинский Андрей

Уровень сложности: middle/pro

Пререквизиты: знание основных методов Deep Learning и Computer Vision

Сейчас есть много хороших SOTA-моделей для style transfer (переноса на изображение контента какого-то художественного стиля) и моделей, генерирующих видео. Нужно будет поисследовать, как их объеденить. К примеру, использовать идею attention-sharing в диффузионных моделях для консистентной генерации соседних фреймов, добавляя туда в cross-attention эмбеддинг стиля и всё такое

Тут можно использовать на ваше усмотрение как какие-то более базовые методы типа GAN’ов, так и диффузии (что предпочтительнее)

Проект для самых мотивированных, потому что работать с видео очень сложно и долго)) Но будем брать небольшие клипы, где-то до 5 секунд

56. Text-to-Image Generation for Personalized Story Illustration

Руководители: Блуменау Марк, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основных методов Deep Learning, NLP и Computer Vision

Хотим генерировать несколько последовательных картинок, которые в достаточной мере хорошо описывали небольшую историю, заданную пользователем. То есть сначала надо будет как-то разбивать эту историю на “действия” (используя LLM), а потом по каждому действию генерировать свои картинки так, чтобы они были в одном стиле. А герои были консистентны между картинками. То есть нужно совместить задачи style alignment, personalized generation и text-to-image генерацию, каждая из которых уже в целом хорошо решена

Датасет можно собрать с помощью той же LLMки, просить ее описать историю по картинкам из интернета, к примеру. Или использовать датасет tiny stories и как-то самостоятельно придумать лосс, который бы смотрел, а описывает ли наша картинка ту историю, которую мы ей дали (условно, генерируем картинку из истории, прогоняем ее через LLM, получаем ее описание и сравниваем с исходным текстом)

Проблема в том, что в прошлом году довольно много студентов брали эту тему, поэтому имейте в виду, придется придумать что-то интересное

57. Personalized Anime Character Generation

Руководители: Блуменау Марк

Уровень сложности: middle/pro

Пререквизиты: знание основных методов Deep Learning и Computer Vision

Кто не хочет себе аниме-девочку (или мальчика) со своим лицом? Хотим обучить модель, которая бы по текстовому описанию/картинке человека выдавала бы аниме-версию

Тут можно и style-GAN поиспользовать, и диффузии (ip-adapter и тд). По вашему желанию, но диффузии, конечно, работают лучше :)

Проблема в том, что в прошлом году довольно много студентов брали эту тему, поэтому имейте в виду, придется придумать что-то интересное

58. Предсказание результатов теннисных матчей с помощью машинного обучения

Руководители: Скворцов Илья, Махров Иван, Ковалева Александра, Хамрин Роман, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основных методов машинного обучения

Цель этого проекта — разработать модель машинного обучения, которая может предсказывать результаты теннисных матчей. Студенту предстоит собрать и подготовить данные, разработать и обучить модель, а затем проанализировать её точность и возможные улучшения.

Основные задачи:

- Сбор данных:
- Построение базовой модели, результаты которой необходимо будет превзойти:
- Подготовка данных, создание новых признаков, выбор алгоритма и обучение модели
- Оценка модели
- Анализ влияющих факторов:
- Документация и сервис, позволяющий получить предсказания для интересующего матча

Дополнительные идеи для экспериментов:

- Использовать новости (про спортсмена или турнир) как признак при обучении модели
- Использовать мнение людей как признак при обучении

Результат:

Студент должен разработать и представить работающую модель машинного обучения, способную предсказывать результаты теннисных матчей, а также предоставить детальный анализ результатов и предложить идеи для дальнейшего улучшения модели. Кроме того, модель будет обернута в сервис, который позволит любому желающему получить предсказания матчей.

59. Предсказание “популярности” новостного поста и предложение улучшений

Руководители: Чепиков Иван, Ковалева Александра, Хамрин Роман, Поспелов Артем, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основных методов машинного обучения

Цель этого проекта — разработать модель машинного обучения, которая будет предсказывать популярность новостного поста на основе его текста и изображения. Если модель предскажет, что пост не будет популярен, необходимо автоматически предложить изменения, которые могут повысить популярность и кликабельность поста.

Основные задачи:

- Сбор данных:
- Построение модели для определения популярности
- Оценка модели
- Создание LLM-агента / набора функций, которые помогут сделать пост более популярным
- Анализ влияющих факторов популярности поста
- Создать сервис, помогающий создателям контента

Результат:

- Рабочая модель для предсказания популярности новостных постов.
- Выявление основных причин низкой “популярности” поста и предложения для улучшения

60. Автоматизированная многоаспектная оценка эссе с применением методов обработки естественного языка и машинного обучения

Руководители: Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основных алгоритмов машинного и глубинного обучения

Оценка эссе – трудоемкий процесс, требующий учета множества факторов: содержания, структуры, стиля и оригинальности. Цель работы – автоматизация процесса оценки эссе/сочинений с использованием методов NLP и машинного обучения.

Базовая часть:

- Сбор данных или работа с готовыми корпусами: Набор сочинений, оцененных по различным критериям
- Предобработка текста: Токенизация, нормализация, удаление стоп-слов, лемматизация, подготовка EDA
- Разработка моделей: Построение эвристик, регрессионных моделей и нейросетевых архитектур для оценки эссе по заданным критериям (грамматика, лексика, структура и тд).

Задачи ML & DL:

- Дообработка данных: аугментация данных, создание псевдометок (Pseudo Labels), Back translation и тд
- Обучение моделей: Извлечения эмбеддингов, дообучение модей на данных, кросс-валидация для оценки качества моделей (например, MultilabelStratifiedKFold),
- Визуализация результатов: Разработка интерфейса для демонстрации результатов оценки и объяснения полученных оценок.

Поэкспериментируем с: Optuna, Pooling, различными вариантами Bert’a и Ensembling

61. Идентификация самолета по его фото (с названием и тд) с прогнозом вероятности задержки рейса по входным данным (дополнительно к фото)

Руководители: Сулейманов Нихат

Уровень сложности: middle

62. Face Recognition

Руководители: Ляпин Данила, Скворцов Илья, Блуменау Марк, Александр Голубев

Трек: DL / Research
Уровень сложности: middle/pro

Пререквизиты: знание основ Deep Learning

Разработка пайплайна для задачи Face Recognition.
Этот проект больше исследовательский, направленный на изучение новой архитектуры нейросети, чтения статей и постановки экспериментов. Он как раз примечателен своим исследовательским акцентом.

Допустим, вы владеете компанией и хотите разработать систему распознавания лиц, чтобы применять ее в своем офисе. Например, чтобы ваши сотрудники могли сканировать лицо вместо прикладывания id карточек к турникетам при входе. Или для обеспечения безопасности в офисах.

Что может включать:
1) Изучить литературу, разобраться в том, как работают системы распознавания лиц
2) Собрать датасеты (например, LFW, CASIA-WebFace, CelebA). Тут можно добавить и разметить свои фотографии 🙂
3) Обучить нейросеть для распознавания лиц на фото (face detection)
4) Обучить нейросеть для выравнивания лица по ключевым точкам (face alignment)
5) Обучить нейросеть для классификации лица (или выдачи эмбеддинга лиц) (face recognition)
6) Реализация специфичных лосс-функция для данной задачи (Triplet Loss, ArcFace Loss)
7) Собрать все в единый пайплайн: (входное фото) -> detection -> alignment -> recognition -> (выходной вектор)
8) Попробовать уже готовые решения, попробовать улучшить их, посчитать мини-бенчмарки.
9) Реализовать сервис для работы с изображениями.

Для тру хардкор бойцов можно сделать этот пайплайн и сервис под видео (аля real-time).

63. Автоматическая категоризация обращений в службу поддержки

Руководители: Махров Иван, Гераськина Надежда, Абакумов Юрий, Садулаев Идрис, Александр Голубев

Уровень сложности: middle

Пререквизиты: основы ML/DL (классификация текстов), NLP (представления текста TF-IDF, word2vec, sentence embeddings), библиотеки для парсинга (BeautifulSoup, Selenium).

Введение:

В крупных компаниях ежедневно поступают тысячи обращений в службу поддержки. Автоматическая категоризация тикетов по типу проблемы (например, «доступ», «сеть», «ПО», «биллинг») позволяет быстрее перенаправлять запросы к нужным специалистам и экономить ресурсы.

ML-задачи:

- Классификация тикетов по заранее выделенным категориям
- Кластеризация «неизвестных» тикетов для выделения новых категорий.
- Интерпретация модели (SHAP/LIME) для объяснения предсказаний.

Сервисная часть:

- API для интеграции с корпоративной почтой/системой тикетов.
- Веб-приложение или Telegram-бот, принимающий текст запроса и выдающий: категорию, вероятность, список похожих запросов.

64. NLP в Mental Health

Руководители: Залесинский Роман, Кузнецов Виктор, Андреев Дмитрий, Цуриков Виталий, Садулаев Идрис, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: основы ML/DL (классификация текстов), NLP, LLM и тд

Введение:

Тема NLP в Mental Health последнее время набирает обороты (https://arxiv.org/abs/2403.15401) и в целом в рамках данной темы можно работать в разных направлениях:

- Личный AI ассистент, который мог бы оценивать твое состояние, оценивать риски, давать рекомендации и тд;
- Помощник для специалистов в области при принятии решения;
- Инструмент для поиска и выделения в интернете групп риска.

В качестве входных данных есть определенное количество датасетов для детекции депрессии, определения уровня депрессии, детекции склонности к суициду и т.д., но а) данных всё ещё не очень много б) большинство из них собраны с реддита в) некоторые датасеты пересекаются между собой. Этот момент добавляет задачи в начале исследования - необходимо найти и изучить данные, оценить их применимость. А также добавляет задачи в конце исследования - нужно понять как реализованный сервис / модель работает с данными не из реддита (как пример), то есть оценить обобщаемость.

Что можно делать:

- тюнить большие модельки
- привязывать RAG
- собирать агентов

Конкретный вариант зависит от выбранного use-case'а, над которым предстоит подумать, также и в сервисной части - это может быть простенький сервис с апишкой, а может быть сервис с чатом.

65. Проактивная тьюторская система с использованием LLM и RAG

Руководители: Залесинский Роман, Кузнецов Виктор, Мустафин Фарид, Ильинский Андрей, Цуриков Виталий, Александр Голубев, Арина Неволина

Уровень сложности: MIDDLE/PRO

Трек: DL или RESEARCH

Пререквизиты: основы машинного и глубинного обучения, LLM, RAG, API

Цель проекта

Разработать интеллектуальную тьюторскую систему с использованием LLM-RAG архитектуры, реализующей персонализированную выдачу учебного материала, адаптивную проверку знаний и поддерживающей проактивный режим взаимодействия. Предполагается реализация с минимум несколькими темами из одной учебной дисциплины из школьной или вузовской программы.

Примерный план

- Проанализировать современные подходы к AI-tutoring системам (LLM, RAG, student modeling, proactive tutoring).
- Выбрать дисциплину (на усмотрение команды) и подготовить структурированную базу учебных материалов.
- Реализовать retrieval-модуль с векторным хранилищем и механизмом поиска релевантных фрагментов.
- Реализовать генерацию персонализированных объяснений на основе LLM +retrieved context.
- Реализовать модель пользовательского профиля (уровень освоения тем + история взаимодействий).
- Реализовать адаптивный модуль проверки знаний (генерация вопросов + автоматическая оценка + обновление профиля).
- Добавить режим проактивной подачи материала с краткой объяснительной обратной связью.

Для трека DL необходимо разработать полноценный сервис с чатом (Streamlit LLM app или Telegram Bot) и базой данных.

Для трека RESEARCH можно сфокусироваться на исследованиях в области проактивного обучения и реализовать интересные подходы для моделирования студента, проверки его знаний и персонализированного обучения.

Проактивный режим взаимодействия рекомендован для PRO, для MIDDLE можно упростить задачу и реализовать сервис с реактивным обучением по типу Q&A RAG без персонализации.

66. Прогнозирование нагрузки на электрические сети города

Руководители: Рудеев Кирилл, Александр Голубев

Уровень сложности: middle/pro
Трек: ML с внедрением DL (можно сделать акцент на сервис)

Описание:
Модель для предсказания потребления электроэнергии на основе исторических временных рядов, температуры, праздников, погоды и т.п.

Пререквизиты: классический ML, основы DL, временные ряды, PyTorch/Sklearn, базовые знания распределенных систем

Возможные цели проекта:

- Разработать и развернуть сервис краткосрочного и/или среднесрочного прогнозирования электрической нагрузки (например, с шагом 15 мин/1 ч) по узлам городской сети с учётом погодных и календарных факторов
- Обеспечить оценку неопределённости прогноза и рекомендации по сглаживанию пиков.

Возможные задачи:

- Ресерч
  - Сбор и очистка временных рядов с данными телеметрии по точкам сети, погодных рядов, календаря/праздники/события, тарифные/плановые ремонты.
  - Синтетика для редких режимов (аномальные пики/просадки).
  - Классические модели: SARIMA/Prophet/ETS, градиентный бустинг (CatBoost/LightGBM) по табличным фичам.
  - Метрики: MAE/RMSE, MAPE/wMAPE, p50/p90-погрешности; отдельная оценка на «пиковых» интервалах.
  - Кросс-валидация по сдвижному окну; бэк-тест на год.
  - Для версии ПРО можно рассмотреть графовые сети (DCRNN/Graph WaveNet) с топологией сети: узлы = шины/подстанции, рёбра = линии/импедансы.
- Сервис
  - REST API: получение прогноза по узлу/району, горизонту, плюс интервалы неопределённости.

- Дашборд (Streamlit/FastAPI + фронт) с картой/графами подстанций, историей/прогнозом и алертами.
- Визуализация прогноза в реальном времени

67. Генерация автоматических заметок по лекциям (speech-to-text + summarization)

Руководители: Карагодин Никита, Мустафин Фарид, Ильинский Андрей, Александр Голубев

Уровень сложности: pro
Трек: DL (речь + NLP)

Описание:

Построить сервис, который из аудио/видео лекции автоматически получает:

- корректный транскрипт,
- структурированные конспекты,
- краткие резюме на разных уровнях детализации
- полезные артефакты: глоссарий терминов, контрольные вопросы, таймлайны тем.

Необязательно использовать лекции в классическом представлении, можно взять научпоп-видео (они хорошо размечены таймкодами обычно), более гуманитарные темы, чтобы не погрязнуть в формулах и схемах.

Пререквизиты: PyTorch/Transformers, основы DSP/ASR, современные методы суммаризации (extractive/abstractive), опыт с FastAPI/Docker/MLflow, базовые знания очередей

Возможные задачи:

- Ресерч
  - Препроцессинг аудио: VAD (voice activity detection), подавление шума, ресемплинг (16 kHz), нормализация громкости.
  - Разметка: сегментация по темам/слайдам (если есть метаданные), таймкоды.
  - Распознавание речи (ASR)
  - Диризация спикеров (speaker diarization): выделить «лектор» vs «вопросы из зала».
  - Детектирование тем/подтем (topic segmentation) — текстовые эмбеддинги + change-point detection.
- Сервис
  - Рабочий сервис с API и простым веб-интерфейсом, который принимает лекции и отдаёт транскрипт + многоуровневые конспекты с таймкодами.
  - Потоковый инференс: частичная расшифровка в реальном времени
  - Интерфейс/дашборд: просмотр транскрипта с подсветкой, переход по таймкодам, уровни саммари, экспорт (PDF/Markdown/JSON).

Тему можно (и нужно!) адаптировать под себя, выше представлены лишь рекомендации, которые ждут Вашей корректировки)

68. Автоматическая оценка качества речи

Руководители: Скворцов Илья, Карагодин Никита

Уровень сложности: middle/pro

Трек: DL + Research

Пререквизиты: ML, DL, CNN, RNN, Transformers, PyTorch, основы обработки аудио

Цель проекта:

Разработать автоматитическую систему для оценки качества аудио, в первую очередь синтезированной речи. Система должна предсказывать субъективную оценку качества (MOS) или вычислять другие релевантные метрики

Примерный план:

- **анализ современных подходов к оценке качества аудио**: изучить существующие метрики (PESQ) и нейросетевые модели (UTMOS, NISQA)
- **Найти и подготовить данные**
- **Разрабаотать и обучить модель:** реализовать архитектуру нейронной сети (например, RNN, CNN, RCNN, Transformer, Transformer + SSL модель) для предсказания MOS и обучить её на подготовленных данных.

69. Инициативные темы

Куратор: Цуриков Виталий, Качкин Дмитрий, Герасимова Мария
Трек: ML, DL, RESEARCH
Уровень: Middle/Pro

Можете выбрать любую интересующую вас задачу\раздел и вместе додумаем до темы КР\ВКР. Советую прежде всего прочитать несколько survey по интересующему вас разделу, чтобы понимать что там происходит и интересно ли вам.

70. Анализ спутниковых и аэрофотоснимков: сегментация, детекция и классификация объектов

Руководители: Скворцов Илья, Цуриков Виталий, Александр Голубев

Уровень сложности: MIDDLE/PRO

Трек: DL

Пререквизиты: основы машинного и глубинного обучения, CV

Введение

Спутниковые и аэрофотоснимки — важный источник данных для анализа окружающей среды, урбанистики, сельского хозяйства и мониторинга катастроф. Методы компьютерного зрения позволяют автоматически извлекать из них информацию: сегментировать здания и дороги, находить автомобили, определять изменения во времени, классифицировать землепользование.

В рамках проекта студентам предлагается выбрать одну из задач (или объединить несколько) и разработать модель, решающую прикладную задачу на реальных геоизображениях.

Цель проекта

Разработать и протестировать модель для анализа геоизображений (сегментация, детекция или классификация) и продемонстрировать её работу на примерах реальных спутниковых/дроновых снимков.

Примеры задач

- Сегментация зданий на спутниковых снимках (MIDDLE)
- Детекция автомобилей и техники на аэроснимках (MIDDLE)
- Сегментация водных объектов и береговой линии (MIDDLE)
- Change Detection: выявление изменений на местности (PRO)
- Классификация типов землепользования (MIDDLE)

Подобрать и собрать датасет можно самостоятельно, либо использовать готовый.

Для реализации пользовательского сервиса можно использовать Streamlit или Telegram bot.

71. Визуализация динамики диффузии

Руководители: Родионов Никита

Уровень сложности: middle

Студенту предлагается исследовать, как меняются латентные представления изображения на разных шагах прямого и обратного процесса диффузии. Для этого можно брать скрытые состояния модели (или просто латенты на каждом шаге), а затем сжимать их с помощью UMAP/t-SNE/PCA для визуализации в 2D/3D пространстве.

Возможные результаты:

- Графики/анимации, показывающие, как траектория образа "приближается" к финальному результату.
- Сравнение траекторий для разных классов изображений (например, кошки/собаки на CIFAR-10).
- Возможные закономерности: сходятся ли траектории к "общим" аттракторам, различаются ли они между семантическими классами.
- Студент может предложить собственный способ кластеризации/метрики расстояния траекторий (например, динамика Fréchet Distance между шагами).

В целом тема – это полезный "образовательный вклад": наглядное понимание механики диффузии.

72. Feature Attribution в диффузиях

Руководители: Блуменау Марк, Родионов Никита

Уровень сложности: middle/pro

Студенту предлагается поисследовать, какие части шума или какие скрытые признаки наиболее важны для генерации конкретных деталей в изображении. Можно применять методы из explainable AI, адаптируя их к диффузионным сетям.

Возможные результаты:

- Карты "важности" на разных шагах диффузии (например, какие области шума ответственны за уши кота, какие за фон).
- Сравнение методов атрибуции и их адекватности (какие дают интерпретируемый результат, а какие — нет).
- Можно также проверить, возможно ли предсказать качество итоговой генерации по ранним attribution-метрикам. К примеру, были работы, предсказывающие карты глубины по первым шагам диффузии. Можно посмотреть, а какая еще информация содержится в ранних шагах генерации?

73. Анализ механизма внимания в диффузионных моделях

Руководители: Родионов Никита

Уровень сложности: middle/pro

В диффузионных моделях есть блоки self-attention/cross-attention. Задача студента — исследовать, как разные слои внимания участвуют в формировании глобальной структуры и локальных деталей изображения. Есть ли какие-то слои, отвечающие за “объект”? Или за “фон”? Или именно за собачку?

Возможные результаты:

- Визуализация карт внимания на разных слоях (например, верхние слои отвечают за общую форму, нижние — за текстуры).
- Проверка гипотезы: если "выключить" внимание на определённом слое, какие аспекты изображения страдают? Можно позаниматься всякими layer perturbations.
- В attention слоях еще часто наблюдается token redundancy. Можно поглядеть в ту сторону.

На самом деле, довольно обширная тема, можно прям очень разные направления потрогать

73. Сегментация коронарных артерий на ангиографических изображениях

Руководители: Скворцов Илья, Герасимова Мария

DL,RESEARCH

Уровень сложности: middle/hard

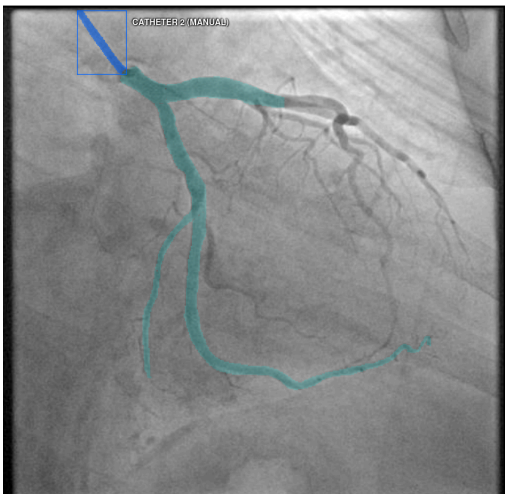
Пререквизиты: методы компьютерного зрения

Задача сегментации коронарных артерий в ангиографических изображениях заключается в автоматическом выделении сосудистого русла на рентгеновских видео или сериях кадров. Основная сложность состоит в высокой вариабельности результатов ручной разметки: разные специалисты могут сегментировать неодинаковое количество артерий, уделять внимание разным ветвям и по-разному трактовать границы сосудов. Это приводит к неполноте и неоднородности исходных данных.

Мы ставим задачу не только повторить уже имеющуюся разметку, но и **дополнить её**, формируя более полное и согласованное представление сосудистой сети. Таким образом, модель должна уметь:

- учитывать вариативность в экспертных аннотациях,
- сохранять корректность уже размеченных артерий,
- достраивать недостающие сегменты сосудов, повышая целостность финальной маски.

Такой подход позволит создать систему, которая объединяет экспертные знания и алгоритмическое дополнение, что в итоге улучшает качество сегментации и её пригодность для клинического анализа.



Для работы предлагается использовать датасет ARCADE, вполне возможно, что потребуется дополнительная ручная сегментация.

74. Автоматическое определение костного возраста по рентгенограммам кисти и запястья.

Руководители: Скворцов Илья, Герасимова Мария

DL,RESEARCH

Уровень сложности: middle/hard

Пререквизиты: методы компьютерного зрения

Основная цель исследования — разработка и внедрение алгоритмов машинного обучения, способных по рентгенограммам кисти и запястья:

- автоматически сегментировать кости кисти и запястного сустава,
- извлекать морфологические признаки, связанные с костным возрастом,
- предсказывать возраст с высокой точностью в сравнении с экспертной оценкой.

Для исследования предлагается использовать датасет.



75. Применение методов машинного обучения для анализа и визуализации климатических симуляций NASA.

Руководители: Блуменау Марк

ML,RESEARCH

Уровень сложности: middle/hard

Пререквизиты: Методы визуализации и машинного обучения

Современные климатические модели, такие как ECCO LLC4320 и DYAMOND, генерируют петаскейл-объёмы данных, содержащие информацию о динамике океана и атмосферы с высокой пространственно-временной детализацией. Эти данные открывают новые возможности для исследования экстремальных погодных явлений, океанических течений и долгосрочных процессов, связанных с изменением климата, однако их масштаб и сложность затрудняют традиционный анализ.

В рамках работы предлагается использование методов машинного обучения для автоматизированного выявления и изучения закономерностей в климатических симуляциях. Возможные направления включают:

- сегментацию и классификацию пространственно-временных структур (циклоны, вихри, фронты),
- обнаружение и прогнозирование экстремальных событий,
- построение эмбеддингов и снижение размерности для упрощения визуального анализа,
- применение методов суперразрешения для повышения качества данных.

Такая работа позволит разработать инструменты, сочетающие вычислительную эффективность и интерпретируемость, и создаст основу для более глубокого понимания климатических процессов

76. Предсказание общего спроса на недвижимость.

Руководители: Чепиков Иван, Скворцов Илья, Махров Иван, Павлов Игорь, Ковалева Александра, Хамрин Роман, Гераськина Надежда, Поспелов Артем, Александр Голубев, Шатило Надежда, Арина Неволина

ML,RESEARCH

Уровень сложности: base/middle

Пререквизиты: Методы машинного обучения

Спрос на недвижимость является ключевым индикатором состояния экономики и основным фактором, определяющим динамику цен и инвестиционную привлекательность рынка. Точное прогнозирование уровня спроса позволяет участникам рынка — от государственных регуляторов до частных инвесторов и девелоперов — принимать обоснованные решения по планированию строительства, инвестициям и управлению рисками.

Задача заключается в разработке моделей машинного обучения для предсказания общего спроса на недвижимость на основе исторических и текущих данных. В качестве входных признаков могут использоваться:

- макроэкономические показатели (ВВП, уровень инфляции, процентные ставки, уровень безработицы),
- демографические факторы (численность населения, миграция, возрастная структура),
- данные о доходах и покупательной способности населения,
- рыночные характеристики (цены на жильё, количество сделок, объем ввода нового жилья),
- пространственные данные (географическое распределение объектов, инфраструктура, транспортная доступность).

Ключевые вызовы включают высокую вариативность данных, влияние неожиданных экономических и политических факторов, а также необходимость учёта региональной специфики. Использование методов машинного обучения и статистического анализа позволяет выявлять скрытые зависимости, строить краткосрочные и долгосрочные прогнозы, а также адаптировать модели под динамично меняющуюся рыночную конъюнктуру.

Для исследования предлагается использовать датасет с kaggle или собрать данные из открытых источников своей любимой страны.

- ML, классический ML (с обязательным ML и затем внедрением DL)
- DL, глубинное обучение (проекты, где ML не предусмотрен - они обязательно имеют градацию MIDDLE или PRO
- DL,RESEARCH,

77. (Prompt-driven) Music Source Separation

Руководители: Карагодин Никита

Уровень сложности: middle/pro

Пререквизиты: Знание методов DL, работа с текстом и звуком

78. Джем-ассистент для музыкантов

Руководители: Карагодин Никита, Папулов Олег

Уровень сложности: middle/pro

Пререквизиты: Знание методов DL, работа с текстом и звуком

79. Текстовый поиск по изображениям//видео

Руководители: Панчук Георгий

Уровень сложности: middle/pro

Пререквизиты: Знание методов DL, работа с текстом и визуальным доменом

80. Определение возраста по фотографиям лица

Руководители: Ильинский Андрей, Герасимова Мария, Александр Голубев

Уровень сложности: middle

Пререквизиты: основы компьютерного зрения, нейронные сети

Основная цель исследования — создать алгоритм, который по фотографии лица сможет:
находить и обрабатывать лицо,
предсказывать возраст как число или возрастную категорию,
сравнивать разные методы (готовые модели и собственные подходы).
Прикладные варианты использования:
проверка возрастных ограничений в онлайн-сервисах,
подбор рекламного или медиаконтента под аудиторию,
анализ восприятия «реального» и «кажущегося» возраста.
Для работы можно использовать открытые наборы данных (UTKFace, AgeDB и др.) и попробовать разные архитектуры нейросетей.

81. Детекция дефектов речи с помощью скороговорок

Руководители: Ковалева Александра, Скворцов Илья, Ильинский Андрей

Уровень сложности: middle/pro

Пререквизиты: знание основных методов машинного обучения, DL

Цель этого проекта — разработать модель машинного или глубокого обучения, способную предсказывать дефекты речи по аудиозаписям скороговорок. Работа предполагает использование готового датасета, содержащего записи, где дети произносят скороговорки для выявления шепелявости и заикания. Датасет включает два типа аудиозаписей: с правильным и нарушенным произношением. В результате должна быть создана модель, которая сможет оценивать качество речи и указывать на проблемные звуки.

Основные задачи:

- Провести EDA аудиозаписей
- Построить модель для определения качества речи
- Оценка модели
- Разработать ML-модель с применением библиотек для конвертации звуков в речь или спектрограммы, которые помогут выявлять неточности в произношении
- Проанализировать факторы, влияющие на качество речи
- Создать сервис, помогающий родителям определять дефекты речи у детей :)

Результат:

- Рабочая модель для классификации речи на «хорошую» и «плохую»
- Определение звуков и сочетаний звуков, которые вызывают затруднения у ребенка

82. Прогнозирование продаж продуктов одной известной крупной компании (имя которой созвучно с планетой 🙂) с использованием временных рядов

Руководители: Ковалева Александра, Янышев Дмитрий, Рудеев Кирилл, Александр Голубев

Уровень сложности: middle/pro

Пререквизиты: знание основ анализа временных рядов, методов машинного обучения, базовые навыки работы с DL-моделями для time series.

Цель проекта — разработать модель прогнозирования продаж на основе исторических данных. В работе будет использоваться датасет с продажами за несколько лет, включающий показатели по различным категориям продуктов. Основная задача — построить модель временных рядов, которая учитывает сезонность, цикличность и долгосрочные тренды.

Основные задачи:

- Провести EDA и визуализацию временных рядов
- Выявить сезонные и циклические компоненты в данных
- Построить базовые модели прогнозирования (ARIMA, SARIMA, ETS)
- Реализовать ML/DL-модели для предсказания продаж (например, Random Forest, XGBoost, LSTM/GRU)
- Сравнить качество моделей по метрикам RMSE, MAPE, MAE
- Разработать сервис/дашборд для визуализации прогнозов и отслеживания динамики продаж

Результат:

- Рабочая модель для прогнозирования продаж с учетом сезонности и трендов
- Выявление факторов, влияющих на спрос
- Визуализация прогнозов и аналитический инструмент для поддержки управленческих решений

83. Автоматизированная система оценки рисков кредитного портфеля банка

Руководители: Поспелов Артем, Чепиков Иван, Александр Голубев

Уровень сложности: base
Трек: ML (можно сделать акцент на сервис)

Описание:
Система, которая автоматически прогнозирует вероятность дефолта клиента по заявке на кредит. Классическая задача, которая поможет познакомиться со всеми интересующими инструментами и подходами. Также можно (и нужно!) размышлять на тему - если предложите свои подходы, будет очень круто.

Пререквизиты: классический ML (градиентный бустинг, CatBoost/XGBoost), основы DL для табличных и текстовых данных (PyTorch/Transformers), знание метрик для несбалансированных выборок

Возможные цели проекта:

- разработка и развертывание сервиса скоринга клиентов (риск дефолта + вероятностная оценка)
- мониторинг качества модели во времени, алерты при деградации
- исследование fairness-моделей (непредвзятость по полу/возрасту)

Возможные задачи:

- Ресерч
  - Сбор и очистка табличных данных: финансовые признаки, транзакции, кредитная история.
  - Генерация текстовых признаков (NLP на заявках/комментариях).
  - Классические модели: логрегрессия, CatBoost.
  - DL-модели: TabTransformer, DeepFM, текстовые эмбеддинги (BERT).
  - Метрики: AUC-ROC, PR-AUC, F1 на миноритарном классе
  - Техника: upsampling/undersampling, SMOTE, cost-sensitive learning.
- Сервис
  - REST API: ввод признаков клиента, заполнение им формы → выдача вероятности дефолта.
  - Дашборд (Streamlit/FastAPI + фронт) для аналитиков: распределение рисков, динамика портфеля.
  - Pytest: тестирование сервисной части.

84. Сервис прогнозирования популярности TikTok/YouTube-видео

Руководители: Хамрин Роман, Александр Голубев

Уровень сложности: middle/pro
Трек: ML (NLP + табличные данные) с сервисной частью

Описание:
Модель для предсказания количества просмотров/лайков видео на TikTok или YouTube по метаданным (заголовок, хэштеги, длина ролика, время публикации, автор, жанр). Круто было бы использовать аудио и текст в том числе.

Пререквизиты: NLP (эмбеддинги текста: BERT, word2vec), основы ML для табличных данных (CatBoost, sklearn), понимание метрик ранжирования и регрессии

Возможные цели проекта:

- разработать сервис прогнозирования успеха контента (по метаданным и содержимому до публикации)
- исследовать влияние факторов (заголовок, хэштеги, тайминг публикации)
- сделать рекомендательную подсказку авторам «как улучшить ролик», например, “Начните видео более динамично”

Возможные задачи:

- Ресерч
  - Сбор данных: TikTok/YouTube API (метаданные + статистика по роликам).
  - Очистка и нормализация текстов (заголовки, описания, хэштеги).
  - Классические модели: CatBoost/XGBoost по табличным + текстовым признакам.
  - DL: BERT для текстов, CNN для обложек + аудио.
  - Метрики: RMSE/MAE для просмотров, классификация «успешное/неуспешное» (F1, AUC).
  - Интерпретируемость: SHAP для объяснения, что сильнее всего влияет.
- Сервис
  - REST API: ввод заголовка, хэштегов, параметров → предсказание числа просмотров.
  - Дашборд (Streamlit/FastAPI + фронт) с визуализацией прогнозов.
  - Доп. фича: генерация «идеального» заголовка/набора хэштегов с помощью LLM.

85. Детектирование аномалий в данных распределённых облаков

Руководители: Качкин Дмитрий

Уровень сложности: base/middle/pro

Пререквизиты:

1. Желательны основы ML/DL (классификация, кластеризация, метрики качества).
2. базовые знания о распределенных облачных системах и мониторинге.

Описание:
Проект востребован, над темой активно работают многие исследователи. Он подойдёт как начинающим, так и продвинутым ресерчерам, а также может стать хорошей основой для дальнейшей работы уже в рамках ВКР. По сложным техническим вопросам (работа облаков, специфика данных, примеры успешных решений) можно будет получить консультации у специалистов из ИСП РАН.

Цель проекта : построить систему автоматического анализа телеметрии (метрик и логов) распределенной инфраструктуры и выявления подозрительных состояний для обеспечения безопасности инфраструктуры .

Возможные задачи проекта

- **Сбор данных:** метрики Prometheus/OpenTelemetry, открытые датасеты (loghub) . Логи реальных облачных систем (есть большие наборы данных собранных из реальных проектов)

- **ML-подходы**
  - Unsupervised: DBSCAN, Isolation Forest, One-Class SVM.
  - Ensemble из supervised и unsupervised.
- **DL-подходы:**
  - VAE для поиска по reconstruction error.
  - **Semi-supervised:** DQNLog, Deeplog
  - LSTM/Logbert/Mamba для работы с последовательностями (аномалии по ошибке прогноза).
  - экспериментальные архитектуры Mamba + LLM, включая модели семейства Nemotron.
- **Сервисная часть :**
  - Работа с брокерами (kafka или rabbitmq)
  - Онлайн обработка данных
  - Продвинутый инференс (triton) либо fastapi .

В зависимости от интересов проект можно сместить в сторону **ML/DL research**, исследования **LLM/Mamba** для детекции аномалий, либо разработки полноценной онлайн системы обнаружения аномалий в облачной инфраструктуре.

86. Uplift-моделирование

Руководители: Усов Александр, Янышев Дмитрий, Александр Голубев, Арина Неволина

Уровень сложности: middle

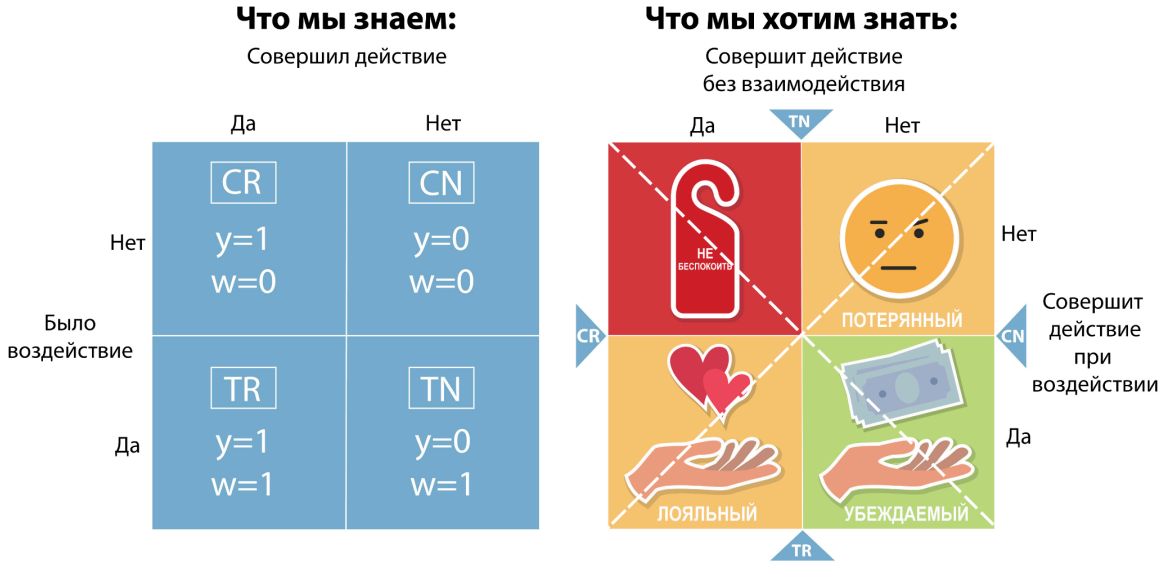
Пререквизиты: Pandas, Numpy, Matplotlib, Scikit-learn

Стек: CausalML, EconML, Scikit-uplift, AUF

Описание:

Необходимо разработать модель, которая точно прогнозирует прирост вероятности сделки клиента после воздействия (Uplift). Это позволит таргетировать рекламные коммуникации только на те группы клиентов, которые положительно отреагируют на них, исключая «бесполезные» контакты с теми, кто купит и так (лояльные) или не купит никогда (потерянные), тем самым оптимизируя маркетинговый бюджет





Задачи:

- **Сбор и подготовка данных:** Получение исторических данных о маркетинговых кампаниях, включая информацию о воздействии (например, отправленное email-сообщение), признаках клиентов и факте отклика (например, покупка).
- **Разведочный анализ данных (EDA)**
- **Дизайн эксперимента:** Подтверждение корректности проведения кампании (данных контрольной и тестовой групп)
- **Выбор и реализация методов моделирования:**
    - **Исследование классических подходов:** S-Learner (модель с признаком воздействия), T-Learner (две независимые модели), X-Learner
    - **Исследование более современных подходов:** например, методы на основе деревьев (Causal Forest)
- **Оценка качества модели:** Использование специализированных метрик для Uplift-моделирования
- **Интерпретация результатов:** Анализ полученных прогнозов, выделение групп клиентов с наивысшим predicted uplift ("убеждаемые") и с отрицательным uplift ("не беспокоить").
- **Разработка сервиса**

Почитать про аплифт:

1. **https://habr.com/ru/companies/ru_mts/articles/485980/**
2. **https://habr.com/ru/companies/ru_mts/articles/485976/**
3. **https://habr.com/ru/companies/ru_mts/articles/538934/**
4. **https://habr.com/ru/companies/alfa/articles/895002/**

87. Сервис для классификации пород собак/кошек

Руководители: Скворцов Илья, Белый Роман, Ильинский Андрей, Александр Голубев

Уровень сложности: base / middle

Цель проекта

Создать сервис, который по фото собаки или кошки возвращает топ-N наиболее вероятных пород, чтобы можно было определить как чистокровных животных, так и возможных метисов.

Этапы проекта

1. **Сбор данных**
   - Поиск готовых датасетов.
   - Дополнение картинками путем парсинга.
2. **Предобработка изображений**
   - Поиск животного на фото.
   - Вырезание и нормализация изображений.
   - Аугментация и разделение данных на train/val/test.
3. **Моделирование**
   - Извлечение признаков и обучение модели классификации пород.
   - Реализация top-n предсказаний.
4. **Оценка модели**
   - Метрики: accuracy, F1-score и др.
   - Анализ ошибок классификации.
5. **Реализация микросервиса**
   - Telegram-бот: загрузка фото → поиск животного → классификация → выдача топ-результатов.

Результаты

- Модель для классификации пород собак/кошек.
- Возможность определять вероятные породы метисов через top-n предсказания.
- Telegram-бот для загрузки фото и получения предсказаний.

88. Сервис для определения похожести на известного актера или актрису

Руководители: Архипов Максим, Скворцов Илья, Александр Голубев

Уровень сложности: base / middle

Цель проекта

Создать сервис, который по фотографии человека возвращает топ-N актёров или актрис, наиболее похожих на изображённого человека.

Этапы проекта

1. **Сбор данных**
    - Поиск готовых датасетов с изображениями известных актеров и актрис.
    - Дополнение картинками путем парсинга.
2. **Предобработка изображений**
    - Поиск лица на фотографии.
    - Вырезание и нормализация лица.
    - Определение пола (мужчина/женщина).
    - Аугментация и разделение данных на train/val/test.
3. **Моделирование**
    - Извлечение признаков и обучение модели классификации актёров.
    - Реализация top-n предсказаний по вероятности.
4. **Оценка модели**
    - Метрики: accuracy, F1-score и др.
    - Анализ ошибок классификации по полу и по отдельным актерам.
5. **Реализация микросервиса**
    - Telegram-бот: загрузка фото → поиск лица → определение пола → классификация → выдача топ-результатов.

Результаты

- Модель для определения актёров и актрис по фото.
- Telegram-бот для загрузки фото и получения топ-n актёров/актрис с вероятностями.

89. Optical Character Recognition

Руководители: Белый Роман, Цуриков Виталий, Родионов Никита

Трек: DL
Направление: Computer Vision + LLM\VLM

Уровень: MIDDLE/PRO

Пререквизиты: PyTorch, Transformers, основы CV и DL

Здесь довольно широкий пул задач, начиная от работы со сканами и печатными документами, заканчивая распознаванием текста in the wild, на вывесках в городе и автомобильных номерах.

Можно разобраться в основах, написать свою версию CRNN, а можно поработать с VLM или оптимизировать существующее решение.

90. Интеллектуальный ассистент для художников: превращение набросков в реалистичные изображения с помощью ControlNet и текстовых подсказок

Руководитель: Булыгин Глеб

Уровень: PRO
Направление: Computer Vision + Generative AI + UX

Разработка веб- или Telegram-сервиса, который позволяет пользователю загрузить грубый рисунок (например, скетч дома, человека, животного) и, используя ControlNet + Stable Diffusion (или Flux, или любую другую опенсурнсую модель), превращает его в реалистичное изображение с учётом текстового описания (например, "это должен быть старинный замок с башнями и флагами").

Задачи:

- Интеграция ControlNet (Canny, Scribble, Depth) для сохранения структуры наброска
- Fine-tuning модели на русскоязычных описаниях (если используется LLM для переформулировки запросов)
- Создание интерфейса с возможностью итеративного улучшения изображения
- Исследование качества генерации при слабом/нечётком скетче

Можно сделать open-source датасет "скетч - финальное изображение".

91. Обнаружение и классификация повреждений на памятниках архитектуры по фото с мобильных устройств

Руководители: Скворцов Илья

Уровень: PRO
Направление: Computer Vision + Cultural Heritage + Mobile AI

Создание системы (например, мобильного приложения или Telegram-бота), которая по фотографии фасада здания определяет тип повреждений: трещины, выветривание, граффити, коррозия и т.д. Система может использоваться волонтёрами, архитекторами или органами охраны памятников.

Задачи:

- Сбор и разметка датасета (можно начать с OSM + фото с Викисклада)
- Сегментация повреждений (U-Net, Mask R-CNN)
- Классификация степени износа (light/moderate/severe)
- Интеграция с картой (OpenStreetMap) для отображения "здоровья" памятников в городе

92. Автоматическая генерация 3D-моделей интерьера по 2D-фото комнаты с помощью monocular depth estimation и diffusion-моделей

Руководитель: Булыгин Глеб

Уровень: PRO
Направление: 3D Computer Vision + Generative Models + AR

По одному 2D-фото комнаты (например, из объявления о продаже квартиры) система строит приблизительную 3D-сцену: стены, мебель, окна. Это можно использовать в риелторских сервисах, дизайне интерьеров или метавселенных.

Задачи:

- Получение depth-карты с помощью моделей вроде MiDaS или Depth Anything
- Реконструкция геометрии комнаты (layout estimation)
- Генерация 3D-подобной сцены (в виде point cloud или mesh)
- Визуализация в 2.5D (panorama) или интеграция в Three.js

93. Децентрализованное обучение глубоких нейронных сетей в распределенной вычислительной среде

Руководители:

Уровень сложности: middle/pro

Пререквизиты: знание основных методов машинного обучения, DL

Предлагается реализовать децентрализованное распределенное обучение глубокой нейронной сети на распределенной системе (возможно BOINC, но не обязательно). Предполагается, что распределенная вычислительная система состоит из гетерогенных вычислительных узлов: виртуальные машины, персональные компьютеры, сервера, мобильные персональные устройства. Для тестирования предложенного подхода предлагаются актуальные прикладные задачи классификации и сегментации изображений.

Основные задачи:

- Исследование подходов распределенного обучения и выбор подхода под определенную прикладную задачу
- Исследование способов взаимодействия узлов децентрализованной распределенной системы (графы взаимодействия)
- Адаптация подхода распределенного обучения под прикладную задачу и данные
- Успешное децентрализованное обучение на большом объеме данных

Результаты:

- Подробное описание адаптированного подхода/метода децентрализованного распределенного обучения
- Сравнительный анализ результатов успешного распределенного обучения различными методами и их модификациями
- Подтверждение воспроизводимости результатов распределенного обучения
- Доклад на научной конференции
- Публикация по результатам работы

94. Решение различных задач распределенного обучения глубоких нейронных сетей на грид-системе

Руководители: Качкин Дмитрий

Уровень сложности: middle/pro

Пререквизиты: знание основных методов DL, основы распределенных вычислений

Распределенные вычислительные системы или грид-системы позволяют агрегировать географически разнесенные и разнородные ресурсы от разных организаций для решения комплексных вычислительных задач. Существует различное программное обеспечение для организации грид-систем, например BOINC – программная платформа с открытым исходным кодом. Платформа BOINC позволяет разворачивать проекты распределенных вычислений, где в качестве вычислительных узлов могут использоваться различные узлы. Предлагается развернуть распределенную систему на базе BOINC для решения нескольких задач распределенного глубокого обучения в асинхронном режиме.

Основные задачи:

- Исследование подходов распределенного глубокого обучения
- Разворачивание грид-системы (зонтичного проекта распределенных вычислений)
- Адаптация подходов распределенного обучения под грид-систему
- Успешное распределенное обучение (несколько сетей одновременно) на грид-системе

Результаты:

- Подробное описание грид-системы и ее развертывания
- Демонстрация эффективности работы грид-системы
- Результаты успешного распределенного обучения различных задач
- Подтверждение воспроизводимости результатов распределенного обучения
- Доклад на научной конференции
- Публикация по результатам работы

95. StarRL: обучение агентов StarCraft II с переносом на новые пользовательские карты

Трек: DL / RESEARCH

Уровень сложности: MIDDLE/PRO

Руководители: Ильинский Андрей

Сможет ли команда игровых агентов использовать выученную тактику, если изменить карту, расположение препятствий или стартовые позиции противника? Или высокая доля побед объясняется тем, что агенты приспособились к одному знакомому сценарию?

В проекте предлагается обучить агентов совместному управлению небольшим отрядом в StarCraft II и исследовать перенос их поведения на новые пользовательские карты. Основная постановка — короткие тактические сражения без строительства базы и управления экономикой.

Важно не только получить работающую стратегию, но и определить, какие изменения условий она выдерживает без дообучения, когда требуется адаптация и сколько взаимодействий с игровой средой это занимает.

Цель проекта

Разработать и сравнить методы мультиагентного обучения с подкреплением для пользовательских карт StarCraft II, оценить перенос обученных политик на незнакомые сценарии и создать сервис для запуска и анализа игровых экспериментов.

Среда и данные

Основной стенд — StarCraft II, PySC2 и SMACv2. Для первоначальной проверки можно использовать сценарий terran_5_vs_5, после чего перейти к собственной постановке.

Обязательная часть проекта — создать или существенно модифицировать совместимую пользовательскую карту для обучения и подготовить отдельную тестовую версию с изменённой геометрией проходов или препятствий. Простое изменение random seed не считается созданием новой карты.

Важные ограничения

Проект не предполагает воспроизведение AlphaStar, обучение полноценной стратегии для всей игры или достижение уровня профессионального игрока.

Новые стартовые позиции не доказывают перенос на новую геометрию. Успешное дообучение не считается zero-shot переносом. Рост вспомогательной награды без улучшения исходов сражений не считается улучшением игровой стратегии.

Нельзя обещать работу на любой пользовательской карте: выводы действуют только для проверенных условий и согласованного интерфейса наблюдений и действий.

Ожидаемый результат

Набор пользовательских карт и конфигураций с зафиксированным протоколом обучения и проверки.

Обученные агенты и воспроизводимое сравнение baseline, MAPPO и QMIX.

Количественная оценка переноса без дообучения и адаптации при ограниченном бюджете.

Работающий сервис запуска и анализа эпизодов для программного варианта проекта.

Отчёт о том, какие тактические навыки переносятся между картами, какие не переносятся и чем это объясняется.

96. Разработка системы диаризации речи

Руководители: Скворцов Илья, Карагодин Никита

Уровень сложности: middle/pro

В современном мире мы окружены аудиоданными: многочасовые записи рабочих совещаний в Zoom, интервью для подкастов, лекции, переговоры в колл-центрах и судебные заседания. Эта информация бесценна, но в "сыром" виде она представляет собой сплошной звуковой поток, анализировать который крайне сложно.

Нам хотелось бы быстро и точно ответить на вопрос: "Кто и когда говорил?". Эта задача называется **диаризацией**.

Цель проекта: разработать и реализовать pipeline для автоматической диаризации аудиозаписей. На входе система будет получать аудиофайл с неизвестным количеством дикторов, а на выходе — предоставлять структурированную разметку, где каждому отрезку времени сопоставлен уникальный идентификатор говорящего.

Пререквизиты: Эту задачу будет интересно решать тем, кто уже знаком с областью Deep Learning и готов применять нейросети. Будет плюсом

базовое понимание цифровой обработки сигналов. Если вы не знакомы с этими областями, будьте готовы активно в них погружаться.

Основные требования: знание классических ML алгоритмов, кластеризации, основных архитектур нейросетей

97. Virtual try on

Руководители: Карагодин Никита

Уровень сложности: pro

Индустрия онлайн-торговли одеждой сталкивается с проблемой: покупатели не могут примерить вещь перед покупкой. Это приводит к высокому проценту возвратов. Каждый возврат — это не только потери для магазина, но и негативный опыт для клиента.

Наша задача - разработать систему, которая позволит пользователю загрузить свою фотографию и примерить любую вещь из каталога, получив на выходе фотореастичное изображение.

Описание проекта: Цель проекта — создать end-to-end систему виртуальной примерки (Virtual Try-on), которая по двум изображениям фото человека и фото одежды генерирует новое изображение, где человек одет в выбранную вещь.

Пререквизиты: Глубокое понимание сверточных нейронных сетей (CNN), архитектуры генеративно-состязательных сетей (GANs) или диффузионных моделей, уверенное владение Python и PyTorch.

Рекомендация: Начать проект стоит с изучения существующих open-source реализаций, например, VITON-HD.

98. Генерация диалогов в стиле известных персонажей/писателей и оценка их при помощи самообученного классификатора

Руководители: Залесинский Роман, Мустафин Фарид, Абакумов Юрий, Александр Голубев

Уровень сложности: base/middle

С помощью промптов позволить LLM генерировать диалоги, стилистически и тонально соответствующие заданному персонажу, автору или культурному архетипу. (zero/few shots, COT).

Оценка качества генерации будет производится как при помощи других LLM, так и с помощью собственного классификатора.

ЗАДАЧИ ПРОЕКТА

1. Протестировать с разными промптами и параметрами сэмплинга для стилизации диалогов под разных персонажей.
2. Провести серию экспериментов с разными LLM и разными стилями.
3. Создать систему оценки “узнаваемости стиля”
4. Построить прототип интерактивного чат-бота с переключением стилей - streamlit/telegram bot/MAX bot.
5. Проанализировать ограничения, ошибки, дрейф стиля, “галлюцинации характера”.

99. **Мультиагентная система на основе LLM для генерации и автоматической проверки математических задач**

Руководители: Кузнецов Виктор, Абакумов Юрий, Александр Голубев

Уровень сложности: middle

Разработать и протестировать мультиагентную систему, в которой несколько LLM-агентов взаимодействуют для:

1. Генерации математических задач (алгебра, геометрия, мат. анализ, теория вероятностей, школьные задачи).
2. Автономного решения этих задач.
3. Проверки решений и выявления ошибок.

Система должна работать полностью через API LLM (без обучения моделей), а агенты — взаимодействовать по чёткому протоколу, эмулируя “педагогическую команду”. Возможно добавить api SymPy, Wolfram, используя function calling.

ЗАДАЧИ ПРОЕКТА

1. Спроектировать архитектуру мультиагентной системы для генерации и проверки задач.
2. Реализовать 3+ агентов с разными ролями на основе LLM.
3. Настроить коммуникацию между агентами (через текстовые сообщения / JSON / память).
4. Провести эксперименты: точность генерации, решения, проверки.
5. Создать прототип интерфейса (streamlit).
6. Оценить систему: насколько фидбэк полезен, где ошибаются агенты, как улучшить.

-

101. Подбор планограммы (предложил Козлов Дмитрий [@KozlovDmitry89])

Руководители:

Основная задача: подбирать/предсказывать наиболее подходящую планограмму к фото.

Алгоритм работы сервиса:

1. Подаются (на вход) данные по товарам, распознанным на фото (уже есть нейронка, которая это делает). Пример как это выглядит:

такое фото -> превращает в такие данные





2. Подается (на вход) список из возможных планограмм. Пример как это выглядит:



3. Объект (на вход) с настройками. Должен будет отвечать за «важность» того или иного фактора при подборе планограммы (например порядок, в котором стоят товары или просто их наличие или не важность конкретного товара, но важность его бренда и тд)

4. Результатом работы сервиса будет являться подобранная планограмма(или ответ, что ее подобрать не удалось) + какие доп. данные, чтоб показать пользователю, насколько «хорошо» подобралась планограмма.

102. Автоматизация построения архитектуры ПО (предложил Валентин Осипов [@valanatos])

Руководители:

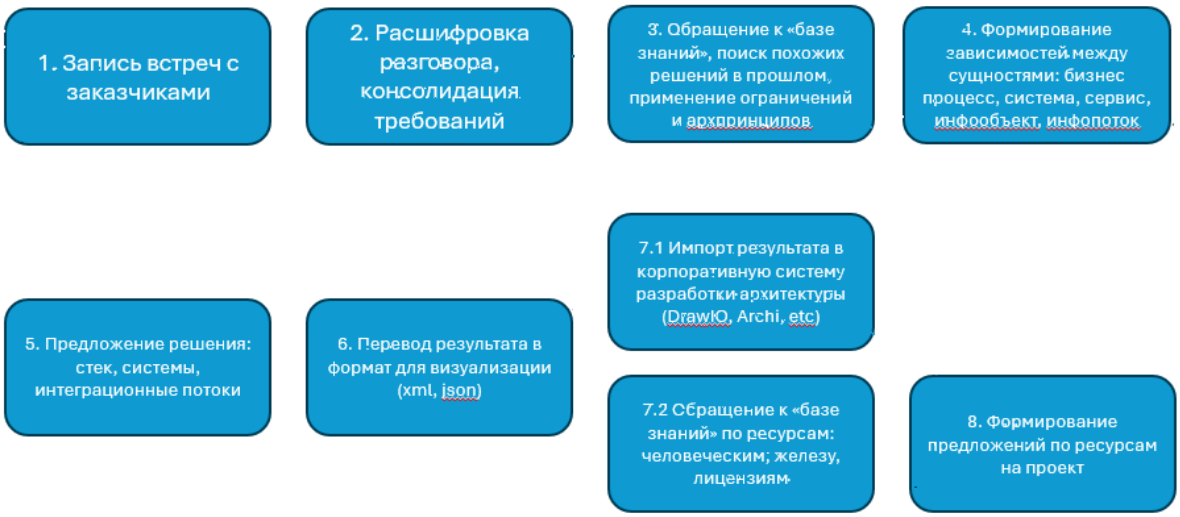
Сегодня у каждой корпорации налажены стандартизированные процессы контроля над ИТ-ландшафтом. Для этого используют как общепринятые фреймворки (TOGAF или Zachman) и нотации (ArchiMate, C4, UML и пр), так и свои собственные внутренние решения.

Все обычно сводится к следующей цепочке процессов:
Бизнес заказчик приносит свои идеи и требования – архитектор оценивает какие системы могут покрыть эти требования, какие должны взять на себя желаемый новый функционал, и представить архитектурную диаграмму с описанием бизнес-процессов в привязке к системам, потокам данных между системами. Далее, как правило, идет проработка архитектуры решения уже на более низком уровне сервисов, контейнеров, ETL/ELT на пути потоков данных – результатом работы также являются архитектурные диаграммы .
Ну а дальше следует оценка бюджета на эти доработки и, собственно, начало разработки.

Проблема
Обеспечение работы конвейера по обработки таких задач ложится на плечи архитекторов разной специализации: корпоративных, функциональных, технических, бизнес-архитекторов и архитекторов решений. При этом в крупных компаниях большая часть архитектурных решений как правило покрывается стандартными шаблонами проектирования.

Например:
1.Все интеграционные потоки между системами должны проходить через интеграционную шину
2.Для хранения данных используются корпоративные хранилища данных, как холодные, так и горячие
3.Для визуализации отчетности используется ограниченный набор BI инструментов, которые тянут данные из определенного набора источников
4.Существует утвержденный стек технологий, которыми можно пользоваться при проектировании решения (СУБД, языки программирования, инструменты виртуализации и контейнеризации, инструменты мониторинга, интеграции и пр)
В таком случае работа архитектора сводится во многом к воспроизведению шаблонных решений, подготовку которых можно переложить на системы, о которых пойдет далее речь

Пример решения (технический слой)



103. Мультиагентная AI-система для анализа безопасности смарт-контрактов: выявление и симуляция уязвимостей в блокчейнах Ethereum и TON (предложил Сергей Соловьев [@Sergey_Solovjov])

Руководитель: Качкин Дмитрий

Идея

Одной из причин, почему крупные капиталы пока с осторожностью заходят в DeFi, являются уязвимости смарт-контрактов. Я предлагаю разработать систему, которая объединяет несколько AI-агентов:

- Анализатор кода — разбирает смарт-контракты (Solidity, FunC/Tact), применяет большие языковые модели (LLM) для поиска потенциальных уязвимостей.
- Симулятор атак — воспроизводит найденные сценарии в песочнице (Ethereum fork через Foundry, TON sandbox), чтобы проверить, эксплуатируется ли уязвимость.
- Репортёр — формирует итоговый отчёт в структурированном виде.

Для повышения качества система также будет использовать RAG: LLM получает контекст из базы известных уязвимостей – есть большой датасет по Ethereum (SWC Registry, SmartBugs Dataset, отчёты аудиторов). Если окажется, что доступных данных недостаточно, можно воспроизвести агента-генератора, который будет симулировать смарт-контракты с типовыми багами и тем самым создавать дополнительные обучающие примеры. Такой синтетический датасет можно использовать как для дообучения модели, так и для тестирования всей системы

Проект полностью соответствует требованиям к программным ВКР: он включает как исследовательскую, так и инженерную составляющие.

ML/DL-часть:

o Deep Learning — применение LLM для анализа исходного кода смарт-контрактов и генерации гипотез атак;

o Machine Learning — использование для выделения «подозрительных функций», потенциально уязвимых участков кода и приоритизации результатов анализа

Инфраструктурная часть:

o технический стек полностью соответствует требованиям магистратуры. Для организации мультиагентного взаимодействия и работы с LLM будут применяться библиотеки — LangChain и LangGraph.

o демонстрация: будет предусмотрен сервис в формате утилиты или лёгкого дашборда.

Таким образом, проект сочетает в себе:

- исследовательский компонент — архитектура мультиагентной системы, сравнение подходов (LLM + RAG), оценка качества по метрикам, генерация синтетических контрактов с багами для расширения датасета;
- программную часть — разработку полноценного инструмента, который реализует весь цикл: от загрузки контракта до симуляции атаки и формирования отчёта.

105. Рекомендательная система для сайта (предложил Александр Усов [@Alexander_Usoff])

Руководители:

Крупная федеральная ювелирная компания.

Есть данные по покупкам клиентов:

ID клиента,

Дата и время покупки,

ID товара

Также есть данные с характеристиками товаров.

Необходимо создать рекомендательную систему для сайта компании, чтобы рекомендации рассчитывались на лету на основании того, что клиент купил и смотрел в последнее время.

106. Прогнозирование ликвидности банка (предложил Иван Протасеня [@protasenia_ru])

Руководители: Поспелов Артем, Александр Голубев, Ковалева Александра

Формулировка проекта

В рамках модели планируется реализация оптимизационной модели для банка с использованием временных рядов и подходов к ним (ARIMA, VARX), возможно, других методов. В качестве теоретической основы для реализации модели планируется использовать подход к оптимальному поведению российской банковской системы в работе [Пильник, Радионов, Языков, 2018] с упрощением и доработкой в отношении рынков капитала (управления торговой книгой). Для исследования вопроса будут использоваться массивы данных ЦБ РФ

Актуальность темы

Планирование ликвидности банка основная задача банковской отрасли в отношении управления балансовой книгой. Ранее в работах по моделированию банковской системы не освещались комплексные подходы с учетом торговой книги. **Задачи**

• Систематизация и обработка датасетов ЦБ РФ

• Анализ полученных данных, расчет компонентов модели

• Предсказание ликвидности банка на основе простых моделей ML-задачи

• Использование ML-моделей для получения прогнозов

• Использование эконометрических моделей

• Использование адаптивных моделей

• Поиск и удаление аномалий

DL задачи:

• Использование DL-моделей для получения прогнозов

• Адаптивная селекция и/или композиция моделей

107. Прогнозирование ключевой ставки ЦБ РФ по новостному фону (предложил Иван Протасеня [@protasenia_ru])

Руководители: Поспелов Артем, Александр Голубев, Ковалева Александра

Формулировка проекта

На основании пресс-релизов Центрального банка РФ и общего новостного фона вокруг темы ключевой ставки предсказывать ожидаемое движение ставки на периоде до двух лет. В проекте предполагается использование NLP моделей для предсказания ставки.

Актуальность темы

В зависимости от ключевой ставки банки и субъекты экономики изменяют свое экономическое поведение. Например, если ожидается повышение ключевой ставки, то люди, желающие приобрести жилье в ипотеку не по специальным программам будут создавать дополнительный спрос и давление на инфляцию. Ожидание по ключевой ставке определяет планирование в банках и напрямую влияет на рынок.

Задачи

• Сбор информации пресс-релизов ЦБ РФ и других источников

• Предобработка данных

• Разметка источников по уровню доверия исходя из реализации прошлого события

• Создание эмбеддингов

• Разработка ML-классификаторов

• Разработка DL-классификаторов

108. Генерация ASMR-видео

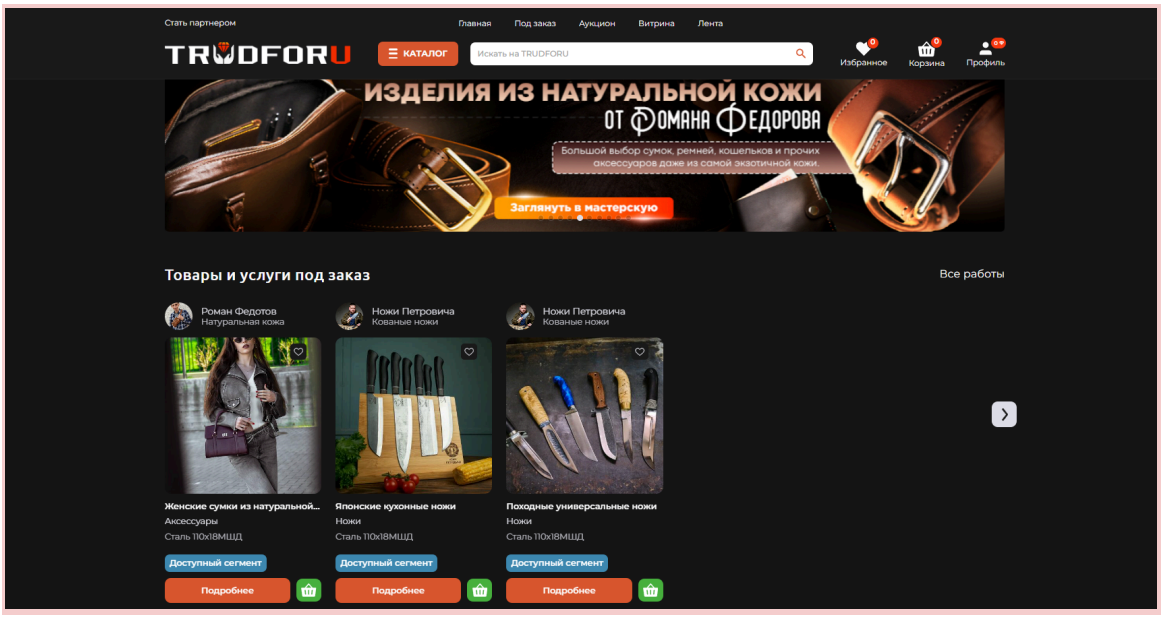
Руководители:

Будет сложно

109. Разработка рекомендательной системы товаров на маркетплейсе для производителей TRUDFORU (предложил Викторов Александр [@a_victorov])

Руководители: Александр Голубев

Уровень сложности:



Меня зовут Александр Викторов и мы с командой больше 5 лет занимаемся своим производством, а также продвигаем некоторых других производителей, помогая им продавать их товар. Поэтому мы не понаслышке знаем, как сложно конкурировать качественному продукту из дорогих материалов с китайскими товарами на универсальных крупных маркетплейсах. Ведь по одной картинке и краткому описанию очень сложно оценить реальные преимущества, а ценник отличается в разы. К тому же алгоритмы крупных маркетплейсов разумеется будут продвигать более популярный массовый товар. Поэтому мы разработали свою площадку TRUDFORU, где приглашаем к сотрудничеству только реальных производителей (не перекупов) с хорошим рейтингом.
Рекламные бюджеты хорошие, наличие данных о поведении пользователей гарантируем. Данные о товарах подготовим. В сентябре вносим последние правки и выпускаем, пока сайт запаролен, могу дать доступ и ответить на все вопросы в лс.

Цель проекта: разработать и реализовать в рамках микросервиса рекомендательную систему товаров для нашего сайта TRUDFORU.

Пререквизиты:

Основные требования:

110. Бот-агрегатор постов в TG (предложил Максим Алексюк [@maleksjuk])

Руководители: Мустафин Фарид

Задача. Создать телеграмм-бота, который будет выдавать пользователю:

1) подборку наиболее интересных ему статей по какому-либо конкретному каналу,

2) подборку относительно объективных новостных постов из разных источников.

Наиболее близкие к этому темы:

- 19 (определение тематики и суммаризация статей на Хабре)

- 31 (рекомендательная система)

- 37 (построение новостного графа и сервисов вокруг него)

111. Game State Reconstruction (предложил Олег Байшев [@dxdxxd])

Руководители: Блуменау Марк

В футболе. Комбинация задач детектирования, трекинга, реидентификации игроков, ocr номеров на форме, классификации по командам, а также локализация поля - конвертация позиций игроков с пространства изображения в реальные координаты. Несколько камер

112. Транспортная видеоаналитика (предложил Олег Байшев [@dxdxxd])

Руководители: Блуменау Марк

Пайплайн с детектированием и трекингом транспортных средств и последующим распознаванием номеров

113. Voice Cloning

Руководители: Карагодин Никита

Уровень сложности: pro

Трек: DL (Audio + Speech)

Описание:

Построить пайплайн автоматического мультиязычного дубляжа видеоконтента (сцены из фильмов, мультфильмов или сериалов) с сохранением тембра, эмоциональной окраски и просодии оригинальных актёров. Сервис принимает на вход видеофрагмент, отделяет речь от фонового звука, переводит реплики на целевой язык с контролем таймингов и синтезирует дубляж клонированными голосами персонажей, аккуратно микшируя результат обратно с оригинальным саундтреком и шумами.

Для проекта можно взять фрагменты любимой анимации (где голоса выразительнее и проще валидировать эмоции) или классические кинематографические сцены с несколькими спикерами.

Пререквизиты: PyTorch, архитектуры современных нейросетевых TTS/VC (VITS, Flow Matching, Diffusion/Autoregressive TTS, Neural Codecs), ASR + Diarization (Whisper, PyAnnote), базовые алгоритмы DSP и работы с аудио (Demucs, torchaudio), основы FastAPI/Docker.

Тему можно (и нужно!) адаптировать под себя, выше представлены лишь рекомендации, которые ждут Вашей корректировки)

114. Система мониторинга и детекции аномалий сетевого трафика

Руководители: Скворцов Илья, Гераськина Надежда, Александр Голубев

Введение:

Глобально есть несколько проблем, которые хочется пересерчить и потом уже в зависимости от результатов предложить программное решение. А проблемы варьируются от сборки и разметки трафика для обучения, до проблем с валидацией результатов и перепелетениями с современным криптографическим стеком.

Цель проекта:

Хотелось бы создать систему, которая в реальном времени анализирует сетевой трафик, классифицирует приложения и обнаруживает подозрительную активность, используя различные источники данных и методы анализа.

Исследовательская часть:

Продолжить работу над классификацией зашифрованного трафика, но расширить ее до детекции аномалий. Исследовать, какие данные можно извлечь из сетевого трафика без нарушения шифрования: размеры пакетов, временные паттерны, TLS метаданные, DNS запросы, поведенческие характеристики хостов.

ML задачи:

Использовать статистические тесты NIST как один из источников признаков для Random Forest и SVM. Добавить анализ TLS handshake - сертификаты, cipher suites, JA3 fingerprints. Анализировать DNS запросы и их временные паттерны. Применять методы обнаружения аномалий: Isolation Forest, One-Class SVM для поиска необычного поведения. Кластеризация хостов по их сетевому поведению для выявления групп риска. Может в целом пересмотреть то, как я подходил к классификации в ВКРБ.

DL задачи:

Обучить автоэнкодеры для детекции аномалий на комбинированных признаках - статистические характеристики + TLS метаданные + поведенческие паттерны. Использовать LSTM/GRU для анализа временных последовательностей - изменения в DNS активности, периодичность соединений, эволюция TLS fingerprints. Transformer-архитектуры для работы с последовательностями сетевых событий. Попробовать графовые сети для

анализа коммуникационных графов между хостами - кто с кем и как часто общается.

Продвинутые подходы:

Может попробовать GAN-сети для генерации синтетических сетевых паттернов и обучения на них детекторов аномалий(так как есть проблема с сбором данных реальных атак, мало кто их публикует). Self-supervised обучение на больших объемах немаркированного трафика.

Сервисная часть:

В рамках диплома я реализовал только основной модуль с классификацией и обучением моделей, но там пока много сырых мест. Глобально хочется двигаться в сторону веб-клиента с дашбордом, показывающим состояние сети в реальном времени - карты коммуникаций, тренды трафика, алерты по аномалиям, что-то в этом духе.

115. Интеллектуальная система прогнозирования популярности постов и оптимизации контента

Руководители: Андреев Дмитрий
Сложность: middle

Пытаемся заранее предсказать популярность поста, переписываем пост с помощью моделей для максимизации конверсий.

116. Предсказание ретросинтеза: какими путями можно получить молекулу, и какие из них оптимальны

Трек: ML / DL

Уровень сложности: base/middle

Руководитель: Виктор Кузнецов

Пререквизиты: Python, базовые знания ML/DL. Знание химии или интерес к ней.

Введение

По целевой молекуле надо определить, из каких более простых веществ её можно получить, и при помощи каких механизмов, реакций. Данные довольно доступны. Похожими задачами занимаются ведущие институты мира. При разработке новых лекарств или материалов, важно иметь представление о потребностях в реактивах, энергии, оценивать количество отходов

Цель работы

Разработать модель ретросинтеза, которая по структуре целевой молекулы предсказывает вероятные исходные вещества (реагенты), условия реакции и собрать на ее основе прототип сервиса с оценкой уверенности предсказаний.

Примерный план решения

1. Данные

- USPTO-50k — стандартный открытый бенчмарк ретросинтеза с готовыми train/val/test-сплитами. Дополнительно: Open Reaction Database (ORD), полный набор USPTO.
- Извлечение шаблонов реакций с RDKit

2. Baseline и улучшение

- Признаки: молекулярные фингерпринты (Morgan / ECFP), физико-химические дескрипторы.
- классификация: какой шаблон реакции применим к данной молекуле.
- Модели: градиентный бустинг, случайный лес, KNN, полносвязная нейросеть.
- Применение предсказанного шаблона через RDKit: список молекул-предшественников.
- DL-подходы: seq2seq, Transformer по SMILES

3. Оценка качества

- top-1 / top-5 / top-10 accuracy, попал ли верный набор реагентов в первые k предсказаний.
- Доля синтаксически валидных предсказанных молекул
- Сравнение с опубликованными результатами

4. Сервис и визуализация (опционально), посмотреть **Reaxys, сделать лучше!**

Направления развития

Исследовательская или стартап-составляющая:

- Ранжирование маршрутов по практичности: число стадий, доступность и стоимость реагентов.
- Оценка «зелености» маршрута: метрики зелёной химии (E-factor), выбор растворителя.
- Оценка условий и энергозатрат стадий; флаги безопасности (опасные реагенты и условия).

- Интерпретируемость: почему модель предложила именно этот путь.

117. Рекомендательная система книг/фильмов с объяснением рекомендаций

Руководители: Хамрин Роман Евгеньевич, Александр Голубев

уровень: middle/pro

Описание: пользователи в современном мире хотят видеть не только рекомендации, но еще и их объяснение. на данный момент в исследовательском поле существует множество статей, посвященных внедрению LLM в сферу рекомендательных систем для решения подобных задач

Пререквизиты (необязательные, можно разобраться по ходу дела): базовое знание RecSys (базовые подходы, матричная факторизация и фильтрации, опционально нейросетевые модели рекомендаций), понимание метрик рекомендательных систем, LLM (поверхностное понимание)

Возможные цели проекта:

– улучшение качества модели рекомендаций
– улучшение обоснования рекомендаций
– улучшение пользовательского интерфейса

возможные задачи:

- Ресерч
    - Сбор и очистка данных (перебор публичных датасетов)
    - Подготовка данных (предобработка, добавление мета-информации)
    - Бейзлайновые модели (например, TopPop BayesMean)
    - Модели машинного обучения (например, ALS)
    - Опционально модели глубинного обучения (например, графовые модели)
- Сервис
    - Умный поисковик по книгам
    - Сервис с возможностью получить рекомендации и объяснение их релевантности
    - Личный кабинет с историей чтения и возможностью ведения читательского дневника
    - Возможность общаться с LLM для погружения в контекст произведения

118.Сервис для автоматического анализа и сегментации опухолей на медицинских изображениях

Трек: DL
Уровень сложности: MIDDLE

Руководители: Сулейманов Нихат

Введение

Современные методы глубокого обучения позволяют автоматически обнаруживать и выделять патологические области на медицинских изображениях. В рамках проекта предлагается разработать полноценный сервис для анализа медицинских снимков и автоматической сегментации опухолей.

Цель работы

Разработка веб- или desktop-приложения, позволяющего врачу загружать медицинские изображения и получать результат автоматической сегментации опухолей.

Задачи

- Изучение современных методов сегментации медицинских изображений.
- Подготовка и обработка медицинских датасетов.
- Обучение и сравнение моделей глубокого обучения.
- Разработка пользовательского интерфейса.
- Интеграция модели в сервис.
- Реализация инфраструктурной части проекта.
- Оценка качества работы системы.

Примерный план решения

- Подготовка датасета.
- Обучение моделей U-Net, nnU-Net, Attention U-Net и других архитектур.
- Анализ результатов по Dice Score, IoU и другим метрикам.
- Разработка REST API и пользовательского интерфейса.
- Контейнеризация и мониторинг сервиса.

Пререквизиты

Python, основы машинного обучения и глубокого обучения.

119.Генерация синтетических медицинских данных для улучшения сегментации опухолей

Трек: RESEARCH
Уровень сложности: PRO

Руководители: Сулейманов Нихат

Введение

Одной из основных проблем медицинского машинного обучения является ограниченное количество размеченных данных. Генеративные модели позволяют создавать синтетические изображения, которые могут использоваться для повышения качества обучения моделей сегментации.

Цель работы

Исследование возможностей генеративных моделей для расширения медицинских датасетов и повышения качества сегментации опухолей.

Задачи

- Изучение современных GAN и Diffusion-моделей.
- Генерация синтетических медицинских изображений.
- Оценка качества синтетических данных.
- Анализ влияния сгенерированных данных на качество сегментации.

Примерный план решения

- Подготовка медицинских датасетов.
- Обучение генеративной модели.
- Генерация новых изображений и масок.
- Обучение сегментационных моделей на расширенном датасете.
- Сравнение результатов с базовыми подходами.

Возможные направления исследования

- GAN-based генерация.
- Diffusion Models.
- Semi-supervised Learning

Пререквизиты

Знание Python и основ глубокого обучения.

120.Создание универсальных adversarial-примеров для различных архитектур глубоких нейронных сетей

Трек: RESEARCH
Уровень сложности: PRO

Руководители: Сулейманов Нихат**, Александр Голубев**

Введение

Небольшое, практически незаметное для человека изменение изображения может заставить нейронную сеть неправильно его классифицировать. Например, человек продолжает видеть на фотографии собаку, а модель начинает распознавать её как кошку.

В рамках проекта предлагается исследовать, можно ли создать такое изменение изображения, которое будет заставлять ошибаться **сразу несколько разных нейронных сетей**.

Задачи

- Изучение существующих adversarial-атак.
- Генерация универсальных возмущений.
- Анализ переносимости атак.
- Исследование методов защиты моделей.

Примерный план решения

- Реализация FGSM, PGD и других атак.
- Генерация универсальных adversarial-примеров.
- Оценка эффективности атак на различных архитектурах.
- Исследование методов adversarial training.

Пререквизиты

Глубокое обучение, Python, компьютерное зрение.

121.Прогнозирование цен на рынке электроэнергии Day-Ahead с использованием методов машинного обучения

Трек: ML
Уровень сложности: base/MIDDLE

Руководители: Сулейманов Нихат**, Александр Голубев**

Введение

Точное прогнозирование цен на рынке электроэнергии позволяет участникам рынка принимать более эффективные торговые решения и снижать финансовые риски.

Цель работы

Разработка моделей прогнозирования цен на рынке электроэнергии Day-Ahead на следующие сутки.

Задачи

- Сбор и анализ рыночных данных.
- Построение признаков на основе исторических данных и внешних факторов.
- Обучение моделей машинного обучения и глубокого обучения.
- Сравнение качества прогнозов.

Примерный план решения

ML этап

- Linear Regression.
- Random Forest.
- CatBoost.
- XGBoost.
- LightGBM.

DL этап

- LSTM.
- Temporal Convolutional Networks.
- Transformers для временных рядов.

Дополнительные направления

- Прогнозирование ценовых скачков.
- Вероятностное прогнозирование.
- Использование погодных данных и прогнозов генерации ВИЭ.

Пререквизиты

Основы анализа данных, машинного обучения и временных рядов.

123.Multi-Task и Adversarial Multi-Task Learning для сегментации опухолей различных органов

Трек: RESEARCH
Уровень сложности: PRO

Руководители: Сулейманов Нихат

Введение

Большинство существующих моделей обучаются для одного органа или одного типа опухоли. Multi-Task Learning позволяет обучать единую модель для нескольких задач одновременно, что может повысить качество и устойчивость моделей.

Цель работы

Исследование методов Multi-Task Learning и Adversarial Multi-Task Learning для сегментации опухолей различных органов.

Задачи

- Подготовка датасетов нескольких органов.
- Разработка многозадачных архитектур.
- Исследование adversarial-подходов в многозадачном обучении.
- Сравнение с отдельными специализированными моделями.

Примерный план решения

- Использование датасетов LiTS, KiTS и других открытых наборов данных.
- Реализация Multi-Task архитектур.
- Исследование методов совместного обучения.
- Анализ качества сегментации печени, почек и других органов.
- Сравнение вычислительной эффективности и качества моделей.

Возможные направления исследования

- Liver + Kidney Segmentation.
- Multi-Organ Tumor Segmentation.
- Domain Adaptation.
- Transfer Learning между медицинскими задачами.

Пререквизиты

Уверенное знание глубокого обучения, компьютерного зрения и Python.

124.Сегментация опухолей печени на медицинских изображениях с использованием глубоких нейронных сетей

Трек: DL
Уровень сложности: MIDDLE

Руководители: Сулейманов Нихат

Введение

Автоматическая сегментация опухолей печени является одной из наиболее востребованных задач медицинского компьютерного зрения и может использоваться для поддержки принятия врачебных решений.

Цель работы

Разработка и сравнение моделей глубокого обучения для автоматического выделения опухолей печени на медицинских изображениях.

Задачи

- Изучение открытых медицинских датасетов.
- Подготовка данных и обучение моделей.
- Сравнение различных архитектур.
- Анализ результатов.

Примерный план решения

- Использование датасетов LiTS и аналогичных.
- Обучение моделей U-Net, nnU-Net и других архитектур.
- Оценка качества по Dice, IoU, Precision и Recall.
- Анализ ошибок моделей.

Пререквизиты

Python, основы ML и DL.

125. Использование мультимодальных медицинских данных для сегментации опухолей

Трек: RESEARCH
Уровень сложности: Middle/PRO

Руководители: Сулейманов Нихат

Введение

В клинической практике решение о диагнозе принимается на основе различных источников информации: медицинских изображений, лабораторных анализов и клинических данных пациента. Совместное использование этих данных может повысить качество моделей искусственного интеллекта.

Цель работы

Исследование мультимодальных методов для повышения качества сегментации опухолей.

Задачи

- Подготовка различных типов медицинских данных.
- Исследование методов объединения признаков.
- Разработка мультимодальных архитектур.
- Сравнение результатов с одномодальными моделями.

Примерный план решения

- Работа с КТ, МРТ и клиническими данными.
- Реализация мультимодальных нейронных сетей.
- Исследование различных стратегий fusion.
- Анализ вклада каждого источника данных.

Пререквизиты

Основы глубокого обучения и компьютерного зрения.

126. Реконструкция 3d модели животного по разрозненным домашним фото.
Уровень: MIDDLE/PRO
Трек: DL/ресерч
Пререквизиты: базовые знания DL, желание поработать с CV / 3D, наличие домашних животных - большой плюс
Руководитель: Папулов Олег (@Olegiy)

Описание: Задача - превратить фотографии и видео конкретного питомца (с разных ракурсов и не в “полный рост”) в качественную 3D-модель со скелетом, готовую к анимации.
Готовые модели для 3D-реконструкции животных (SMAL и её развитие) существуют, но у них есть конкретная слабость: они хорошо изучены для собак и лошадей, и заметно хуже — для всего остального. При этом буквально в последние месяцы (2025–2026) вышла серия статей, решающих ровно эту проблему новыми методами — синтетическая генерация данных через диффузионные модели, биологические приоры для редких видов, компактные foundation-модели для 3D-реконструкции без калибровки камеры. Мы берём самые свежие подходы и адаптируем их под наш конкретный сценарий: обычные, "домашние" фото, а не студийная съёмка. В планах:

- Аудит и воспроизведение современных SOTA-моделей реконструкции животных на готовых бенчмарках — понять, что уже работает и на каких условиях.
- Генерация синтетических данных через диффузионные модели — воссоздание пайплайна из статей, дающих SOTA-результат вообще без реальных данных.
- Дообучение регрессора (фото → 3D-модель) на объединённых данных, с современными трюками против типичной проблемы "усреднения" для редких видов.

127. Персонализированное поведение виртуального питомца

Уровень: MIDDLE/PRO
Трек: DL/ресерч
Пререквизиты: базовые знания DL, наличие домашних животных - большой плюс
Руководитель: Папулов Олег (@Olegiy)

Описание: может ли один и тот же виртуальный питомец в одной и той же ситуации вести себя по-разному, в зависимости от того, чей он аватар — так же, как два реальных кота, разбуженные хозяином, поступают по-разному: один продолжит спать, другой сорвётся бежать навстречу.
Ближайшая опубликованная работа по теме — Liang et al., CHI 2021, "Scene-Aware Behavior Synthesis for Virtual Pets in Mixed Reality": LSTM-генератор, учитывающий, что "idling чаще следует за eating" — то есть паттерны, зависящие от истории поведения, а не только от текущего момента. Но там один общий генератор на всех кошек, без различения отдельных особей, и привязка к сцене — отдельный шаг после генерации, не часть самой модели.
Мы расширяем эту работу ровно по двум осям, которых там нет: персонализация на уровне конкретной особи и сцена как часть генерации, а не пост-обработка. Причём для персонализации уже есть работающий архитектурный паттерн из смежной области — свежая статья 2025 года ("Few-shot Personalized Scanpath Prediction") решает практически идентичную по структуре задачу (предсказание индивидуальной последовательности поведения человека при разглядывании изображений) через отдельную "subject-embedding" сеть, которая обобщается на нового человека по считанным наблюдениям без дообучения всей модели. Мы адаптируем тот же принцип на поведение животных. Что предстоит сделать:

- Аудит данных: проверить, действительно ли открытые датасеты поведения животных (тысячи собак с ошейниковыми акселерометрами) содержат достаточно повторных наблюдений на одну и ту же особь, чтобы выучить устойчивый индивидуальный "отпечаток" поведения — это первый и самый критичный вопрос всего трека.
- Воспроизведение базовой версии в духе Liang et al. — LSTM/attention-генератор последовательности поведения без персонализации, как отправная точка и baseline для сравнения.
- Добавление персонализации: обучаемый вектор идентичности на каждую известную при обучении особь, влияющий и на то, что животное предпочитает делать, и на то, как быстро/энергично оно реагирует.
- Интеграция сцены прямо в генерацию, а не отдельным шагом после, как в оригинальной работе.
- Самый интересный и рискованный шаг: научить систему выводить персональный вектор для нового питомца, которого не было в

обучающих данных, по малому числу наблюдений за ним — без переобучения всей модели.

128. AI Tax Strategist
Уровень: BASE/MIDDLE
Тип проекта: ML
Пререквизиты: базовые знания работы RAG-систем
Руководитель: Папулов Олег (@Olegiy)

Описание: Современные LLM демонстрируют впечатляющие способности в обработке естественного языка, но в налоговой сфере они сталкиваются с фундаментальной проблемой: галлюцинации— модель может генерировать правдоподобный, но юридически неверный ответ. Традиционные RAG-системы частично решают эту проблему, но не справляются со сложными кросс-юрисдикционными сценариями и оптимизационными задачами.
В мире open-source уже существуют проекты, закладывающие фундамент для глобального налогового консультирования
Проблема: ни один из этих проектов сам по себе не является «советником» или «стратегом». Они предоставляют данные и вычисления, но не умеют планировать и оптимизировать — отвечать на вопросы типа «В какой стране открыть компанию для SaaS-стартапа с учётом моей налоговой резиденции?» или «Как структурировать международные инвестиции, чтобы минимизировать совокупную налоговую нагрузку?».
Цель проекта — создать интеллектуальную надстройку над существующими открытыми налоговыми данными: multi-agent систему, которая умеет не только отвечать на фактографические вопросы, но и сравнивать юрисдикции, предлагать структуры оптимизации и объяснять свои рекомендации.

129. Моделирование нагрузки и авто-масштабирование сервисов высоконагруженной событийной платформы

Трек: ML Уровень сложности: MIDDLE/PRO

Руководители: Чепиков Иван

Введение

Система обрабатывает большие потоки событий через брокер сообщений и цепочки воркфлоу-задач. При росте трафика узкие места такие как брокер, консьюмеры, сервис-витрина и модули фильтрации начинают деградировать

Цель работы

Построить модель пропускной способности и правила масштабирования, при которых система выдерживает нагрузку и остаётся наблюдаемой.

Данные и сигналы

Метрики брокера: backlog в байтах и сообщениях, storage_size, число ledger, скорость eviction; RPS продюсеров и консьюмеров; метрики подов и число реплик в Kubernetes; логи Loki, метрики Prometheus/Grafana, статусы и retry задач воркфлоу.

Технологический стек

Python, Pulsar/Kafka, Kubernetes (HPA), Prometheus, Grafana, ClickHouse, SimPy, PyTorch/sklearn.

Задачи

- Построить аналитическую или симуляционную модель очереди «производитель–потребитель» с eviction и вывести условие устойчивости топика.
- Собрать нагрузочный стенд-генератор RPS для валидации порогов масштабирования.
- Реализовать автоскейлер консьюмеров по backlog и lag с гистерезисом.
- Сделать детектор аномалий backlog и дельт обработки, подобрать алерты.
- Собрать прототип LLM-агента-диагноста поверх логов и метрик.

-

Примерный план решения

- Сбор и анализ метрик, формализация модели нагрузки и критериев устойчивости.
- Построение симулятора и нагрузочного стенда.
- Реализация и валидация правил авто-масштабирования.
- Оценка качества на нагрузочных сценариях и анализ наблюдаемости системы.

Пререквизиты

Python, базовый ML. Будут полезны знания распределённых систем, очередей сообщений и теории массового обслуживания; недостающие темы можно осваивать по ходу работы.

130. Диалоговый голосовой ассистент подбора вакансий в режиме телефонного звонка

Трек: DL Уровень сложности: MIDDLE/PRO

Руководители: Чепиков Иван

Введение

Голосовой робот в ходе разговора определяет, ищет ли человек работу, выявляет интересующий сегмент линейного персонала — курьер, кассир, продавец или склад — и при согласии переводит звонок на оператора.

Цель работы

Разработать и исследовать голосового ассистента, который персонализирует сценарий подбора вакансий и повышает конверсию в перевод на оператора.

Технологический стек

ASR (Whisper и аналоги), TTS, LLM с function calling, диалоговый менеджер.

Возможные задачи

- Построить модель предсказания склонности к поиску работы по источнику и поведению.
- Сделать NLU-разметку транскриптов и автоматический поиск точек отвала диалога.
- Оптимизировать сценарий диалога методами bandit/RL по репликам.
- Исследовать синтез речи и влияние интонации на dropout.

Примерный план решения

- Подготовка транскриптов и разметка интентов, сегментов и исходов диалога.
- Построение базовых NLU- и propensity-моделей.
- Интеграция ASR, TTS и LLM с function calling в диалоговый менеджер.

- Экспериментальная оценка сценариев и качества перевода на оператора.

Возможные модификации задачи

- Добавить real-time подсказки оператору в момент перевода звонка.

Пререквизиты

Знание NLP и трансформеров, готовность дообучать трансформеры, базовое знакомство с ASR/TTS и опыт работы с LLM API (function calling).

131. Прогнозирование оттока клиентов (Churn Prediction)

Руководители: Мовсумов Денис, Абакумов Юрий

- **Тип задачи:** бинарная классификация
- **Данные:** Telco Customer Churn (Kaggle), IBM sample datasets, датасеты подписочных сервисов на Kaggle
- **Методы:** Logistic Regression (baseline), Random Forest, Gradient Boosting (XGBoost/LightGBM/CatBoost)
- **Метрики:** ROC-AUC, F1, Precision/Recall с учётом дисбаланса классов, бизнес-метрика (стоимость false negative/positive)
- **Усложнения:** SHAP/LIME для интерпретации; cost-sensitive learning; uplift-модели для оценки эффекта retention-кампании
- **Уровень:** BASE\MIDDLE

Проблема: компания теряет клиентов, но не понимает заранее, кто уйдёт, и тратит бюджет на удержание "вслепую".

Что сделать?: построить модель, которая по историческим данным о клиенте предсказывает вероятность его оттока в ближайший период.

Возможные задачи:

- EDA данных, анализ признаков и оттока по сегментам
- обработка пропусков, кодирование категориальных признаков
- построение baseline-модели (Logistic Regression)
- обучение и тюнинг Gradient Boosting, сравнение моделей
- интерпретация модели (SHAP), выделение ключевых факторов оттока
- подготовка отчёта с рекомендациями по удержанию

Критерии приемки: модель обучена и провалидирована на отложенной выборке; ROC-AUC не ниже согласованного порога и выше naive baseline; топ-N клиентов по вероятности оттока проверены на разумность (интерпретация фичей); подготовлен отчёт с бизнес-рекомендациями.

132. Сегментация клиентов (Customer Segmentation)

Руководители: Мовсумов Денис

- **Тип задачи:** обучение без учителя, кластеризация
- **Данные:** Online Retail Dataset (UCI), любой транзакционный e-commerce датасет
- **Методы:** RFM-анализ, K-Means, DBSCAN, Hierarchical Clustering, PCA/t-SNE для визуализации
- **Метрики:** Silhouette score; практическая интерпретируемость и полезность сегментов
- **Усложнения:** сравнение нескольких алгоритмов кластеризации; персонализированные рекомендации по сегментам
- **Уровень:** BASE
- **Проблема:** маркетинг работает со всеми клиентами одинаково, хотя они сильно различаются по поведению и ценности.

Что сделать?: кластеризовать клиентскую базу на устойчивые сегменты и описать профиль каждого сегмента.

Возможные задачи:

- EDA транзакционных данных, построение RFM-таблицы
- подбор числа кластеров (elbow/silhouette)
- кластеризация (K-Means, DBSCAN), сравнение результатов
- визуализация сегментов (PCA/t-SNE)
- описание профиля каждого сегмента
- формулирование маркетинговых рекомендаций

Критерии приемки: выбрано и обосновано число кластеров; сегменты содержательно интерпретируемы (минимум 3–4 отчётливых профиля); для каждого сегмента сформулирована маркетинговая рекомендация; результаты визуализированы (PCA/t-SNE).

133. Обнаружение аномалий / фрод-детекция

Руководители: Мовсумов Денис, Архипов Максим, Александр Голубев

- **Тип задачи:** anomaly detection, крайне несбалансированная классификация
- **Данные:** Credit Card Fraud Detection — ULB (Kaggle), IEEE-CIS Fraud Detection (Kaggle)
- **Методы:** Isolation Forest, One-Class SVM, Local Outlier Factor; сравнение с supervised (XGBoost + class weighting)
- **Метрики:** PR-AUC (важнее ROC-AUC при сильном дисбалансе), Recall при фиксированном Precision
- **Усложнения:** потоковое (online) обнаружение; объяснение решений модели для комплаенса
- **Уровень:** BASE/MIDDLE
- **Проблема:** часть транзакций — мошеннические, их пропуск ведёт к прямым финансовым потерям, а ложные срабатывания раздражают добросовестных клиентов.

Что сделать?: построить модель обнаружения аномальных/мошеннических транзакций в потоке данных.

Возможные задачи:

- EDA, анализ дисбаланса и типов аномалий
- построение unsupervised baseline (Isolation Forest)
- обучение supervised модели с балансировкой классов
- подбор порога под целевой Precision/Recall
- анализ ложных срабатываний
- описание процесса интеграции в мониторинг

Критерии приемки: модель достигает целевого Recall при заданном уровне Precision (или PR-AUC выше baseline); протестирована устойчивость к дисбалансу классов; описан процесс принятия решения (порог, объяснение флагов) для интеграции в процесс проверки.

134. Классификация текста классическими методами

Руководители: Мовсумов Денис, Панчук Георгий, Александр Голубев

- **Тип задачи:** NLP-классификация без DL
- **Данные:** SMS Spam Collection (UCI), IMDB Reviews, 20 Newsgroups
- **Методы:** TF-IDF + Logistic Regression/SVM/Naive Bayes, n-граммы, feature selection
- **Метрики:** F1, Accuracy, confusion matrix
- **Усложнения:** сравнение TF-IDF с Word2Vec-эмбеддингами (без перехода на DL-архитектуры); анализ типичных ошибок модели
- **Уровень:** BASE
- **Проблема:** большой поток текстовых обращений/отзывов невозможно обрабатывать вручную.

Что сделать?: построить классификатор текста (спам/тональность/тема) на классических методах без DL.

Возможные задачи:

- сбор и предобработка текстов (токенизация, очистка)
- построение TF-IDF признаков
- baseline модель (Naive Bayes/Logistic Regression)
- тюнинг и сравнение классификаторов (SVM, LogReg)
- анализ ошибок классификации
- тест на новых, ранее не виденных примерах

Критерии приемки: Accuracy/F1 выше согласованного порога и baseline (majority class); проведён анализ ошибок с примерами; модель работает в разумное время на новых данных.

135. Интерпретируемая диагностика по табличным медицинским данным

Руководители: Мовсумов Денис

- **Тип задачи:** классификация с фокусом на интерпретируемость
- **Данные:** Pima Indians Diabetes (UCI/Kaggle), Heart Disease UCI, Framingham dataset
- **Методы:** Logistic Regression, Decision Trees, Random Forest, Gradient Boosting + SHAP/LIME
- **Метрики:** AUC-ROC, Recall (false negative критичен в медицине), calibration
- **Усложнения:** fairness/bias-анализ по подгруппам; доверительные интервалы предсказаний
- **Уровень:** MIDDLE

Проблема: врачам нужен инструмент поддержки принятия решений, но "чёрный ящик" без объяснений в медицине неприменим.

Что сделать?: построить интерпретируемую модель прогноза риска заболевания по клиническим показателям.

Возможные задачи:

- EDA клинических данных, проверка качества/пропусков
- baseline Logistic Regression
- обучение Random Forest/Gradient Boosting
- подключение SHAP/LIME для объяснений
- анализ подгрупп на предмет bias
- подготовка отчёта с примерами объяснённых предсказаний

Критерии приемки: AUC-ROC/Recall выше согласованного порога; для каждого предсказания доступно объяснение (SHAP/LIME) вкладов признаков; проведён базовый анализ на bias по подгруппам (если позволяют данные).

136. Классификация изображений с Transfer Learning

Руководители: Мовсумов Денис

- **Тип задачи:** image classification
- **Данные:** PlantVillage, MVTec AD (дефекты производства), отраслевые датасеты с Kaggle
- **Методы:** transfer learning на ResNet/EfficientNet/ConvNeXt, fine-tuning, data augmentation
- **Метрики:** Accuracy, macro-F1, confusion matrix
- **Усложнения:** режим few-shot / малых данных; сравнение архитектур; explainability (Grad-CAM)
- **Уровень:** BASE/MIDDLE
- **Проблема:** ручная визуальная проверка (дефекты, болезни растений, товары) медленная и не масштабируется.

Что сделать?: построить модель классификации изображений с использованием transfer learning на предобученной сети.

Возможные задачи:

- сбор/разметка датасета изображений, train/val/test split
- аугментация данных
- fine-tuning предобученной сети (baseline)
- подбор архитектуры/гиперпараметров
- Grad-CAM визуализация и анализ ошибок
- оценка на отложенном тестовом наборе

Критерии приемки: Accuracy/macro-F1 выше baseline; работа модели продемонстрирована на отложенном тестовом наборе; получены и проинтерпретированы примеры Grad-CAM; зафиксированы классы/примеры с низким качеством предсказаний.

137. Object Detection / сегментация изображений

Руководители: Мовсумов Денис

- **Тип задачи:** детекция объектов / семантическая сегментация
- **Данные:** SKU-110k (ритейл), COCO subset, SpaceNet (спутник), ISIC (сегментация кожи)
- **Методы:** YOLOv8/YOLOv11, Faster R-CNN — для детекции; U-Net/DeepLabV3 — для сегментации
- **Метрики:** mAP (детекция), IoU/Dice (сегментация)
- **Усложнения:** работа при ограниченной разметке (semi-supervised, active learning); деплой с ускорением (ONNX/TensorRT)
- **Уровень:** MIDDLE/PRO

Проблема: нужно не просто определить, что на изображении, а точно локализовать объекты/области (для автоматизации проверки, аналитики, медицины).

Что сделать?: построить модель детекции объектов или сегментации изображений под конкретную задачу.

Возможные задачи:

- подготовка и разметка датасета (bbox/маски)
- baseline на предобученной модели (YOLO/U-Net)
- fine-tuning под целевой домен
- оценка mAP/IoU, анализ проблемных случаев
- визуализация предсказаний на тестовых изображениях
- (опционально) оптимизация модели для инференса

Критерии приемки: mAP (детекция) или IoU/Dice (сегментация) выше согласованного порога; модель протестирована на новых изображениях, не участвовавших в обучении; продемонстрирован инференс с визуализацией предсказаний (bbox/маски).

138. Fine-tuning трансформера для NLP-задачи

Руководители: Мовсумов Денис, Абакумов Юрий, Андреев Дмитрий

- **Тип задачи:** классификация текста / NER / sentiment
- **Данные:** доменные тексты — отзывы, новости, тикеты поддержки (например, датасеты отзывов на русском с Kaggle)
- **Методы:** fine-tuning BERT/RoBERTa/DeBERTa или их русскоязычных аналогов (ruBERT, RuRoBERTa); LoRA для эффективного дообучения
- **Метрики:** F1 (macro/weighted), Accuracy, качество на редких классах отдельно
- **Усложнения:** сравнение full fine-tuning vs LoRA/PEFT; дистилляция модели для продакшена
- **Уровень:** PRO

Проблема: общие языковые модели плохо справляются со специфической терминологией и структурой доменных текстов.

Что сделать?: дообучить предобученную языковую модель под конкретную прикладную NLP-задачу (классификация/NER/тональность).

Возможные задачи:

- подготовка и разметка доменного текстового датасета
- baseline (TF-IDF + классический классификатор)
- fine-tuning предобученной трансформер-модели
- сравнение full fine-tuning и LoRA/PEFT
- оценка на тестовой выборке, анализ ошибок по классам
- (опционально) дистилляция модели

Критерии приемки: F1/Accuracy дообученной модели заметно выше baseline (TF-IDF + классический классификатор или zero-shot); проведено сравнение full fine-tuning и LoRA/PEFT по качеству и затратам; модель воспроизводимо инференсит на новых примерах.

139. RAG-система / дообучение LLM под домен

Руководители: Мовсумов Денис, Абакумов Юрий, Цуриков Виталий, Панчук Георгий, Мустафин Фарид, Александр Голубев, Родионов Никита

- **Тип задачи:** question answering, генерация текста
- **Данные:** собственный корпус документов или открытые корпуса (например, статьи arXiv)
- **Методы:** эмбеддинги + vector store (FAISS/Qdrant/Chroma) + retrieval + генерация LLM; альтернатива — LoRA fine-tuning небольшой open-source модели
- **Метрики:** качество ответов (human eval, RAGAS-метрики: faithfulness, relevance), latency
- **Усложнения:** сравнение чистого RAG vs fine-tuning; борьба с hallucinations; тест на adversarial-вопросах
- **Уровень:** PRO

Проблема: пользователям нужны точные ответы по большому корпусу документов, а обычный поиск по ключевым словам не даёт связного ответа, а LLM без контекста — "галлюцинирует".

Что сделать?: построить систему вопрос-ответ по корпусу документов на основе RAG (или дообученной LLM).

Возможные задачи:

- сбор и подготовка корпуса документов
- построение эмбеддингов и векторного индекса
- реализация retrieval + генерации ответа
- формирование тестового набора вопросов с эталонами
- оценка качества ответов (human eval/RAGAS)
- анализ и минимизация случаев галлюцинаций

Критерии приемки: собран и проиндексирован корпус документов; на тестовом наборе вопросов ответы оценены по релевантности/достоверности (human eval или RAGAS-метрики) выше согласованного порога; задокументированы случаи неудачных ответов и предложены меры их снижения.

140. Генеративные модели изображений (GAN / VAE / Diffusion)

Руководители: Мовсумов Денис

- **Тип задачи:** генерация изображений
- **Данные:** небольшой доменный датасет изображений (удобно связать с проектом №8)
- **Методы:** DCGAN/StyleGAN (базово), VAE, упрощённая диффузионная модель (DDPM)
- **Метрики:** FID, визуальная оценка, польза синтетики для downstream-классификатора (augmentation test)
- **Усложнения:** conditional generation; сравнение GAN vs Diffusion по качеству и стабильности обучения
- **Уровень:** PRO

Проблема: для узкого домена не хватает данных для обучения других моделей (редкие классы, дефекты), а сбор реальных данных дорог.

Что сделать?: построить генеративную модель, синтезирующую реалистичные изображения выбранного домена.

Возможные задачи:

- подготовка доменного датасета изображений
- baseline генеративная модель (например, DCGAN)
- обучение более сложной модели (VAE/DDPM)
- оценка качества генерации (FID, визуальная проверка)
- тест полезности синтетики для downstream-классификатора
- сравнение подходов между собой

Критерии приемки: получены визуально правдоподобные сгенерированные изображения (оценка FID и/или экспертная визуальная проверка); показана полезность синтетики — обучение downstream-классификатора с аугментацией даёт прирост метрики по сравнению с обучением без неё.

141. Аудио: классификация звука / распознавание речи

Руководители: Мовсумов Денис

- **Тип задачи:** audio classification / ASR
- **Данные:** UrbanSound8K, ESC-50, Common Voice (для ASR)
- **Методы:** CNN на мел-спектрограммах; fine-tuning Whisper/Wav2Vec2
- **Метрики:** Accuracy/F1 (классификация), WER (для ASR)
- **Усложнения:** работа в условиях шума; real-time инференс
- **Уровень:** PRO

Проблема: аудиопоток (звуки оборудования, речь) требует автоматической обработки, ручной мониторинг невозможен в реальном времени.

Что сделать?: построить модель классификации звуковых событий или дообучить модель распознавания речи под конкретный домен/язык.

Возможные задачи:

- подготовка аудиоданных, построение спектрограмм
- baseline модель классификации
- обучение/fine-tuning основной модели (CNN или Whisper/Wav2Vec2)
- тест на данных с шумом
- оценка метрик (Accuracy/F1 или WER)
- замер времени инференса

Критерии приемки: Accuracy/F1 (классификация) или WER (ASR) достигает согласованного порога; модель протестирована на аудио с шумом/помехами; оценено время инференса на одном примере (применимость в real-time сценарии).

142. Мультимодальные модели (image + text)

Руководители: Мовсумов Денис, Панчук Георгий (retrieval)

- **Тип задачи:** image captioning / VQA / retrieval
- **Данные:** Flickr8k/30k, подмножество COCO Captions
- **Методы:** CLIP для image-text retrieval; encoder-decoder (CNN/ViT + LSTM/Transformer) для captioning
- **Метрики:** BLEU/CIDEr (captioning), Recall@K (retrieval)
- **Усложнения:** zero-shot classification через CLIP; сравнение с fine-tuned подходом
- **Уровень:** PRO

Проблема: изображение и текст часто нужно связывать вместе (поиск по описанию, автоматическое описание контента), а раздельные модели для этого не подходят.

Что сделать?: построить систему image-text retrieval или image captioning на мультимодальной модели.

Возможные задачи:

- подготовка датасета пар изображение-текст
- baseline через готовую CLIP-модель (zero-shot)
- дообучение/реализация captioning-модели
- оценка по BLEU/CIDEr или Recall@K
- анализ успешных/неуспешных примеров
- сравнение zero-shot и fine-tuned решений

Критерии приемки: Recall@K (retrieval) или BLEU/CIDEr (captioning) выше baseline; продемонстрированы примеры успешной и неуспешной работы модели; для retrieval — показана работа zero-shot через CLIP как минимум одного сравнительного baseline.

143. Фундаментальные модели физики: нейронные операторы и генеративный ИИ с физической согласованностью

Трек: RESEARCH

Уровень сложности: mid/pro

Руководители: Захаров Андрей

Пререквизиты: уверенный PyTorch, опыт обучения DL-моделей, дифференциальные уравнения и численные методы на уровне базового курса, готовность читать статьи

Классические численные решатели уравнений в частных производных точны, но дороги: расчёт одного режима может занимать часы. Нейронные операторы и суррогатные модели учатся по данным симуляций отображать параметры задачи сразу в решение, ускоряя расчёт на порядки. Ключевая проблема тут это физическая согласованность: модель должна не просто минимизировать ошибку, но и не нарушать законы сохранения.

Цель проекта **состоит** в том чтобы обучить и честно сравнить несколько архитектур на открытых мультифизических датасетах, а затем встроить в обучение физические ограничения и измерить, что это даёт в точности, устойчивости и переносе на новые режимы.

Возможные задачи:

- подготовка данных и baseline: интерполяция, персистентность, классический решатель как эталон
- обучение и сравнение SOTA-архитектур: FNO / Geo-FNO, DeepONet, U-Net-суррогаты, Neural ODE/PDE
- гибридные функции потерь: невязка уравнения, законы сохранения, граничные условия
- исследование автогрессивного развертывания на длинных горизонтах и способов стабилизации обучения
- перенос модели на новые параметры уравнения и новую геометрию (out-of-distribution)
- сервисная часть: инференс-API и дашборд с визуализацией полей и метрик ошибки

Ожидаемый результат: воспроизводимый бенчмарк нескольких архитектур на едином протоколе, количественная оценка вклада физических ограничений, сервис инференса; при хорошем результате будет статья на воркшоп уровня A/A*

Данные и полезные ссылки: The WELL, PDEBench; Multiple Physics Pretraining (Polymathic, 2024), Geo-FNO (2023), OmniArch (2024)

144. RL-управление функцией потерь для ускорения и стабилизации обучения PINN

Трек: RESEARCH
Уровень сложности: mid/pro
Руководители: Захаров Андрей
Пререквизиты: PyTorch, базовое понимание обучения с подкреплением, дифференциальные уравнения, аккуратность в постановке экспериментов

Физически-информированные нейронные сети (PINN) обучаются на взвешенной сумме нескольких слагаемых: невязка уравнения, начальные и граничные условия, данные измерений. Качество и сама сходимость обучения критически зависят от весов этих слагаемых, а подбирают их обычно вручную и на глаз.

Идея проекта: сделать подбор весов адаптивным, обучить RL-агента, который по промежуточным метрикам обучения (динамика градиентов, невязки, скорость убывания лоссов) на лету меняет коэффициенты. Тема продолжает нашу работу Kolzhetsov V., Zakharov A., Makarov I. «Accelerating PINN Training via RL-based Adaptive Loss Control» (ICLR 2026 Workshop on AI and Partial Differential Equations).

Возможные задачи:

- воспроизведение baseline-PINN на наборе канонических уравнений (Burgers, Allen-Cahn, Navier-Stokes в простой постановке)
- сравнение существующих схем балансировки весов (NTK-based, GradNorm, SA-PINN) как честных baseline
- формализация задачи для RL: пространство состояний из метрик обучения, действия - изменение весов, награда - скорость и качество сходимости
- обучение агента (PPO/SAC) и проверка переносимости политики на новые уравнения без переобучения
- ablation-исследование: какие сигналы из процесса обучения действительно важны
- оформление результатов в виде библиотеки-обёртки над обучением PINN

Ожидаемый результат: библиотека адаптивного управления лоссами, воспроизводимые эксперименты с ускорением сходимости относительно baseline, статьи на воркшоп уровня A/A*

145. Генеративный ИИ для моделирования живых тканей и коллективной динамики клеток

Трек: DL/RESEARCH
Уровень сложности: mid/pro
Руководители: Захаров Андрей
Пререквизиты: PyTorch, основы компьютерного зрения (сегментация, трекинг), базовое знание генеративных моделей (VAE/GAN/диффузия); биологический бэкграунд не требуется!
Морфогенез, заживление ран и опухолевая инвазия - это процессы, в которых клетки движутся согласованно, подчиняясь и биологическим, и физическим правилам. Данные микроскопии этих процессов есть, но перейти от «картинок» к предсказательной модели динамики является открытой задачей.
В проекте предлагается построить полный пайплайн: от сегментации и трекинга клеток на видео микроскопии до генеративной модели, которая предсказывает эволюцию клеточного пласта и учитывает физические ограничения (несжимаемость, корреляции скоростей соседей). Тема развивает нашу работу Stanislavchuk-Abovsky D., Zakharov A., Makarov I. «Physics-Constrained Correlation-Aware Attention for Collective Cell Dynamics» (ICLR 2026, LMRL Workshop, A*). Работа будет происходить в коллаборации с совместной лабораторией AIRI+НГУ+ИСИ СО РАН.

Возможные задачи:

- сборка и разметка данных: открытые датасеты микроскопии (Cell Tracking Challenge и аналоги)
- сегментация и трекинг клеток современными моделями (Cellpose, SAM-подобные), оценка качества трекинга
- извлечение физических характеристик: поля скоростей, корреляционные длины, плотность
- бенчмаркинг генеративных архитектур предсказания динамики: VAE, GAN, диффузионные и гибридные модели, attention с физическими ограничениями
- метрики физической правдоподобности предсказаний, а не только попиксельной ошибки
- сервис: загрузка видео микроскопии, автоматический анализ и визуализация предсказанной динамики

Ожидаемый результат: пайплайн анализа и предсказания клеточной динамики, сравнение генеративных архитектур на единых метриках, демо-сервис; потенциал публикации на профильном воркшопе, статьи A*/Q1

146. Биоинспирированное мультиагентное обучение с подкреплением для роевой робототехники

Трек: DL/RESEARCH

Уровень сложности: pro

Руководители: Захаров Андрей

Пререквизиты: PyTorch, обучение с подкреплением (хотя бы один самостоятельно реализованный алгоритм), готовность работать с симуляторами; полезны графовые нейронные сети

Рой из сотен простых агентов способен решать задачи, недоступные одному сложному роботу, например коллективная транспортировка груза, обход препятствий, самоорганизация в заданную конфигурацию. Централизованное управление здесь не масштабируется, поэтому нужны децентрализованные политики, где каждый агент принимает решение по локальным наблюдениям. Проект выполняется в рамках нашего сотрудничества с ИТМО и посвящён обучению и анализу таких политик для больших кластеров агентов (более 100).

Возможные задачи:

- выбор и настройка среды (SwarmRL, PettingZoo, VMAS) и постановка практических сценариев
- децентрализованный RL для координации: MAPPO, QMIX, независимое обучение как baseline
- GNN-политики: представление роя графом соседства, перенос обученной политики на другое число агентов
- практические задачи: координированная транспортировка грузов, оптимизация трафика в складских сценариях, децентрализованная навигация и уклонение от препятствий
- анализ спонтанной коллективной динамики: возникающие паттерны, фазовые переходы, метрики устойчивости роя
- сервис/демо: визуализация симуляции и сравнение обученных политик

Ожидаемый результат: обученные децентрализованные политики для 100+ агентов, анализ масштабируемости и эмерджентного поведения, воспроизводимый код и демо, публикации A*/Q1

Данные и полезные ссылки: arXiv:2305.13510 (наш эксперимент), обзор Swarm Autonomy, GNN for PhysicsSimulations, фреймворк SwarmRL

147. ИИ для науки об аккумуляторах: прогноз деградации и обнаружение аномалий

Трек: ML / RESEARCH
Уровень сложности: middle/pro
Руководители: Захаров Андрей
Пререквизиты: ML и временные ряды, основы DL, PyTorch; интерес к физике/электрохимии приветствуется, но предварительных знаний не требуется
Срок службы аккумулятора зависит от режимов заряда, температуры и химии ячейки, а деградация нелинейна и плохо описывается простыми формулами. Модели, обученные на циклических данных, позволяют предсказывать состояние здоровья (SOH) и оставшийся ресурс задолго до отказа, это критично для электротранспорта и систем накопления энергии.
Тема ведётся в сотрудничестве с HKUST и предполагает работу с реальными циклическими данными. Цель - более умные и долговечные аккумуляторы на основе моделей, управляемых данными.
Возможные задачи:

- подготовка данных циклирования: извлечение признаков из кривых заряда/разряда (IC/DV-анализ, внутреннее сопротивление)
- ML-этап: предсказание SOH и числа оставшихся циклов; ранний прогноз по первым десяткам циклов
- DL-этап: последовательные модели (LSTM/TCN/трансформеры) на сырых кривых вместо ручных признаков
- суррогатные модели, сочетающие физику (эквивалентные схемы, полуэмпирические модели деградации) и данные
- пайплайны обнаружения аномалий: выявление ячеек с аномальной динамикой деградации до отказа
- кросс-доменное обучение: перенос модели на новую химию ячеек и новые протоколы циклирования при малом объёме данных
- сервис: API оценки состояния батареи по загруженным циклам и дашборд мониторинга парка ячеек

Ожидаемый результат: модели раннего прогноза деградации с оценкой неопределённости, исследование переноса между химиями, демо-сервис; при сильных результатах будет публикация на A* конференции или Q1 статья
Данные и полезные ссылки: открытые датасеты Severson et al. (Toyota Research Institute), NASA Battery Data Set, MIT-Stanford battery data

148. ИИ-моделирование мембранного электролиза воды (производство водорода)

Трек: ML / RESEARCH
Уровень сложности: middle/pro
Руководители: Захаров Андрей
Пререквизиты: классический ML, временные ряды, основы DL, PyTorch/sklearn; электрохимия не требуется, необходимый минимум разбираем на старте.
Мембранный электролиз воды (PEM/AEM) - это базовая технология «зелёного» водорода. Поведение ячейки описывается набором связанных параметров (напряжение, плотность тока, сопротивление мембраны, температура, выход по току), которые дрейфуют по мере деградации и по-разному ведут себя в разных режимах работы. Экспериментальная карта режимов при этом всегда неполна: ресурсные испытания долгие и дорогие.
Цель проекта - комплекс ИИ-моделей, который по ограниченным экспериментальным данным восстанавливает поведение ячейки, предсказывает динамику её параметров и осмысленно экстраполирует за пределы исследованной области.
Возможные задачи:

- Прогнозирование временных зависимостей электрохимических параметров по начальным условиям
- Экстраполяция характеристик ячейки за пределы исследованных рабочих диапазонов
- Обнаружение скрытых зависимостей и паттернов в данных
- Предсказание кинетики и стадии процессов
- Анализ режимов работы: пакетный / непрерывный / интегрированный

ML-задачи: признаковое описание режима и бустинг для ключевых характеристик; кластеризация экспериментов и снижение размерности; интерпретация зависимостей (SHAP, символьная регрессия); классификация стадии процесса.
DL-задачи: LSTM/TCN/трансформеры и Neural ODE для динамики; операторные модели (DeepONet/FNO) для отображения «условия → траектория»; физически-информированные лоссы (уравнение Тафеля, монотонность поляризационной кривой) для устойчивой экстраполяции.
Сервис: REST API «параметры режима → прогноз с доверительными интервалами», дашборд с поляризационными кривыми, динамикой параметров и алертами о выходе за границы применимости модели.
Ожидаемый результат: комплекс моделей на едином протоколе оценки с честной проверкой экстраполяции (обучение внутри диапазона, тест строго вне него) и оценкой неопределённости; сервис прогнозирования. Международные публикации в топ журналах.
Данные: экспериментальные данные предоставляются в рамках проекта, коллаборация с Технион (Израиль).

149.**Распознавание аномальных данных и неизвестных объектов с помощью нейронных сетей**

Трек: RESEARCH
Уровень сложности: middle/PRO
Руководитель: Сулейманов Нихат

Введение

Нейронная сеть обычно обучается распознавать определённый набор объектов или классов. Однако в реальных условиях она может получить данные, которые сильно отличаются от обучающих или относятся к неизвестному классу.

Например, модель обучена распознавать **кошек и собак**, но получает изображение автомобиля. Вместо того чтобы понять, что это неизвестный объект, модель может уверенно классифицировать его как кошку или собаку.

Цель работы

Разработка и исследование методов, позволяющих нейронной сети определять, является ли входное изображение **обычным для обучающей выборки или неизвестным/аномальным**.

Задачи

- Изучение методов OOD detection и anomaly detection.
- Обучение моделей на известных классах.
- Создание сценариев с неизвестными данными.
- Исследование методов определения аномальных объектов.
- Сравнение различных подходов.
- Анализ случаев, когда модель ошибочно уверена в своём предсказании.

Пример

Модель обучена на:

Кошках + Собаках

На вход поступает:

🚗 → **Unknown ✓**

Вместо того чтобы заставлять модель выбрать один из известных классов, система должна сказать:

«Я не знаю, что это»

Возможные направления

- OOD detection.
- Anomaly detection.
- Uncertainty estimation.
- Анализ embeddings.
- Сравнение методов на разных архитектурах.

Пререквизиты

Python, основы машинного обучения, глубокого обучения и компьютерного зрения.

150.Обнаружение кибератак на промышленные системы с помощью машинного обучения

Трек: DL/ML/ Research
Уровень сложности: middle/PRO
Руководитель: Сулейманов Нихат, Ширнин Александр

Введение

Современные промышленные системы управления используют большое количество датчиков, контроллеров и автоматических систем. Если злоумышленник получает доступ к такой системе, он может изменять показания датчиков или отправляемые команды, что способно привести к неправильной работе оборудования.

В рамках проекта предлагается исследовать методы машинного обучения для обнаружения таких атак по данным реальной промышленной системы. В качестве основного датасета может использоваться **SWaT (Secure Water Treatment)** — данные с экспериментальной установки очистки воды, содержащие как нормальную работу системы, так и различные сценарии кибератак.

Цель работы

Разработка метода автоматического обнаружения кибератак и аномального поведения промышленной системы по показаниям датчиков и параметрам её работы.

Задачи

- Анализ данных промышленной системы и различных сценариев атак.
- Исследование методов обнаружения аномалий.
- Обучение моделей машинного обучения для обнаружения атак.
- Сравнение классических ML и глубоких моделей.
- Исследование возможности обнаружения атак, которых модель не видела при обучении.
- Анализ наиболее информативных датчиков и параметров системы.

Пример

В нормальном состоянии:

датчики → нормальные значения → система работает штатно ✓

Во время атаки:

злоумышленник → изменяет данные датчиков → система начинает вести себя необычно → 🚨

Модель должна обнаружить изменение и определить:

> **«Это не обычное поведение системы — вероятна кибератака».**

Более сложный вариант — обучить модель только на известных атаках и проверить, сможет ли она обнаружить **новую атаку, которой не было в обучающей выборке**.

Возможные методы

- Random Forest / XGBoost;
- Isolation Forest;
- Autoencoder;
- LSTM;
- Transformer;
- методы anomaly detection и OOD detection.

Датасет

SWaT (Secure Water Treatment) — набор данных, полученный с экспериментальной промышленной установки очистки воды. Он содержит временные ряды показаний датчиков и состояния оборудования при нормальной работе и во время различных кибератак.

Пререквизиты

Python, основы машинного обучения, глубокого обучения и анализа временных рядов.

151. Проекты группы “ИИ в промышленности”

Трек: Research
Уровень сложности: middle
Руководитель: Макаров Илья Андреевич

Пререквизиты. Основы машинного и глубокого обучения; уверенный Python и ML/DL-стек (PyTorch, scikit-learn, NumPy, pandas); углублённое знание хотя бы одного типа данных — изображения, тексты, графы, временные ряды или генеративные модели; английский на уровне чтения и написания статей; готовность к командной работе с git, Overleaf, Telegram. Для прикладных и open-source направлений дополнительно — опыт Python-разработки: ООП, тестирование, сборка библиотек, участие в крупных production- или open-source-проектах.

Описание. Вам предлагается присоединиться к одному из исследовательских или прикладных проектов лаборатории, объединяющей исследователей и разработчиков в современных областях ИИ. Лаборатория фокусируется на сложных динамических системах и мультиагентных LLM (включая эмпатичных агентов), мультимедиа, новых фундаментальны моделях в физике, математике, астрономии, климате и спутниковых снимках, а также генеративных модели в 3D, нейронауке, поведенческой экономике и археологии. Портфель включает 19 направлений, а также свободные темы и стартап-проекты.

Результат работы — публикации на конференции уровня A*/A, open-source-инструмент или прототип продукта; часть проектов ведётся с индустриальными партнёрами и может перерасти в спин-офф или тему кандидатской диссертации.

Возможные задачи.
Обзор литературы и воспроизведение SOTA-решений, сбор и разметка датасетов, построение baseline-моделей.
Обучение и дообучение моделей: VLM для спутниковых снимков и веб-интерфейсов, LLM для узких доменов, нейросетевые операторы и PINN для физических полей, RL-политики для мультиагентных сред.
Проектирование агентных пайплайнов: планирование, память, вызов инструментов, оценка и агрегация неопределённости в многошаговых рассуждениях.
Разработка бенчмарков и методик оценки — от корпоративных LLM до автоматизированного рецензирования научных текстов.
Анализ многомерных временных рядов: диагностика состояния оборудования, детекция аномалий и ранних признаков отказа, оценка остаточного ресурса.
Извлечение интерпретируемых признаков и анализ поведения моделей (attention, механистическая интерпретируемость, объяснимость решений).

Инженерные задачи: продуктивизация исследовательского кода, веб-инструменты, воспроизводимые эксперименты, тестирование и сборка библиотек.
Подготовка статьи и подача на конференцию, участие в ревью и итерациях по фидбеку.

Все подробности, требования конкретных направлений, контакты менторов и полный список подпроектов доступны по ссылке на презентацию.
https://clck.ru/3P9ySm

152. Мультимодальная 3D-детекция: fusion LiDAR и камер в BEV / query-пространстве

Трек: DL/RESEARCH

Уровень сложности: pro

Руководители: Жаботинский К.А.

Пререквизиты: PyTorch, понимание voxel/BEV 3D-детекции(ЖЕЛАТЕЛЬНО, если что разберемся) , калибровка камера–LiDAR; полезны MMDetection3D, CUDA, ONNX

Чистый LiDAR-детектор хорошо локализует геометрию, но хуже классифицирует редкие и мелкие объекты и теряет дальние цели, когда облако становится разреженным. Камера даёт текстуру и семантику, но слаба в метрической глубине. Современный fusion (BEVFusion, TransFusion и последующая линия height-preserving / sparse–dense fusion) совмещает обе модальности в общем BEV или query-пространстве.

Проект — воспроизводимое сравнение LiDAR-only vs camera–LiDAR на открытом nuScenes: где fusion даёт прирост (пешеходы, велосипеды, дальние объекты, ночь) и сколько это стоит в latency. SOTA 2025–2026 (MambaFusion и аналоги) — reading list, не обязательное воспроизведение.

Возможные задачи:

● поднять LiDAR-only baseline (CenterPoint / PointPillars) на nuScenes; отладка на nuScenes-mini

● поднять camera–LiDAR fusion baseline (BEVFusion или TransFusion-подобный пайплайн в MMDetection3D)

● ablation: LiDAR-only vs fusion; влияние калибровки и temporal sync; разрез mAP/NDS по классам и дистанциям (0–30 / 30–50 / 50+ м)

● опционально лёгкий фронтальный стенд на KITTI 3D (не 360°, но быстрый цикл экспериментов)

● профилирование FPS (PyTorch → ONNX/TensorRT по возможности) и отчёт «когда fusion стоит latency»

● сервис/демо: BEV-overlay GT vs prediction, таблица trade-off accuracy/latency в MLflow

Ожидаемый результат: обученные LiDAR-only и fusion-модели на nuScenes val, сравнительная таблица mAP/NDS и FPS, воспроизводимый код и короткий demo, tech report; плюсом — черновик статьи

Данные и полезные ссылки: nuScenes Detection (регистрация, non-commercial), nuScenes-mini; опционально KITTI 3D Object Detection (CC BY-NC-SA); BEVFusion, TransFusion, MMDetection3D `projects/BEVFusion`; обзоры multi-modal 3D OD 2024–2026

153. Семантическая 3D occupancy prediction: от bounding boxes к плотной сцене

Трек: DL/RESEARCH

Уровень сложности: pro

Руководители: Жаботинский К.А.

Пререквизиты: PyTorch, 3D CNN или transformer, понимание voxel-сеток; полезны semantic segmentation, MMDetection3D / TPVFormer

3D boxes не описывают произвольную геометрию: стройка, кусты, открытая дверь, ветка на пути. Occupancy предсказывает плотную voxel-сетку «занято / свободно / класс» вокруг ego и даёт general obstacle awareness без жёсткого списка детектируемых классов. Это один из главных трендов perception 2023–2026 (OpenOccupancy, SurroundOcc, Occ3D; дальше — обобщённые фреймворки вроде OccAny).

Команда поднимает открытый baseline на **Occ3D-nuScenes** (или SurroundOcc / OpenOccupancy — те же сцены nuScenes, другой GT), сравнивает camera-only vs LiDAR vs multi-modal, считает IoU по классам и стоимость инференса. Для отладки пайплайна допустим SemanticKITTI (semantic scene completion, не surround-view).

Возможные задачи:

● собрать пайплайн: nuScenes + occupancy GT (Occ3D-nuScenes как основной протокол; альтернатива — лейблы SurroundOcc / OpenOccupancy)

● baseline occupancy model (SurroundOcc / TPVFormer / OpenOccupancy CONet — один стек) + train/eval

● сравнение модальностей и разрешения voxel-сетки; метрики mIoU / IoU per class, latency, память

● анализ failure modes: динамика, дальние зоны, тонкие структуры

● bonus: occupancy → простая cost-map «можно ли проехать» (мостик к planning)

● сервис/демо: 3D/BEV визуализация occupied voxels vs boxes

Ожидаемый результат: обученная occupancy-модель на открытом бенчмарке, визуализации, отчёт «boxes vs occupancy», воспроизводимый код; плюсом — статья

Данные и полезные ссылки: Occ3D-nuScenes (github.com/Tsinghua-MARS-Lab/Occ3D, GT MIT + ToU nuScenes); OpenOccupancy; SurroundOcc; nuScenes + lidarseg; для отладки SemanticKITTI SSC ([semantic-kitti.org](http://www.semantic-kitti.org/)); TPVFormer; CVPR 2023 Occupancy Prediction Challenge

154. Monocular metric depth estimation для autonomous driving

Трек: DL

Уровень сложности: middle

Руководители: Жаботинский К.А.

Пререквизиты: PyTorch, основы computer vision (CNN/transformer), проективная геометрия камеры; полезны ONNX, KITTI eval protocol

Одна камера → metric depth map. Относительная глубина (relative) недостаточна для driving: нужны метры. Команда берёт современный open baseline (Depth Anything v2, Metric3D, UniDepth или ZoeDepth), дообучает на driving-данных с LiDAR-as-supervision (sparse depth, спроецированный в image plane) и разбирает, где монокулярная глубина полезна, а где систематически врёт (дальние планы, ночь, дождь, блики).

Основной стенд — KITTI Depth (компактный, стандартные метрики) с переносом протокола на nuScenes (камеры + LiDAR, без отдельного official depth benchmark — метрики считаем сами по проекции LiDAR).

Возможные задачи:

● пайплайн pseudo-GT: LiDAR → image plane с учётом intrinsics/extrinsics и occlusion

● fine-tune + ablation (loss, resolution, multi-scale) на KITTI Eigen / official split

● метрики: AbsRel, RMSE, δ<1.25; ошибка по bins 0–20 / 20–50 / 50+ м; ночь vs день на nuScenes

● real-time inference (ONNX) и анализ FPS vs quality

● bonus: depth как auxiliary signal для obstacle awareness (порог по метрам → BEV-заготовка)

● сервис/демо: visualizer depth vs projected LiDAR, лог экспериментов в MLflow

Ожидаемый результат: дообученная metric-depth модель, eval pipeline на KITTI и nuScenes, отчёт по дистанциям и типам сцен, воспроизводимый код

Данные и полезные ссылки: KITTI Depth Evaluation (CC BY-NC-SA); nuScenes cameras + LiDAR; Depth Anything v2, Metric3D, UniDepth, ZoeDepth

155. 3D object detection из monocular camera через depth lifting (pseudo-LiDAR)

Трек: DL/RESEARCH

Уровень сложности: middle

Руководители: Жаботинский К.А.

Пререквизиты: PyTorch, 2D detection, основы 3D detection; полезен опыт с depth estimation

Классическая исследовательская линия: monocular camera → depth map → pseudo point cloud / lifted boxes → 3D bounding boxes. Вопрос проекта — не «победить

LiDAR», а честно измерить, на каких дистанциях и классах camera-only подход конкурентоспособен и где его ломает ошибка глубины.

Команда воспроизводит pipeline «2D detector + depth + lifting» на KITTI (стандартный протокол 3D AP easy/moderate/hard) и переносит сравнение на nuScenes (camera vs LiDAR GT на тех же keyframes).

Возможные задачи:

● 2D detector (YOLO / FCOS) + depth estimator (pretrained или из темы 3)

● lifting 2D boxes в 3D через predicted depth и калибровку камеры

● сравнение с LiDAR-детектором на тех же сценах KITTI / nuScenes

● ablation: качество depth vs качество 3D det; ошибки на дальних объектах

● опционально: fusion pseudo-LiDAR + очень редкий real LiDAR (имитация дешёвого датчика)

● сервис/демо: overlay 2D/3D boxes, таблица AP по дистанциям

Ожидаемый результат: воспроизводимый camera-only 3D pipeline, сравнительная таблица vs LiDAR, отчёт по failure modes

Данные и полезные ссылки: KITTI 3D Object Detection (CC BY-NC-SA); nuScenes Detection; работы линии Pseudo-LiDAR / CaDDN / monocular 3D OD в mmdet3d

156. Zero-shot / open-vocabulary 3D object detection в urban-сценах

Трек: DL/RESEARCH

Уровень сложности: pro

Руководители: Жаботинский К.А.

Пререквизиты: PyTorch, CLIP или аналогичные vision-language модели, основы 3D detection; полезны HuggingFace transformers

Классические 3D-детекторы работают с фиксированным набором классов. Open-vocabulary detection привязывает LiDAR- или image-features к text embeddings (CLIP и наследники) и ищет объекты по текстовому запросу («construction cone», «wheelchair», «delivery robot») без переобучения на каждый новый класс. Для города и рельсового транспорта это способ закрывать длинный хвост редких препятствий.

Протокол: seen-классы nuScenes vs held-out / текстовые запросы. Waymo не используем. При наличии диска — качественный перенос на Argoverse 2 Sensor (CC BY-NC-SA, ring cameras + LiDAR), иначе остаёмся на nuScenes.

Возможные задачи:

● обзор и baseline: image-guided 3D det, CLIP on BEV, lift-2D-to-3D с open-vocab 2D детектором

● адаптация под nuScenes: какие классы «из коробки», где gap

● eval protocol: closed-set mAP vs open-vocabulary (seen/unseen), аккуратная разметка запросов

● demo: интерактивный inference «введи класс → получи 3D boxes»

● анализ ограничений: rare classes, ночь, occlusion, зависимость от камеры

● сервис/демо: простой UI + логирование запросов

Ожидаемый результат: working prototype на nuScenes, eval на seen/unseen, demo, tech report; плюсом — статья

Данные и полезные ссылки: nuScenes (богатая таксономия 23 класса); опционально Argoverse 2 Sensor (CC BY-NC-SA 4.0) как второй домен; CLIP / Grounding DINO / open-vocab 3D OD papers (OV-3DET и аналоги)

157. Как ошибки 3D-perception влияют на планирование траектории (perception → planning bridge)

Трек: DL/RESEARCH

Уровень сложности: pro

Руководители: Жаботинский К.А.

Пререквизиты: PyTorch, готовность разбирать чужой E2E-репозиторий, основы 3D detection или BEV; полезны MOT, понимание open-loop vs closed-loop; команда 3–4 человека с сильным MLOps

End-to-end AD (UniAD, VAD, SparseDrive) объединяет perception, prediction и planning. Куратор сильнее в perception; акцент проекта — не «изобрести planner», а измеримая связка: качество детекции/треков → L2 и collision rate планировщика. Команда поднимает **один** открытый E2E baseline на nuScenes (так считаются опубликованные planning-метрики), воспроизводит open-loop L2 / collision rate и проводит controlled degradations perception (шум boxes, drop recall, задержка треков).

Полный nuPlan (десятки TB) не требуется. NAVSIM / OpenScene — опциональный второй стенд, если потянете по диску и захотите planning-oriented метрики новее nuScenes; это не обязательный scope.

Возможные задачи:

● поднять UniAD **или** VAD **или** SparseDrive (один стек) на nuScenes; сначала eval с публичным чекпойнтом, затем свои ablation

● воспроизвести published open-loop planning metrics (L2 на 1/2/3 с, collision rate)

● эксперименты: degraded detections / delayed tracks → planning; какие ошибки perception «дороже»

● сравнение modular pipeline (det → simple constant-velocity planner) vs E2E

● bonus: occupancy cost-map → rule-based scoring траекторий (связка с темой 2)

● сервис/демо: визуализация planned trajectory vs GT ego, таблица sensitivity в MLflow

Ожидаемый результат: воспроизведённый E2E baseline на nuScenes val, sensitivity study perception→planning, tech report; плюсом — черновик статьи. Риск по compute высокий — заранее согласовать GPU-бюджет

Данные и полезные ссылки: nuScenes (cam + LiDAR + can bus / ego poses, academic ToU) — основной стенд UniAD / VAD / SparseDrive; опционально

NAVSIM
(github.com/autonomousvision/navsim,
OpenScene = nuPlan 2 Hz); UniAD v2, VAD, SparseDrive

158. Интерпретируемое управление поведением LLM с помощью Sparse Autoencoders (SAE Steering)

Руководители: Родионов Никита

Трек: RESEARCH / DL
Уровень сложности: MIDDLE/PRO

Пререквизиты: Python, PyTorch, основы Deep Learning и NLP, понимание архитектуры Transformer. Желательно знакомство с Hugging Face и базовыми методами интерпретируемости нейронных сетей.

Описание

Современные LLM хранят информацию о различных свойствах текста и моделируемых концептах во внутренних представлениях. Один из подходов механистической интерпретируемости - Sparse Autoencoders (SAE), они позволяют разложить плотные активации модели на набор разреженных и потенциально интерпретируемых признаков.

В рамках проекта предлагается исследовать, насколько такие признаки можно использовать не только для анализа, но и для каузального управления поведением языковой модели во время инференса без изменения её весов.

В качестве целевых свойств можно рассматривать:

- механизмы отказа от ответа (refusal behavior) и другие признаки связанные с безопасностью/цензурой;
- наличие или усиление определённых семантических концептов;
- тональность и эмоциональную окраску ответа;
- стиль и особенности генерации;
- другие языковые или поведенческие свойства модели;

Для экспериментов предполагается использовать небольшие LLM с открытыми весами и существующие публичные SAE.

Возможные задачи:

1. Реализовать извлечение внутренних активаций и вмешательство в residual stream модели;
2. Сформировать контрастные наборы промптов для выбранных концептов и типов поведения;

3. Найти SAE-признаки, статистически связанные с целевым свойством;
4. Исследовать различные способы feature selection: разницу средних активаций; классификационные методы, автоматическую интерпретацию признаков с помощью LLM;
5. Исследовать зависимость найденных признаков от слоя модели;
6. Усиливать и подавлять выбранные SAE-признаки во время генерации. Провести sweep по слоям, признакам и силе интервенции. Исследовать зависимость между величиной вмешательства и изменением поведения модели;

159. LLM Wiki: desktop-сервис для автоматического построения персональной базы знаний с помощью LLM, Knowledge Graph и Deep Research

Руководители: Родионов Никита, Мустафин Фарид

Трек: DL / программный проект
Уровень сложности: MIDDLE/PRO

Пререквизиты: Python, основы NLP и LLM.

В рамках проекта предлагается разработать локальное desktop-приложение, которое принимает документы, статьи и веб-страницы, автоматически выделяет из них сущности и концепты, формирует взаимосвязанные wiki-страницы и строит граф знаний.

Пользователь получает возможность:
- изучать автоматически сформированную wiki;
- искать информацию по исходным материалам;
- задавать вопросы LLM с указанием источников;
- исследовать связи между концептами через граф;
- находить пробелы и противоречия в накопленных знаниях;
- запускать Deep Research для автоматического поиска недостающей информации.

В качестве отправной точки можно использовать идею LLM Wiki, предложенную Андреем Карпаты.

Помимо разработки сервиса интересно сравнить несколько архитектур (Classic RAG,Persistent Wiki, Graph-enhanced Wiki/RAG)

Возможные сценарии реализации:

MIDDLE

desktop-приложение;

импорт нескольких форматов документов;
автоматическая генерация Wiki;
vector + keyword search;
чат с цитированием источников;
инкрементальное обновление базы.

PRO

Дополнительно:

Knowledge Graph и graph-aware retrieval;
автоматическое определение knowledge gaps;
Deep Research Agent;
мультимодальные документы;
локальный режим работы с open-weight LLM;
сложная система фоновой обработки и восстановления после ошибок;
экспериментальное сравнение RAG / Wiki / Graph-RAG;
MCP/API для подключения базы знаний к другим AI-агентам.

160. Цифровые двойники пользователей (синтетические двойники LLM)
Трек: RESEARCH/DL
Уровень сложности: middle
Руководитель: Архипов Максим

Мотивация. Компании хотят «спросить» у аудитории реакцию на фичу до релиза или предсказать как зайдет новый продукт аудитории.
Идея — построить синтетического двойника пользователя из его истории поведения и иметь возможность задавать ему вопросы про фичи/товары. Проект учит работе с LLM, RAG, промпт-инжинирингу и, главное, честной оценке качества.
Данные (публичные, с историей во времени). Нужно будет найти данные, где есть пользователь × события × timestamp. Можно взять данные для построения рекомендательных систем и потом сравнить что лучше: алгоритмы рекомендаций или LLM с историей пользователя.
Дорожная карта проекта:
Выбрать датасет, EDA, собрать историю событий по пользователю. Научиться работать с LLM. LLM-суммаризация действий пользователя. RAG над историей пользователя.. Оценка качества + демо (чат с синтетическим пользователем) + отчёт.
Результат. Демка для разговора с “СИНТЕТИКОМ”, собранным из реальной истории» + отчёт.
Работа включает в себя рисерческую составляющую: придется читать статьи и искать лучшие практики.

161. Beauty Hit: похож ли продукт на хиты Sephora?

Уровень сложности: base

Руководители: Ильинский Андрей, Абакумов Юрий

Пререквизиты: базовые знания Python, pandas и основных методов классификации.

Введение

Почему одни косметические продукты оказываются среди самых популярных в каталоге, а другие получают меньше добавлений в избранное? В проекте предлагается исследовать зафиксированный снимок товаров Sephora и определить, похож ли продукт по своим характеристикам на товары из популярной группы.

Цель проекта

Разработать модель бинарной классификации и веб-сервис, который по характеристикам товара оценивает вероятность его принадлежности к популярной группе в рамках зафиксированного снимка каталога.

Данные

Используется датасет Sephora Products and Skincare Reviews. В нём есть карточки более чем 8 тысяч товаров и отдельные таблицы отзывов. Для обязательной части проекта используется только файл product_info.csv.

Ссылка на датасет:

https://www.kaggle.com/datasets/nadyinky/sephora-products-and-skincare-reviews

EDA и 2-й чекпоинт

- Исследовать распределение цен и популярности.
- Сравнить категории и бренды по доле популярных продуктов.
- Проверить, отличаются ли Sephora-exclusive и limited-edition товары.
- Оценить баланс классов и количество пропусков.
- Сформулировать 5–10 содержательных выводов, которые будут использоваться при построении моделей.

ML-задачи: 3-й и 4-й чекпоинты

- DummyClassifier как обязательный baseline.
- One-Hot Encoding + Logistic Regression как линейная модель.
- CatBoostClassifier как нелинейная модель.
- Сравнить модель с признаком бренда и без него: понять, запоминает ли алгоритм бренды или действительно использует характеристики продукта.
- Использовать одно зафиксированное стратифицированное train/validation/test-разбиение для всех моделей.

Сервисная часть: 5-й чекпоинт

- Реализовать Streamlit- или FastAPI-сервис.
- Пользователь выбирает категорию, бренд, цену и свойства товара, доступные в обучающем наборе.

- Сервис возвращает вероятность принадлежности к популярной группе, но не обещает будущие продажи.
- Использовать сохранённый preprocessing + model pipeline, а не дублировать обработку признаков вручную.
- Добавить базовую валидацию пользовательского ввода и несколько pytest-тестов.

DL-задачи: 6-й чекпоинт

- Обучить небольшой MLP на подготовленных табличных признаках.
- Сравнить MLP с Logistic Regression и CatBoost; нейросеть не обязана быть лучшей.
- Опционально: добавить текстовые признаки из описания или ингредиентов через готовые embeddings.

Возможные улучшения: 7-й чекпоинт

- Подбор гиперпараметров CatBoost и MLP.
- Калибровка вероятностей.
- SHAP или permutation importance для интерпретации.
- Анализ ошибок отдельно по категориям и ценовым сегментам.
- Проверка устойчивости результата при другом пороге определения популярности.

Метрики качества

- ROC-AUC.
- F1-score.
- Precision и Recall для популярного класса.
- Дополнительно — PR-AUC при заметном дисбалансе классов.

Важное ограничение

Это не прогноз будущих продаж: данные не содержат надёжной временной истории экспозиции каждого товара. Модель классифицирует продукт относительно популярной группы в одном снимке каталога. На защите нельзя интерпретировать результат как гарантию коммерческого успеха.

Ожидаемый результат

- Воспроизводимый pipeline подготовки данных и обучения моделей.
- Сравнение линейной, нелинейной и нейросетевой моделей.
- Работающий сервис с вероятностным прогнозом.
- Интерпретация факторов, связанных с попаданием товара в популярную группу.

162. FitCheck: будет мало, в размер или велико?

Уровень сложности: base/middle

Руководители: Ильинский Андрей, Абакумов Юрий

Пререквизиты: базовые знания Python и классификации; готовность работать с категориальными признаками и пропусками.

Введение

В датасете нет точных лекал и измерений самих вещей, поэтому корректная учебная постановка относится к уже известным предметам одежды из фиксированного каталога. Модель использует параметры человека, выбранный размер, категорию и идентификатор знакомой вещи и прогнозирует: мала, подходит или велика.

Цель проекта
Разработать многоклассовую модель для известных вещей из каталога и сервис, который выдаёт вероятности трёх вариантов посадки.

Данные
Используется RentTheRunway Clothing Fit Dataset: 192 544 взаимодействия, 105 508 пользователей и 5 850 вещей. В данных есть fit = small / fit / large, параметры пользователя, выбранный размер, категория и item_id.
Страница набора:
https://cseweb.ucsd.edu/~jmcauley/datasets.html#clothing_fit
Прямая загрузка:
https://mcauleylab.ucsd.edu/public_datasets/data/renttherunway/renttherunway_final_data.json.gz

EDA и 2-й чекпоинт
- Исследовать баланс классов small / fit / large.
- Сравнить долю неудачной посадки по категориям вещей.
- Построить распределения роста, веса и выбранного размера.
- Проверить, для каких категорий чаще встречается small или large.
- Проанализировать пропуски и выбросы в антропометрических признаках.

ML-задачи: 3-й и 4-й чекпоинты
- DummyClassifier как baseline.
- Multinomial Logistic Regression как линейная модель.
- CatBoostClassifier как основная нелинейная модель.
- Основная оценка — на новых пользователях при знакомых вещах; отдельный cold-start по новым item_id является только расширением и строится без item_id.
- Построить confusion matrix и отдельно изучить ошибки small ↔ fit и large ↔ fit.

Сервисная часть: 5-й чекпоинт
- Пользователь выбирает анонимизированную вещь из фиксированного каталога (item_id + категория), внутренний код size из допустимого списка, затем вводит рост, вес, bust size и body type.
- На выходе — вероятности small, fit и large для выбранной вещи.
- Показать наиболее вероятный исход и понятное текстовое пояснение.
- Сохранить единый pipeline предобработки и модели.
- Добавить проверки допустимости роста, веса и размера.

DL-задачи: 6-й чекпоинт
- Для item_id и других высококардинальных категорий использовать nn.Embedding, затем небольшой MLP; преподаватель предоставляет стартовый Dataset/DataLoader.

- Сравнение качества MLP с CatBoost на одинаковом test-наборе.
- Не создавать плотную full one-hot матрицу для тысяч item_id. Как упрощённую ablation-модель допустимо обучить MLP без item_id и отдельно объяснить снижение качества.

Возможные улучшения: 7-й чекпоинт

- Class weights для редких классов.
- Новые признаки, связанные с сочетанием роста, веса и выбранного размера.
- Анализ ошибок отдельно по платьям, юбкам, топам и другим категориям.
- Калибровка вероятностей.
- Опционально исследовать cold-start на новых вещах без item_id и честно сравнить снижение качества.

Метрики качества

- Macro-F1.
- Balanced Accuracy.
- Confusion Matrix.
- Дополнительно — per-class Precision/Recall.

Важное ограничение

Без измерений самой одежды модель не может надёжно оценивать совершенно новую вещь. Обязательный сервис работает только для анонимизированных item_id, представленных в обучающем каталоге, а поле size трактуется как внутренний код RentTheRunway, а не универсальный размер. Отзыв, рейтинг и дата отзыва исключаются как сведения, появившиеся после примерки; сервис является учебной демонстрацией, а не готовым магазинным подборщиком.

Ожидаемый результат

- Модель, выдающая вероятности трёх вариантов посадки для известных вещей каталога.
- Сравнение Logistic Regression, CatBoost и MLP.
- Сервис для интерактивной проверки размера выбранной вещи из фиксированного каталога.
- Анализ категорий одежды, на которых модель ошибается чаще всего.

163. Review Decoder: порекомендует ли покупательница эту вещь?

Уровень сложности: base/middle

Руководители: Ильинский Андрей, Абакумов Юрий

Пререквизиты: основы Python и классификации; готовность познакомиться с TF-IDF и базовыми NLP-подходами.

Введение

Датасет содержит англоязычные отзывы интернет-магазина женской одежды. В проекте предлагается научить модель определять по английскому тексту, рекомендует покупательница вещь или нет.

Цель проекта

Разработать англоязычный текстовый классификатор и сервис, который принимает отзыв и возвращает вероятность recommend / not recommend.

Данные

Используется Women's E-Commerce Clothing Reviews: 23 486 анонимизированных англоязычных отзывов, категории одежды и готовая бинарная метка Recommended IND.

Ссылка на датасет:

https://www.kaggle.com/datasets/nicapotato/womens-ecommerce-clothing-reviews

EDA и 2-й чекпоинт

- Исследовать баланс классов.
- Сравнить длину положительных и отрицательных отзывов.
- Построить частотные слова и биграммы для двух классов.
- Сравнить долю рекомендаций по категориям одежды.
- Проанализировать короткие отзывы и пропуски.

ML-задачи: 3-й и 4-й чекпоинты

- DummyClassifier как baseline.
- TF-IDF + Logistic Regression как обязательная вероятностная линейная модель. LinearSVC допускается как дополнительный эксперимент только вместе с CalibratedClassifierCV, если в сервисе требуется вероятность.
- Нелинейный этап: TruncatedSVD до 100–300 компонент и CatBoost/HistGradientBoosting; sentence embeddings относятся уже к DL-этапу.
- Сравнить модель только по тексту и модель текст + категория одежды.
- Провести анализ наиболее важных слов и типичных ошибок.

Сервисная часть: 5-й чекпоинт

- Пользователь вводит английский текст отзыва и при желании выбирает категорию одежды.
- Сервис возвращает вероятность рекомендации из Logistic Regression либо из отдельно откалиброванного классификатора;

необработанный decision score LinearSVC нельзя показывать как вероятность.
- Дополнительно можно показывать несколько слов, которые сильнее всего повлияли на прогноз линейной модели.
- Сервис должен использовать тот же preprocessing pipeline, который применялся при обучении.
- Добавить ограничения на пустой и слишком длинный ввод.

DL-задачи: 6-й чекпоинт

- Обязательный DL-вариант: заранее зафиксированные и кэшированные преподавателем sentence embeddings + небольшой MLP; обучение большой языковой модели не требуется.
- Fine-tuning DistilBERT допускается только как расширение при наличии GPU и времени.
- Сравнить нейросетевой подход с TF-IDF + Logistic Regression по тем же метрикам.

Возможные улучшения: 7-й чекпоинт

- Обработка отрицаний и сочетаний слов.
- Объединение заголовка и основного текста.
- Подбор порога классификации.
- Анализ качества отдельно на коротких, длинных и неоднозначных отзывах.
- Калибровка вероятностей и интерпретация ошибок.

Метрики качества

- Macro-F1.
- F1 для класса not recommend.
- PR-AUC, если класс not recommend объявлен положительным при расчёте метрики.
- Дополнительно — ROC-AUC и confusion matrix.

Важное ограничение

Тема сложнее чисто табличных проектов и рассчитана на английский язык. Rating, Positive Feedback Count и Clothing ID нельзя подавать в основную модель. Обучение трансформера не является обязательным и не должно становиться блокером проекта.

Ожидаемый результат

- Текстовый классификатор рекомендаций.
- Сравнение TF-IDF baseline, нелинейной модели и DL-подхода.
- Интерактивный сервис для анализа нового отзыва.
- Интерпретация слов и типов отзывов, на которых модель принимает ошибочные решения.

164. Perfume Lab: похож ли аромат на высоко оценённые?

Руководители: Ильинский Андрей, Абакумов Юрий, Ширнин Александр
Уровень сложности: base/middle

Пререквизиты: базовые знания Python, pandas и классификации; готовность работать с категориальными и multi-hot признаками.

Введение
Парфюмерная композиция описывается основными аккордами и пирамидой нот. В проекте предлагается проверить, похож ли аромат по этим характеристикам на ароматы из высоко оценённой группы в фиксированном снимке данных.

Цель проекта
Разработать модель бинарной классификации, которая оценивает вероятность принадлежности аромата к высоко оценённой группе в фиксированном наборе данных.

Данные
Используется очищенный Parfumo Fragrance Dataset из TidyTuesday. Он содержит год выпуска, концентрацию, рейтинг, число оценок, основные аккорды, верхние, средние и базовые ноты, бренд и парфюмеров.
Прямая загрузка CSV:
https://raw.githubusercontent.com/rfordatascience/tidytuesday/main/data/2024/2024-12-10/parfumo_data_clean.csv

EDA и 2-й чекпоинт
- Исследовать распределение рейтинга и количества оценок.
- Построить топ наиболее частых нот и аккордов.
- Сравнить рейтинги по концентрациям и годам выпуска.
- Проанализировать бренды с наибольшим числом ароматов.
- Исследовать часто встречающиеся сочетания нот.

ML-задачи: 3-й и 4-й чекпоинты
- DummyClassifier как baseline.
- One-Hot + multi-hot признаки и Logistic Regression.
- CatBoostClassifier как нелинейная модель.
- Основное сравнение: композиционная модель без Brand/Perfumers и отдельная аналитическая модель с брендом.
- Проверить, сохраняется ли качество без запоминания узнаваемых брендов.

Сервисная часть: 5-й чекпоинт
- Пользователь задаёт год выпуска, концентрацию, основные аккорды и несколько top / middle / base notes существующего или гипотетического аромата.
- Сервис возвращает вероятность статистической похожести на высоко оценённую группу в исходном наборе.
- Можно реализовать отдельные поля для top / middle / base notes.

- В интерфейсе показывать наиболее важные признаки прогноза.
- Неизвестные ноты не должны приводить к ошибке: их следует отображать в категорию __OTHER__ либо игнорировать по заранее зафиксированному правилу и показывать пользователю предупреждение.

DL-задачи: 6-й чекпоинт

- MLP на one-hot/multi-hot векторе признаков.
- Опционально: сформировать строковое описание композиции и получить готовый текстовый embedding, затем обучить MLP-классификатор.
- Сравнить DL с CatBoost на одном test-наборе.

Возможные улучшения: 7-й чекпоинт

- Раздельная обработка верхних, средних и базовых нот.
- Признаки взаимодействий наиболее частых нот.
- SHAP или permutation importance.
- Анализ ошибок по годам выпуска, концентрациям и брендам.
- Проверка устойчивости при другом минимальном количестве пользовательских оценок.

Метрики качества

- ROC-AUC.
- F1-score.
- Balanced Accuracy.
- Дополнительно — PR-AUC.

Важное ограничение

Пользовательский рейтинг субъективен и отражает аудиторию конкретной платформы. Это не надёжный прогноз будущего рейтинга: сервис оценивает статистическую похожесть композиции на высоко оценённые ароматы. Brand и Perfumers исключаются из обязательной модели; для необычной комбинации нот вне обучающего распределения интерфейс должен показывать предупреждение.

Ожидаемый результат

- Модель оценки вероятности принадлежности к высоко оценённой группе.
- Сравнение линейной, CatBoost и нейросетевой моделей.
- Сервис-конструктор композиции со статистической оценкой похожести.
- Интерпретация нот и аккордов, наиболее связанных с target.

165. Trip Price: сколько может стоить квартира для поездки?

Уровень сложности: base

Руководители: Ильинский Андрей, Абакумов Юрий

Пререквизиты: базовые знания Python, pandas и методов регрессии.

Введение

При выборе жилья для путешествия полезно понимать типичный уровень цены для конкретного района и набора характеристик. В проекте строится модель стоимости объявления в одном городе и в один фиксированный период.

Цель проекта

Разработать регрессионную модель и сервис, который по параметрам жилья выдаёт ожидаемую цену за ночь и отдельно сообщает типичную абсолютную ошибку модели.

Данные

Используется фиксированный подробный снимок Inside Airbnb для Парижа от 16.06.2026. Команда скачивает файл один раз в начале проекта и больше не обновляет его.

Прямая загрузка:

https://data.insideairbnb.com/france/ile-de-france/paris/2026-06-16/data/listings.csv.gz

EDA и 2-й чекпоинт

- Исследовать распределение цен и выбросы.
- Сравнить цены по районам и типам жилья.
- Проверить влияние числа гостей, спален и кроватей.
- Построить простую карту объявлений.
- Исследовать географию цены: районы, координаты и расстояние до центра.

ML-задачи: 3-й и 4-й чекпоинты

- Baseline: медианная цена по train-набору.
- Linear Regression или Ridge как линейная модель.
- CatBoostRegressor как нелинейная модель.
- Сравнить модели по MAE в исходной валюте.
- Провести анализ ошибок отдельно для дешёвого, среднего и дорогого сегментов.

Сервисная часть: 5-й чекпоинт

- Пользователь выбирает район, тип жилья, число гостей, спальни, кровати, ванные, удобства и minimum_nights. Для расширенной географической модели пользователь дополнительно ставит точку на карте; скрытые координаты нельзя подставлять только в ноутбуке, если их нет в интерфейсе.
- Сервис возвращает ожидаемую цену за ночь.
- MAE показывается как типичная абсолютная ошибка, а не как статистический интервал прогноза.

- Опционально построить эмпирический 80%-й интервал по квантилям остатков на отдельной calibration-выборке.
- Сохранить preprocessing и модель единым pipeline.

DL-задачи: 6-й чекпоинт

- MLP для регрессии на табличных признаках.
- Сравнить MLP с Ridge и CatBoost.
- Зафиксировать и объяснить случай, если DL не улучшает качество.

Возможные улучшения: 7-й чекпоинт

- Добавить расстояние до центра города только вместе с полем координат или выбором точки на карте в сервисе.
- Создать географические признаки по координатам и проверить, что тот же расчёт выполняется в production-pipeline.
- Подобрать гиперпараметры CatBoost.
- Проанализировать ошибки по районам.
- Проверить устойчивость модели после удаления самых дорогих объектов.

Метрики качества

- MAE в исходной валюте.
- RMSE.
- R^2.
- Дополнительно — MAE по ценовым сегментам и районам.

Важное ограничение

Модель описывает цены объявлений Парижа на 16.06.2026 и не определяет универсальную «справедливую стоимость». Нельзя смешивать города и даты. Признаки отзывов и будущей доступности исключены, чтобы форма сервиса соответствовала данным, доступным при создании объявления.

Ожидаемый результат

- Регрессионная модель оценки стоимости жилья.
- Сравнение простого baseline, линейной модели, CatBoost и MLP.
- Интерактивный калькулятор цены.
- Анализ районов и параметров жилья, которые сильнее всего связаны с ценой.

166. Cancel Alert: будет ли отменена бронь?

Уровень сложности: base

Руководители: Ильинский Андрей, Абакумов Юрий

Пререквизиты: базовые знания Python, pandas и бинарной классификации.

Введение

Отмена гостиничного бронирования осложняет планирование загрузки отеля. В проекте предлагается оценивать риск отмены сразу после подтверждения брони, используя только сведения, известные в этот момент.

Цель проекта

Разработать модель бинарной классификации и сервис, который оценивает вероятность последующей отмены новой подтверждённой брони.

Данные

Используется Hotel Booking Demand Dataset: 119 390 бронирований двух португальских отелей и 32 столбца в подготовленной версии TidyTuesday.

Прямая загрузка CSV:

https://raw.githubusercontent.com/rfordatascience/tidytuesday/main/data/2020/2020-02-11/hotels.csv

EDA и 2-й чекпоинт

- Исследовать общую долю отмен.
- Сравнить city hotel и resort hotel.
- Проверить связь отмены со сроком между бронированием и заездом.
- Проанализировать сезонность, тип депозита и количество специальных пожеланий.
- Сравнить новых и постоянных клиентов.

ML-задачи: 3-й и 4-й чекпоинты

- DummyClassifier как baseline.
- Logistic Regression как линейная модель.
- CatBoostClassifier как нелинейная модель.
- Сравнить модели на одном хронологическом test-наборе по ROC-AUC, PR-AUC и калибровке.
- Отдельно оценить Recall отмен: сколько реально отменённых броней модель смогла обнаружить.

Сервисная часть: 5-й чекпоинт

- Форма содержит только поля, доступные сразу после создания брони.
- На выходе — вероятность отмены и категория риска: низкий / средний / высокий.
- Порог между категориями должен быть описан и обоснован.
- Добавить API или Streamlit-интерфейс и тесты входных данных.
- В интерфейсе можно показывать 3–5 факторов, сильнее всего повлиявших на прогноз.

DL-задачи: 6-й чекпоинт

- MLP на табличных признаках.

- Сравнить нейросеть с Logistic Regression и CatBoost.
- Проанализировать не только итоговую метрику, но и качество вероятностей.

Возможные улучшения: 7-й чекпоинт

- Подбор бизнес-порога классификации.
- Калибровка вероятностей.
- SHAP для интерпретации.
- Отдельный анализ city hotel и resort hotel.
- Анализ ошибок по lead_time, сезону, типу отеля и ценовому сегменту.

Метрики качества

- ROC-AUC.
- PR-AUC.
- F1-score.
- Recall отменённых бронирований.
- Дополнительно — calibration curve / Brier score.

Важное ограничение

Использование полей, изменившихся после бронирования, создаёт серьёзную утечку. Обязательная модель работает в момент подтверждения брони; final test должен быть хронологическим по восстановленному booking_date, иначе оценка может оказаться слишком оптимистичной.

Ожидаемый результат

- Модель оценки риска отмены.
- Сервис для интерактивного скоринга новой брони.
- Сравнение линейной, нелинейной и DL-модели.
- Интерпретация основных факторов риска и анализ ошибок.

167. Mutual Match: будет ли взаимная симпатия?

Уровень сложности: base/middle

Руководители: Ильинский Андрей, Абакумов Юрий

Пререквизиты: базовые знания Python и классификации; готовность внимательно работать с утечками и парными признаками.

Введение

После короткой встречи участники speed dating заполняют анкету с оценками партнёра и решением, хотят ли увидеться снова. В проекте финальные решения и наиболее близкие к ним субъективные поля исключаются, а модель ретроспективно связывает взаимные оценки с итоговым match.

Цель проекта

Разработать модель бинарной классификации и ретроспективный демонстрационный сервис, который по взаимным оценкам после короткой встречи оценивает вероятность зафиксированного в эксперименте match.

Данные

Используется открытая CSV-версия Speed Dating с DataHub: 8 378 строк, 123 поля и готовый target match. Набор основан на экспериментах Columbia Business School 2002–2004 годов.

Прямая загрузка CSV:

https://datahub.io/core/speed-dating/_r/-/data/speed-dating.csv

EDA и 2-й чекпоинт

- Исследовать баланс match / no match.
- Сравнить распределения оценок для взаимных и невзаимных случаев.
- Изучить роль общих интересов.
- Сравнить одностороннюю и взаимную симпатию.
- Проанализировать, насколько участники угадывают интерес партнёра.

ML-задачи: 3-й и 4-й чекпоинты

- DummyClassifier как baseline.
- Logistic Regression как линейная модель.
- CatBoostClassifier как нелинейная модель.
- Сравнить исходные взаимные оценки и engineered pair features на одном split по wave; test-события не использовать при выборе признаков и порога. Отдельно можно показать, насколько late-proxy модель с like/guess_prob_liked искусственно упрощает задачу.
- Проанализировать false positive: случаи, когда модель прогнозирует match, а его нет.

Сервисная часть: 5-й чекпоинт

- Интерфейс с двумя колонками взаимных оценок участников.
- Сервис возвращает вероятность взаимного match.
- Показать краткое объяснение наиболее важных факторов прогноза.
- Сервис используется только как демонстрация модели на историческом учебном датасете.
- Добавить тесты на диапазон оценок.

DL-задачи: 6-й чекпоинт

- Небольшой MLP на табличных и парных признаках.
- Сравнить качество с CatBoost.
- Опционально: обучить простые embeddings для категориальных полей, если они сохраняются.

Возможные улучшения: 7-й чекпоинт

- Дополнительный feature engineering парных оценок.
- Калибровка вероятности.
- Подбор порога.
- Анализ false positive и false negative.
- Сравнение основной модели по взаимным оценкам, модели с дополнительными индивидуальными признаками и отдельной late-proxy модели с like/guess_prob_liked.

Метрики качества

- PR-AUC.
- F1-score.
- ROC-AUC.
- Calibration error или Brier score.
- Precision/Recall для класса match.

Важное ограничение

Данные относятся к конкретному американскому эксперименту начала 2000-х. Одна встреча исходно может встречаться дважды с разных точек зрения. Оценки и решение собирались после встречи, поэтому модель не является ранним прогнозом. Поля финального решения и близкие к нему like/guess_prob_liked исключаются из основной модели. Система является только учебной демонстрацией и не измеряет совместимость людей.

Ожидаемый результат

- Бинарный классификатор взаимного match.
- Сравнение Logistic Regression, CatBoost и MLP.
- Интерактивный учебный сервис.
- Исследование того, какие взаимные оценки статистически связаны с target.

168. Home Finder: найдёт ли питомец дом за 30 дней?

Уровень сложности: base/middle
Руководители: Ильинский Андрей

Пререквизиты: базовые знания Python, pandas и бинарной классификации; преподаватель заранее готовит очищенную учебную таблицу и фиксированное разбиение.

Введение
Приюту важно понимать, какие животные дольше ждут усыновления и где необходима дополнительная поддержка процесса пристройства. В проекте предлагается по сведениям, известным при поступлении животного, оценивать вероятность усыновления в течение 30 дней.

Цель проекта
Разработать бинарную модель adopted_30d и сервис, который по карточке поступления питомца оценивает вероятность исхода Adoption в первые 30 дней.

Данные
Используется фиксированный снимок Long Beach Animal Shelter из TidyTuesday. В одной таблице находятся сведения о поступлении и исходе; набор содержит 29 787 записей и 22 поля. Для проекта оставляются кошки и собаки, для которых к дате окончания наблюдения прошло не менее 30 дней после intake; незавершённые эпизоды не удаляются автоматически.
Прямая загрузка CSV:
https://raw.githubusercontent.com/rfordatascience/tidytuesday/main/data/2025/2025-03-04/longbeach.csv

EDA и 2-й чекпоинт

- Посчитать долю всех пригодных для разметки эпизодов кошек и собак, закончившихся усыновлением за 30 дней.
- Сравнить кошек и собак, возрастные группы, пол и состояние при поступлении.
- Исследовать intake type, intake condition и сезонность поступлений.
- Проанализировать редкие цвета, intake subtype и reason_for_intake; объединить редкие категории только по train-набору.
- Проверить пропуски, повторные animal_id, правое цензурирование, некорректный dob, отрицательные/аномальные сроки и согласованность intake/outcome дат.

ML-задачи: 3-й и 4-й чекпоинты

- DummyClassifier как baseline.
- One-Hot Encoding + Logistic Regression как линейная модель.
- CatBoostClassifier как нелинейная модель.
- Использовать class weights или подбор порога, если adopted_30d несбалансирован.
- Сравнить модели на одном фиксированном group test-наборе и провести анализ ошибок по группам животных.

Сервисная часть: 5-й чекпоинт

- Пользователь заполняет обезличенную карточку поступления питомца.
- Сервис возвращает вероятность усыновления в течение 30 дней.
- Дополнительно показывать калиброванную категорию вероятности: низкая / средняя / высокая.
- Интерпретация показывает статистические связи, но не даёт рекомендаций ограничивать помощь животным по возрасту, цвету, полу или состоянию.
- Сохранить preprocessing и модель единым pipeline; добавить тесты диапазонов возраста и категорий.

DL-задачи: 6-й чекпоинт

- Небольшой MLP на тех же табличных признаках.
- Сравнить MLP с Logistic Regression и CatBoost на одном test-наборе.
- Опционально использовать обучаемые embeddings частых категорий; изображения и тексты не требуются.
- Зафиксировать и объяснить случай, если CatBoost превосходит нейросеть.

Возможные улучшения: 7-й чекпоинт

- Подбор порога и калибровка вероятностей.
- Более аккуратная обработка редких цветов, intake subtype и причин поступления.
- SHAP или permutation importance.
- Анализ качества по animal type, возрастным группам и периодам времени.
- Проверка устойчивости при горизонтах 14, 30 и 60 дней как отдельный эксперимент; для каждого горизонта заново определить допустимое окно наблюдения относительно data_cutoff.

Метрики качества

- PR-AUC.
- F1-score.
- ROC-AUC.
- Precision и Recall для adopted_30d.

Важное ограничение

Это ретроспективные данные одного муниципального приюта. Правое цензурирование учитывается консервативным data_cutoff: слишком свежие поступления исключаются, а животные без исхода после полного 30-дневного окна относятся к классу 0.

Ожидаемый результат

- Бинарная модель adopted_30d на фиксированном открытом CSV.
- Сервис для оценки обезличенной карточки поступления кошки или собаки.
- Сравнение Logistic Regression, CatBoost и MLP.
- Анализ факторов и групп, для которых модель ошибается чаще всего.

169. Buy or Bye: купит или уйдёт?

Уровень сложности: base
Руководители: Ильинский Андрей

Пререквизиты: базовые знания Python, pandas и бинарной классификации.

Введение
Датасет описывает каждую сессию уже агрегированным вектором: количеством страниц, длительностями, bounce/exit rate и другими показателями. Проект классифицирует такой зафиксированный снимок сессии, а не строит полноценный потоковый прогноз по каждому клику.

Цель проекта
Разработать воспроизводимый классификатор Revenue и сервис для скоринга одной агрегированной записи пользовательской сессии.

Данные
Использовать официальный Online Shoppers Purchasing Intention Dataset из UCI. В нём 12 330 сессий, 17 входных признаков и нет пропусков. Целевая переменная Revenue показывает, закончилась ли сессия покупкой.
Ссылка на датасет:
https://archive.ics.uci.edu/static/public/468/online+shoppers+purchasing+intention+dataset.zip

EDA и 2-й чекпоинт
- Посчитать общую конверсию в покупку.
- Сравнить число просмотренных товарных страниц.
- Проанализировать длительность сессии.
- Сравнить новых и возвращающихся посетителей.
- Исследовать bounce rate, exit rate, месяц и выходной/будний день.

ML-задачи: 3-й и 4-й чекпоинты
- DummyClassifier как baseline.
- Logistic Regression как линейная модель.
- CatBoostClassifier как нелинейная модель.
- Использовать class weights или подбор порога вместо оценки одной accuracy.
- Отдельно сравнить качество для новых и возвращающихся посетителей.

Сервисная часть: 5-й чекпоинт
- Реализовать в Streamlit демонстрационную форму агрегированных параметров сессии.
- Пользователь задаёт число просмотренных страниц, длительности, тип посетителя, месяц и другие доступные показатели.
- Сервис возвращает вероятность покупки.
- Можно дополнительно показывать low / medium / high purchase intent.
- Добавить валидацию диапазонов и pytest-тесты.

DL-задачи: 6-й чекпоинт
- Небольшой MLP на табличных признаках.

- Сравнить MLP с Logistic Regression и CatBoost.
- Провести одинаковую оценку на test-наборе без ручного подбора результата.

Возможные улучшения: 7-й чекпоинт

- Class weights или cost-sensitive learning.
- Подбор порога под желаемый Precision/Recall.
- Калибровка вероятностей.
- SHAP.
- Сравнение модели с PageValues и без него.

Метрики качества

- PR-AUC.
- F1-score.
- ROC-AUC.
- Recall покупающего класса.
- Precision покупающего класса.

Важное ограничение

Исходные данные не являются последовательностью кликов. Сервис демонстрирует скоринг готового вектора сессии и не должен называться ранним real-time предсказанием. PageValues оценивается только в отдельной модели.

Ожидаемый результат

- Чистый end-to-end pipeline классификации.
- Сравнение Dummy, Logistic Regression, CatBoost и MLP.
- Простой интерактивный сервис.
- Анализ поведения сессий, которые чаще заканчиваются покупкой.

170. Recipe Crush: похож ли рецепт на высоко оценённые?

Уровень сложности: base/middle
Руководители: Ильинский Андрей

Пререквизиты: базовые знания Python и классификации; для текстового представления ингредиентов достаточно TF-IDF.

Введение
Можно ли по ингредиентам, времени приготовления, тегам и пищевой ценности отличить рецепты из высоко оценённой группы от остальных? В проекте используется ретроспективная агрегация пользовательских оценок и строится простой классификатор high_rating.

Цель проекта
Разработать модель, которая по характеристикам рецепта оценивает вероятность принадлежности к высоко оценённой группе в фиксированном наборе данных, и обернуть её в небольшой сервис.

Данные
Используется Food.com Recipes and Interactions. Для проекта нужны RAW_recipes.csv и RAW_interactions.csv.
Ссылка на датасет:
https://www.kaggle.com/datasets/shuyangli94/food-com-recipes-and-user-interactions

EDA и 2-й чекпоинт
- Исследовать время приготовления и число шагов.
- Сравнить калорийность и пищевую ценность.
- Построить распределение числа ингредиентов.
- Исследовать наиболее частые теги и ингредиенты.
- Сравнить характеристики high_rating и остальных рецептов.

ML-задачи: 3-й и 4-й чекпоинты
- DummyClassifier как baseline.
- TF-IDF по строке ингредиентов + Logistic Regression.
- CatBoostClassifier по табличным признакам и тегам.
- Сравнить модель только по ингредиентам и модель только по табличным признакам.
- Опционально объединить вероятности двух моделей простым ансамблем.

Сервисная часть: 5-й чекпоинт
- Пользователь указывает только характеристики, известные до публикации: ингредиенты, теги, время приготовления, число шагов и показатели пищевой ценности.
- Сервис возвращает вероятность принадлежности к высоко оценённой группе в исходном наборе.
- Можно дополнительно показать, какие ингредиенты или параметры повышают/снижают прогноз.

- Ввод ингредиентов преобразуется тем же TF-IDF vectorizer, что использовался при обучении.
- Добавить обработку неизвестных ингредиентов.

DL-задачи: 6-й чекпоинт

- Использовать простой nn.EmbeddingBag по словарю ингредиентов либо заранее рассчитанное среднее embedding-представление.
- Обучить MLP-классификатор.
- Сравнить с TF-IDF + Logistic Regression и CatBoost.

Возможные улучшения: 7-й чекпоинт

- Признаки сочетаний ингредиентов.
- Разделение по категориям блюд.
- Ансамбль текстовой и табличной моделей.
- Подбор порога и калибровка.
- Анализ ошибок на коротких и сложных рецептах.

Метрики качества

- ROC-AUC.
- F1-score.
- PR-AUC.
- Дополнительно — Precision/Recall для high_rating.

Важное ограничение

Это ретроспективная классификация только рецептов минимум с 10 уникальными оценками, а не надёжный прогноз реакции на совершенно новый рецепт. Все агрегаты пользовательских оценок и поля, отсутствующие в форме сервиса, исключаются из X.

Ожидаемый результат

- Классификатор принадлежности рецепта к высоко оценённой группе.
- Сравнение TF-IDF baseline, CatBoost и DL-подхода.
- Интерактивный сервис для оценки характеристик рецепта без обещания будущего рейтинга.
- Анализ ингредиентов и характеристик, связанных с high rating.

171. Цифровой двойник промышленного процесса

Трек: ML / DL

Уровень сложности: base

Руководитель: Виктор Кузнецов

Пререквизиты: Python, базовые знания ML. Знание химии не требуется

Идея: создать виртуальную копию технологической установки или процесса, которая работает параллельно с ним и предсказывает его поведение при разных сценариях. В промышленности цифровая копия процесса позволяет очень быстро протестировать множество возможных условий протекания реакций, найти оптимальный режим работы аппарата гораздо быстрее.

Цель: построить цифровой двойник простого химического реактора: реализовать эталонную физическую модель, обучить на ее данных быструю ML-модель-суррогат, научиться подбирать оптимальный режим и обнаруживать отклонения процесса от нормы.

Основные этапы

- Реализация эталонной модели процесса по готовым уравнениям.
- Генерация обучающего датасета: множество прогонов при разных параметрах.
- Обучение ML-моделей, воспроизводящих поведение эталона.
- Сравнение суррогата с эталоном по точности и скорости.
- Анализ чувствительности и подбор оптимального режима, дизайн эксперимента.
- Обнаружение отклонений процесса
- Интерактивный интерфейс

1. Эталон реактора

- Простой реактор описывается системой обыкновенных дифференциальных уравнений (концентрации веществ и температура во времени); решается стандартными средствами (scipy.integrate).
- Входные параметры: температура, начальная концентрация, время реакции, скорость подачи, конверсия, выход.

2. Генерация данных и обучение регрессии

- Планирование эксперимента (DoE). Добавление шума
- Обучение суррогатной модели, регрессии: входные параметры. выход продукта.
- Другие модели: градиентный бустинг, случайный лес, полносвязная нейросеть.
- Дополнительно: временные ряды, тренды

4. Функции Вашего продукта: делаем его полезным для инженеров и ученых

- Анализ чувствительности (помощь тем, кто следит за непрерывным производством, и должен предсказывать отклонения): какие параметры сильнее всего влияют на результат.
- Подбор оптимального режима (помощь R&D инженерам на предприятии): перебор или байесовская оптимизация по обученной модели. Тестирование сценариев работы реактора
- Risk assessment: имитируем неисправность, утечку энергии, или наоборот отсутствие реакции: изменение каких параметров работы

реактора может в совокупности привести к аварии? Есть ли скрытые закономерности между параметрами реакции и трендами основных показателей качества (можно попробовать PCA, PLS-разложение)

Подобный инструмент очень полезен при масштабировании производства, переносе, адаптации оборудования к новым процессам, а также может быть использован учеными для прогнозирования успешности их экспериментов (лабораторных) в реальной промышленности (производство лекарств, продуктов нефтехимии, парфюмерии, сложных молекул). Более узкую отрасль сможем выбрать совместно.

172. Детекция отмывания денег по транзакционным данным

Трек: ML
Уровень сложности: base
Руководитель: Юдайкин Кирилл (@ample_margin)
Пререквизиты: базовые знания Python и классического ML; понимание задач бинарной классификации и метрик для несбалансированных данных
Введение: Финансовые транзакции могут быть связаны как с легальной деятельностью, так и с незаконными операциями, включая отмывание денежных средств. В проекте используется публичный датасет Elliptic, содержащий информацию о транзакциях Bitcoin. Каждая транзакция уже представлена набором из 166 предвычисленных признаков: локальных характеристик самой транзакции и агрегированных характеристик её ближайшего окружения. Это позволяет решать задачу преимущественно методами классического табличного машинного обучения без обязательного использования графовых нейросетей.
Особенностью датасета является большое количество неразмеченных объектов и выраженный дисбаланс классов. Кроме того, транзакции распределены по временным шагам, поэтому при оценке модели необходимо учитывать временной дрейф и использовать честное temporal-разбиение.

Цель проекта: Разработать модель бинарной классификации подозрительных транзакций и демонстрационный сервис AML-мониторинга, который по признакам транзакции оценивает вероятность её принадлежности к классу illicit.

Данные: Используется открытый датасет Elliptic Data Set: около 203 тысяч Bitcoin-транзакций, распределённых по 49 временным шагам. Каждая транзакция описана 166 признаками: 94 локальными признаками и 72 агрегированными признаками ближайшего окружения. Около 2% транзакций размечены как незаконные (illicit), около 21% — как легальные (licit), а оставшиеся около 77% не имеют метки класса.

Датасет: Elliptic Data Set на Kaggle

Основные этапы:

1. **EDA и 2-й чекпоинт**
    a. Исследовать баланс illicit / licit транзакций
    b. Проанализировать динамику доли незаконных транзакций по временным шагам
    c. Исследовать распределения основных признаков для разных классов
    d. Проанализировать временной дрейф распределений признаков
    e. Подготовить train/test split
2. **ML-задачи: 3-й и 4-й чекпоинты**

    a. Обучение бэйзлайн модели (dummy или логрег)
    b. Обучение более сильных моделей
    c. Feature engineering
    d. Оценить качество классификации и сравнить модели
3. **Semi-supervised-задачи: 3-й и 4-й чекпоинты**
    a. Использовать неразмеченную часть данных для улучшения качества классификации
    b. Реализовать self-training или pseudo-labeling
    c. Опционально: исследовать PU-learning, рассматривая известные illicit-транзакции как positive-примеры, а неразмеченные транзакции - как unlabeled
    d. Опционально: использовать label propagation или kNN-граф в пространстве признаков без обучения графовых нейросетей
4. **Сервисная часть: 5-й чекпоинт**
    a. REST API принимает признаки транзакции и возвращает вероятность класса illicit
    b. Показать краткое объяснение наиболее важных факторов прогноза с помощью SHAP или аналогичного метода интерпретации
    c. Добавить тесты на корректность входных данных и работу API
    d. Сделать UI и визуализации
5. **DL-задачи: 6-й чекпоинт**
    a. Небольшой MLP на табличных признаках
    b. Исследовать DL для табличных данных
    c. Попробовать графовые нейросети
    d. Сравнить модели по качеству, устойчивости к временному дрейфу и интерпретируемости

Ожидаемый результат:

- Бинарный классификатор подозрительных транзакций
- Сравнение Logistic Regression, Random Forest, CatBoost/XGBoost и, при выполнении DL-трека, MLP или табличной DL-модели
- Исследование эффективности semi-supervised подходов на данных с большим количеством неразмеченных объектов
- Анализ устойчивости моделей к временному дрейфу
- Интерактивный учебный сервис AML-мониторинга с API, скорингом транзакций и объяснением прогнозов

173. Свободная тема

Уровень: Pro/Middle/Easy

Руководители: Андреев Дмитрий, Ильинский Андрей, Мустафин Фарид

Если вы не нашли того, что вам по душе, можете писать в личку и предлагать.

174. Мультиагентная система для автоматизации решения задач на хакатонах. (ML + DL)

Уровень: Middle

Руководители: Андреев Дмитрий

Несколько LLM-агентов независимо анализируют задачу и выполняют разные роли: один проектирует решение, другой пишет код, третий проверяет ошибки, четвертый предлагает альтернативные подходы. Отдельный агент-координатор собирает результаты, запускает итерации критики и выбирает итоговое решение.

175. RESEARCH. Долговременная память для LLM - агентов + сжатие KV-cache (опционально) (DL)

Уровень: Pro

Руководители: Андреев Дмитрий

Контекст конечен, агент забывает старые факты и решения. Необходимо придумать решение.

176. RESEARCH. Уверенность LLM и RAG (ML + DL)

Уровень: Proя

Руководители: Андреев Дмитрий

Модель может уверенно отвечать неправильно, а потом, когда пользователь явно указывает на ошибку - в ответ получаем что то типо: “Да, я ошибся”. Было?

177. RESEARCH. Continual Learning без забывания (ML + DL)

Уровень: Pro

Руководители: Андреев Дмитрий

Проблема: при дообучении модели на одном домене падают метрики на других доменах. Пробуем фиксить.

178. Безопасность LLM-агентов, использующих внешние инструменты

Трек: DL,RESEARCH
Уровень: MIDDLE,PRO
Руководители: Цуриков Виталий, Ширнин Александр

Идея. Создать экспериментальную среду, в которой LLM-агент работает с документами, сайтами и внешними инструментами, но может столкнуться со скрытыми вредоносными инструкциями, попытками получить закрытые данные или выполнить опасное действие.

Возможная реализация. Команда может выбрать любой понятный сценарий: электронную почту, календарь, интернет-магазин, образовательную систему или работу с файлами. Предлагается реализовать несколько способов защиты, например разграничение прав, подтверждение критичных действий, проверку источников и фильтрацию подозрительных команд.

Результат и оценка. Итогом станет воспроизводимый стенд для проверки безопасности агентов. Решение можно оценивать по числу предотвращённых атак, доле успешно выполненных обычных задач, ложным блокировкам и дополнительным затратам. Возможное усложнение — автоматическая генерация новых атак или адаптация защиты к разным моделям.

179. Computer-use/GUI-агент для управления браузером и/или приложениями

Трек: DL,RESEARCH
Уровень: MIDDLE,PRO
Руководители: Цуриков Виталий

Идея. Разработать агента, который получает задачу на естественном языке, видит интерфейс программы и самостоятельно выполняет необходимые действия: ищет информацию, нажимает кнопки, заполняет формы и проверяет результат.

Возможная реализация. Команда может выбрать браузерные, офисные, образовательные или другие безопасные сценарии. Агент способен работать по изображению экрана, структуре интерфейса или сочетать оба источника. Базовую версию можно ограничить локальными веб-приложениями, уделив внимание длинным последовательностям и восстановлению после ошибок.

Результат и оценка. Итогом станет работающий агент и набор воспроизводимых заданий. Основные показатели — доля выполненных задач, количество неверных действий, время работы и стоимость запросов. Более сложное развитие может включать адаптацию к изменившемуся интерфейсу, работу с несколькими приложениями или обучение собственного модуля выбора действий.

180. Автоматическая оптимизация LLM-агента по результатам его работы

Трек: DL,RESEARCH
Уровень: MIDDLE,PRO
Руководители: Цуриков Виталий, Мустафин Фарид

Идея. Создать систему, которая анализирует успешные и неуспешные запуски LLM-агента, находит повторяющиеся ошибки и автоматически предлагает улучшения его инструкций, инструментов или последовательности действий.

Возможная реализация. Предметную область можно выбрать свободно: поиск информации, программирование, обработку документов, планирование или анализ данных. Система будет сохранять траектории агента, классифицировать ошибки и формировать улучшенную конфигурацию. В доступной версии достаточно оптимизировать системный промпт или описания инструментов.

Результат и оценка. Итогом станет оптимизатор и интерфейс для сравнения версий агента. Качество измеряется на отдельном наборе задач по успешности, стоимости, стабильности и скорости улучшения. Сильная команда может оптимизировать структуру всего workflow, переносить найденные решения между моделями или обучить модуль, выбирающий стратегию для конкретной задачи.

181. Research Assistant для научных статей

Трек: DL
Уровень: PRO
Руководители: Тимофей Соборнов

Проблема

При чтении научной статьи часто приходится постоянно переключаться между самой статьёй и её источниками. Чтобы разобраться в каком-либо

утверждении, нужно открывать десятки ссылок, искать нужный абзац и восстанавливать контекст вручную.

Существующие чат-интерфейсы над статьями обычно ограничиваются содержимым одного документа и не учитывают сеть цитирований, на которой строится научная работа.

Идея решения

Система позволяет загрузить научную статью (PDF, arXiv-ссылка и т.д.) и построить интерактивное пространство знаний вокруг неё.

После загрузки документа:

Из статьи извлекается текст и список цитируемых источников.

Для каждой статьи создаётся отдельное индексируемое пространство знаний.

Векторный индекс содержит как исходную статью, так и связанные с ней публикации.

Пользователь может задавать вопросы на естественном языке и получать ответы с указанием конкретных источников и фрагментов текста.

Вместо поиска по одному документу система фактически предоставляет поиск по локальному графу научных публикаций.

182. Blog Research Assistant

Трек: DL
Уровень: PRO
Руководители: Тимофей Соборнов, Мустафин Фарид

Проблема

Большинство инструментов для генерации контента пытаются сразу написать готовый пост.

На практике это приводит к появлению большого количества однотипного AI-сгенерированного текста, который плохо отражает экспертизу автора.

При этом настоящая ценность часто заключается не в написании текста, а в поиске интересных идей и структурировании материала.

Идея решения

Система выступает не как генератор постов, а как исследовательский помощник для автора.

На вход подаются:

транскрипты выступлений;

записи встреч;

интервью;

статьи;

заметки.

Модель анализирует материал и предлагает потенциально интересные направления для публикаций.

Затем пользователь выбирает тему, а система формирует исследовательскую справку:

ключевые тезисы;

спорные моменты;

неожиданные наблюдения;

возможные выводы;

подтверждающие цитаты.

Финальный текст остаётся за человеком.

183. Real Economy Dashboard

Трек: DL
Уровень: PRO
Руководители: Тимофей Соборнов

Проблема

Большинство макроэкономических показателей являются агрегированными метриками, которые слабо отражают повседневную экономическую реальность.

Например:

инфляция измеряется через усреднённую потребительскую корзину;

валютные курсы публикуются как среднерыночные значения;

статистика по недвижимости публикуется с задержкой и в агрегированном виде;

ключевая ставка не показывает стоимость кредитов для конечного потребителя.

В результате между официальными макроэкономическими показателями и ощущениями населения часто возникает заметный разрыв.

Цель системы

Построить дашборд, отображающий экономическую ситуацию через наблюдаемые рыночные показатели, напрямую влияющие на повседневную жизнь.

Вместо анализа производных индексов система собирает данные из первичных источников и позволяет отслеживать их динамику во времени.

Источники данных

Система периодически агрегирует информацию из открытых источников.

Кредитный рынок

Отслеживаются:

потребительские кредиты;

ипотечные кредиты;

автокредиты.

Для каждого предложения сохраняются:

эффективная ставка;

размер первоначального взноса;

требования к заёмщику;

банк и регион.

Это позволяет анализировать фактическую доступность кредитования.

Рынок недвижимости

Система собирает объявления о продаже и аренде жилья.

Нормализуются следующие признаки:

район;

тип жилья;

количество комнат;

площадь;

год постройки;

сегмент недвижимости.

На основе объявлений рассчитываются:

медианная стоимость;

цена квадратного метра;

стоимость аренды;

скорость изменения цен.

Рынок топлива

Для различных сетей АЗС собираются:

стоимость топлива;

тип топлива;

регион;

дата обновления.

Это позволяет отслеживать как общую динамику цен, так и различия между сетями.

Потребительские товары

Система регулярно собирает цены на фиксированный набор товаров.

Например:

молоко;

яйца;

хлеб;

курица;

кофе;

бытовая химия.

При этом сохраняются:

магазин;

бренд;

объём упаковки;

цена за единицу.

В отличие от официальной потребительской корзины пользователь может самостоятельно определять интересующий его набор товаров.

Валютный рынок

Собираются курсы:

банков;

обменных пунктов;

онлайн-платформ.

Это позволяет анализировать реальные курсы покупки и продажи, доступные населению.

184. Ресурсно-эффективный краткосрочный прогноз осадков по радиолокационным данным

Трек: DL / RESEARCH
Уровень: PRO
Руководители: Михаил Сахаров (tg: @mcccc)

Область: прогнозирование последовательностей радиолокационных изображений, Computer Vision, метеорологический nowcasting, нейросетевые архитектуры

Пререквизиты: уверенное владение Python; основы машинного и глубокого обучения; опыт работы с PyTorch; понимание принципов работы свёрточных нейронных сетей и архитектур семейства U-Net; базовые навыки обработки изображений и проведения вычислительных экспериментов. Будут полезны знакомство с PyTorch Lightning, Hydra, обработкой геоданных и чтением научных статей. Специальные знания в метеорологии не требуются — необходимый минимум можно освоить в ходе проекта.

Описание проекта

Краткосрочный прогноз осадков (nowcasting) — это предсказание перемещения и изменения зон дождя по последовательности последних радиолокационных наблюдений на горизонте от нескольких минут до нескольких часов. Такие прогнозы применяются в авиации, логистике, энергетике, городских сервисах и системах предупреждения об опасных погодных явлениях.

Современные модели nowcasting способны строить качественные прогнозы, но часто требуют нескольких GPU и значительного времени инференса. Для прикладного погодного сервиса модель должна обрабатывать большие радиолокационные карты и обновлять прогноз каждые несколько минут, поэтому важны не только точность, но и скорость, потребление памяти и устойчивость модели в разных регионах и сезонах.

В качестве отправной точки проекта используется компактная архитектура SmaAt-UNet.

Цель проекта — разработать и экспериментально исследовать ресурсно-эффективный метод краткосрочного прогноза осадков, устойчивый к смене региона, сезона и горизонта прогнозирования.

Что предстоит сделать (примерный план)

- Изучить современные методы краткосрочного прогноза осадков: optical flow, свёрточные и рекуррентные модели, трансформеры, вероятностные и генеративные подходы. Подумать на выбором решения из научных статей, которое попробуем улучшить.

- Воспроизвести baseline и сформировать единый протокол сравнения моделей с корректным временным разделением данных.

- Подготовить радиолокационные данные для нескольких регионов и сезонов (исходные данные предоставлю), исследовать пропуски, дисбаланс осадков, различия климатических режимов.

- Сформулировать гипотезы на эксперименты. Что может повлиять на результат. Например: добавление геоданных местности, использование данных погодных моделей, PINN и т. д.

- Определиться с метриками и составить протокол сравнения экспериментов.

- Собрать фреймворк для проведения экспериментов: конфиг на входе со всеми параметрами, подробный результат на выходе (все эпохи, процесс обучения, метрики).

- По результатам экспериментов делать выводы.

Обязательная часть проекта — воспроизводимое сравнение с базовыми методами проверка обобщенности хотя бы на нескольких регионах или временных периодах.

Ожидаемый результат

Воспроизводимый экспериментальный стенд для оценки модели nowcasting; обученная компактная модель краткосрочного прогноза осадков; сравнение качества и вычислительной стоимости с baseline; анализ предложенных улучшений.

104. Автоматическое распознавание сердечных патологий по многоканальным сигналам ЭКГ

Руководитель: Герасимова Мария
Датасет: PTB-XL

Уровень сложности: middle

Пререквизиты: основы ML/DL, модели классификации, основы обработки временных рядов и сигналов, метрики качества классификации, Python.

Электрокардиограмма является одним из основных методов диагностики сердечно-сосудистых заболеваний. Одна запись ЭКГ может одновременно содержать признаки нескольких патологий, поэтому задача естественным образом формулируется как мультиметочная классификация.

Цель проекта — разработать модель, которая по 12-канальному сигналу ЭКГ определяет наличие различных сердечных патологий.

задачи:

- предобработка и фильтрация сигналов ЭКГ;
- анализ частоты встречаемости диагнозов;
- исследование дисбаланса классов;
- визуализация ЭКГ разных диагностических групп;
- построение временно-частотных представлений сигналов;
- анализ зависимости качества модели от количества используемых каналов.

ML/DL-задачи:

- построение классификатора на основе статистических и спектральных признаков ЭКГ;
- применение одномерных свёрточных нейронных сетей;
- сравнение моделей, работающих с исходным сигналом и спектрограммами;
- мультиметочная классификация сердечных патологий;
- применение методов балансировки данных;
- подбор функций потерь для несбалансированной мультиметочной классификации;
- калибровка вероятностей модели;
- определение участков сигнала, наиболее сильно влияющих на прогноз.

---

185. Раннее прогнозирование интраоперационной гипотензии по физиологическим сигналам

Руководитель: Герасимова Мария
Датасет: VitalDB

Уровень сложности: pro

Пререквизиты: основы ML/DL, анализ временных рядов, модели классификации, обработка пропущенных значений, Python.

Во время хирургической операции состояние пациента непрерывно контролируется с помощью физиологических сигналов. Одним из опасных

осложнений является резкое снижение артериального давления. Если предсказать его заранее, медицинский персонал сможет своевременно вмешаться.

Цель проекта — построить модель раннего предупреждения об интраоперационной гипотензии на основе недавней истории физиологических сигналов пациента.

Для ограничения объёма работы предлагается использовать небольшой набор наиболее информативных сигналов: артериальное давление, частоту сердечных сокращений, сатурацию и при необходимости отдельные клинические параметры.

Возможные задачи:

- синхронизация физиологических сигналов;
- обработка пропусков, выбросов и артефактов;
- выделение эпизодов гипотензии;
- формирование временных окон перед наступлением осложнения;
- предотвращение утечки данных между обучающей и тестовой выборками;
- исследование различий между стабильными периодами и периодами перед гипотензией.

ML/DL-задачи:

- построение базовых моделей на статистических характеристиках сигналов;
- применение одномерных CNN, LSTM или других моделей временных рядов;
- прогнозирование гипотензии за разные интервалы времени;
- сравнение моделей, использующих разные наборы сигналов;
- анализ влияния отдельных физиологических параметров на прогноз;
- оценка количества ложных тревог;
- калибровка вероятностей;
- оценка неопределённости предсказания.

---

186. Сегментация и классификация клеточных ядер на гистологических изображениях

Руководитель: Герасимова Мария
Датасет: PanNuke

Уровень сложности: middle/pro

Пререквизиты: основы ML/DL, обработка изображений, модели сегментации и классификации, свёрточные нейронные сети, Python.

Количество, форма и расположение клеточных ядер являются важными признаками при анализе опухолевой ткани. Автоматическое выделение ядер позволяет ускорить морфологический анализ и получить количественные характеристики изображения.

Цель проекта — разработать модель для сегментации клеточных ядер и определения их типов на гистологических изображениях различных тканей.

PanNuke уже содержит небольшие фрагменты изображений с размеченными ядрами, поэтому работа не требует обработки полноразмерных гистологических слайдов.

Возможные задачи:

- исследовательский анализ размеров и формы клеточных ядер;
- изучение различий между типами клеток и тканей;
- анализ дисбаланса классов;
- предобработка и нормализация окраски изображений;
- исследование касающихся и перекрывающихся ядер;
- визуализация пространственного расположения клеток.

ML/DL-задачи:

- бинарная сегментация клеточных ядер;
- разделение соприкасающихся ядер;
- instance-сегментация отдельных объектов;
- классификация найденных ядер;
- сравнение совместного и раздельного решения задач сегментации и классификации;
- исследование переноса модели между разными типами тканей;
- анализ устойчивости модели к изменению окраски;
- построение признаков клеточного микроокружения.

---

187. Диагностика глазных заболеваний по парным изображениям глазного дна

Руководитель: Герасимова Мария
Датасет: ODIR-5K

Уровень сложности: middle

Пререквизиты: основы ML/DL, модели классификации изображений, transfer learning, методы работы с несбалансированными данными, Python.

При диагностике офтальмологических заболеваний врач обычно анализирует изображения обоих глаз. Однако многие автоматические модели рассматривают каждый снимок независимо и не используют информацию о сходстве и различиях между правым и левым глазом.

Цель проекта — разработать модель, которая совместно анализирует парные снимки глазного дна и определяет наличие офтальмологических заболеваний.

Возможные задачи:

- предобработка изображений и удаление неинформативного фона;
- приведение снимков к единому масштабу и разрешению;
- анализ качества и освещённости изображений;
- исследование дисбаланса диагностических классов;
- анализ различий между снимками правого и левого глаза;
- визуализация признаковых представлений различных заболеваний.

ML/DL-задачи:

- классификация заболеваний по одному изображению;
- мультиметочная классификация;
- построение модели с двумя ветвями для правого и левого глаза;
- сравнение моделей с общими и независимыми весами;
- сравнение раннего и позднего объединения признаков;
- применение transfer learning;
- анализ вклада каждого глаза в итоговое решение;
- интерпретация предсказаний с помощью карт активации.

---

188. Совместная классификация и сегментация новообразований молочной железы по УЗИ

Руководитель: Герасимова Мария
Датасет: BUSI

Уровень сложности: base/middle

Пререквизиты: основы ML/DL, классификация изображений, основы сегментации, свёрточные нейронные сети, Python.

Ультразвуковое исследование используется для первичной оценки новообразований молочной железы. При анализе изображения важно не только определить тип образования, но и локализовать его границы.

Цель проекта — построить систему классификации УЗИ на нормальные, доброкачественные и злокачественные случаи. Для более сильного студента задача может быть дополнена сегментацией новообразований.

Возможные задачи:

- исследовательский анализ изображений;
- анализ размеров и формы новообразований;
- оценка качества экспертных масок;
- предобработка изображений и подавление шума;
- анализ дисбаланса классов;
- подбор аугментаций для небольшой выборки;
- визуализация отличительных признаков классов.

ML/DL-задачи:

- классификация УЗИ на три категории;
- построение бинарного классификатора доброкачественных и злокачественных образований;
- применение transfer learning;
- сегментация новообразований с помощью U-Net или аналогичной архитектуры;
- классификация на основе всего изображения и выделенной области;
- совместное обучение сегментации и классификации;
- оценка неопределённости модели;
- анализ ошибок на сложных и неоднозначных случаях.

---

189. Сегментация камер сердца и диагностика заболеваний по кино-МРТ

Руководитель: Герасимова Мария
Датасет: ACDC

Уровень сложности: middle/pro

Пререквизиты: основы ML/DL, сегментация изображений, основы анализа медицинских изображений, Python.

Кино-МРТ позволяет наблюдать изменение формы сердечных камер в течение сердечного цикла. Автоматическая сегментация желудочков необходима для вычисления объёмов и функциональных показателей, используемых при диагностике сердечных заболеваний.

Цель проекта — сегментировать основные структуры сердца и исследовать возможность определения типа заболевания по геометрическим и нейросетевым признакам.

Для основной части проекта можно ограничиться двумерной сегментацией ключевых фаз сердечного цикла.

Возможные задачи:

- предобработка МРТ;
- выбор конечной диастолической и конечной систолической фаз;
- анализ формы и объёма сердечных камер;
- вычисление фракции выброса и других функциональных показателей;
- сравнение пациентов разных диагностических групп;
- визуализация изменения формы сердца.

ML/DL-задачи:

- сегментация левого и правого желудочков;
- сравнение двумерных и 2.5D-моделей;
- постобработка масок;
- извлечение геометрических признаков;
- классификация заболеваний по геометрическим показателям;
- классификация по признакам, извлечённым нейронной сетью;
- объединение геометрических и нейросетевых признаков;
- анализ влияния ошибок сегментации на итоговый диагноз.

---

190. Анализ старения мозга и выявление когнитивных нарушений по МРТ

Руководитель: Герасимова Мария
Датасет: OASIS-3

Уровень сложности: middle/pro

Пререквизиты: основы ML/DL, модели классификации и регрессии, обработка изображений, методы понижения размерности, Python.

В процессе нормального старения структура мозга постепенно изменяется. При нейродегенеративных заболеваниях эти изменения могут происходить быстрее или иметь иной характер.

Цель проекта — построить модель для определения возраста по МРТ мозга и исследовать связь между ошибкой определения возраста и наличием когнитивных нарушений.

Чтобы ограничить объём проекта, предлагается использовать одну МРТ-модальность и одну временную точку для каждого пациента.

Возможные задачи:

- предобработка МРТ;
- выделение области мозга;
- анализ распределения возрастов и клинических групп;
- извлечение двумерных срезов или компактных признаков;
- визуализация признаковых представлений пациентов;
- исследование структурных отличий между группами;
- анализ возможного влияния пола и возраста на результаты.

ML/DL-задачи:

- регрессия возраста по МРТ;
- классификация нормального старения и когнитивных нарушений;
- вычисление разницы между предсказанным и фактическим возрастом мозга;
- сравнение моделей на отдельных срезах и наборах срезов;
- применение transfer learning;
- использование признака brain age gap для классификации;
- анализ участков мозга, влияющих на прогноз;
- исследование систематических ошибок модели для разных групп пациентов.

---

191. Совместный анализ рентгенограмм и текстовых медицинских заключений

Руководитель: Герасимова Мария
Датасет: PadChest

Уровень сложности: pro

Пререквизиты: основы ML/DL, классификация изображений, основы NLP, трансформеры, Python.

Медицинские архивы часто содержат не только изображения, но и написанные врачами текстовые заключения. Эти заключения могут использоваться как дополнительный источник информации или как слабая разметка для обучения моделей.

Цель проекта — разработать модель, которая совместно использует рентгенограмму грудной клетки и текст медицинского заключения для определения патологий.

Полная генерация медицинских отчётов в основную часть проекта не включается. Основной задачей должна быть классификация или сопоставление изображений и текстов.

Возможные задачи:

- очистка и нормализация текстовых заключений;
- выделение диагностических терминов;
- анализ частоты встречаемости патологий;
- изучение ошибок и противоречий в разметке;
- получение текстовых эмбеддингов;
- извлечение признаков из рентгенограмм;
- визуализация соответствия между изображениями и заключениями.

ML/DL-задачи:

- классификация патологий только по изображению;
- классификация только по тексту;
- мультимодальная классификация;
- сравнение способов объединения визуальных и текстовых признаков;
- сопоставление изображения и соответствующего заключения;
- применение предобученных визуальных и языковых моделей;
- обучение на шумных диагностических метках;
- анализ случаев, в которых изображение и текст дают противоречивую информацию.

192. Исследование влияния области лёгких и технических артефактов на классификацию рентгенограмм

Руководитель: Герасимова Мария
Датасет: COVID-19 Radiography Database

Уровень сложности: base/middle

Пререквизиты: основы ML/DL, модели классификации изображений, свёрточные нейронные сети, transfer learning, Python.

При классификации медицинских изображений нейронная сеть может использовать не только признаки заболевания, но и постороннюю информацию: подписи на снимке, рамки изображения, особенности оборудования или способ подготовки данных. В результате модель показывает высокое качество на тестовой выборке, но плохо работает на новых данных.

В датасете представлены рентгенограммы пациентов с COVID-19, пневмонией, другими изменениями лёгких и без патологий. Для изображений доступны маски лёгких, что позволяет сравнить модели, использующие полный снимок и только область лёгочной ткани.

Цель проекта — построить классификатор рентгенограмм и исследовать, какие области изображения модель использует для принятия решения.

Возможные задачи:

- исследовательский анализ изображений разных классов;
- проверка размеров, контрастности и качества снимков;
- поиск надписей, рамок и других технических артефактов;
- анализ дисбаланса классов;
- визуализация области лёгких;
- сравнение изображений до и после применения масок;
- поиск различий в источниках и способах подготовки изображений.

ML/DL-задачи:

- бинарная или многоклассовая классификация рентгенограмм;
- применение предобученных свёрточных нейронных сетей;
- сравнение моделей, обученных на полных изображениях и только на области лёгких;
- исследование влияния фона и технических артефактов;
- применение Grad-CAM и других методов интерпретации;
- оценка калибровки вероятностей;
- анализ уверенности модели на ошибочных примерах;
- исследование устойчивости к изменению контрастности, масштаба и качества изображения;
- проверка качества модели после искусственного удаления или добавления отдельных артефактов.

193. Сравнение сигналов о побочных реакциях в международных базах фармаконадзора

Руководитель: Герасимова Мария
Датасеты: FAERS/openFDA, Canada Vigilance, SIDER
Уровень сложности: pro
Пререквизиты: основы статистики и машинного обучения, работа с табличными данными, Python, pandas, SQL; понимание принципов проверки статистических гипотез будет преимуществом.

Системы фармаконадзора содержат спонтанные сообщения о предполагаемых побочных реакциях на лекарственные препараты. Однако наличие сообщения не доказывает причинно-следственную связь между препаратом и реакцией, а результаты анализа могут зависеть от страны, особенностей системы здравоохранения и структуры отчётности.

Цель проекта — разработать и исследовать методы выявления сигналов о нежелательных лекарственных реакциях и проверить, насколько сигналы,

обнаруженные в американской базе FAERS, воспроизводятся в канадской базе Canada Vigilance.

Проект рекомендуется ограничить выбранным классом препаратов, например антикоагулянтами, антидепрессантами, противодиабетическими или противоопухолевыми препаратами.

Возможные задачи:
очистка и объединение связанных таблиц;
удаление повторных версий и предполагаемых дубликатов сообщений;
нормализация торговых названий и действующих веществ;
разделение подозреваемых и сопутствующих препаратов;
анализ полноты и качества данных;
анализ динамики сообщений по годам;
исследование распределения сообщений по полу, возрасту, стране и источнику;
выделение клинических побочных реакций среди исходов, ошибок применения и сообщений об отсутствии эффективности;
сопоставление терминов реакций между базами;
использование SIDER как справочника уже известных побочных эффектов.

ML/статистические задачи:
расчёт ROR, PRR и других методов диспропорционального анализа;
сравнение рейтингов сигналов в FAERS и Canada Vigilance;
оценка воспроизводимости сигналов между базами;
исследование зависимости воспроизводимости от частоты сообщений;
ранжирование потенциальных сигналов;
прогнозирование того, будет ли сигнал воспроизведён во второй базе;
анализ временного, странового и информационного смещения;
оценка устойчивости результатов к различным правилам фильтрации данных.

194. Прогнозирование токсичности химических соединений

Руководитель: Герасимова Мария
Датасеты: Tox21, ToxCast, ChEMBL
Уровень сложности: pro
Пререквизиты: основы ML/DL, классификация, Python; базовое знакомство с нейронными сетями и химическими структурами желательно, но не обязательно.

Оценка токсичности соединений является важной частью разработки лекарственных средств. Экспериментальное тестирование требует значительных ресурсов, поэтому модели машинного обучения могут использоваться для предварительного отбора потенциально безопасных и опасных соединений.

Цель проекта — разработать модели прогнозирования одного или нескольких токсикологических свойств химических соединений по их молекулярной структуре и исследовать надёжность получаемых предсказаний.

Возможные задачи:

- выбор токсикологических endpoints;
- очистка и стандартизация молекулярных структур;
- анализ распределения классов;
- исследование пропущенных и противоречивых меток;
- расчёт молекулярных дескрипторов;
- получение молекулярных fingerprints;
- визуализация химического пространства;
- кластеризация соединений;
- анализ структурного сходства;
- формирование случайного и scaffold-разбиения;
- исследование соединений, находящихся вне обучающего
- химического пространства.

  ML/DL-задачи:

- бинарная классификация отдельных видов
- токсичности;многозадачное прогнозирование нескольких
- токсикологических endpoints;
- сравнение классических моделей на дескрипторах и fingerprints;
- применение графовых нейронных сетей;
- применение предобученных моделей молекулярных представлений; работа с несбалансированными классами;
- оценка неопределённости предсказаний;
- определение области применимости модели;
- сравнение качества на случайном и scaffold-разбиении;
- анализ интерпретируемости и важных молекулярных фрагментов.

195.Прогнозирование взаимодействий лекарственных соединений с белковыми мишенями

Руководитель: Герасимова Мария

Датасеты: BindingDB, ChEMBL

Уровень сложности: pro

Пререквизиты: основы ML/DL, регрессия и классификация, Python; основы работы с молекулярными представлениями, последовательностями и нейронными сетями будут преимуществом.

Действие лекарственного соединения определяется его взаимодействием с определёнными белковыми мишенями. Экспериментальное измерение таких взаимодействий является дорогостоящим, поэтому вычислительные

модели применяются для прогнозирования вероятности связывания или величины аффинности.

Цель проекта — разработать модель прогнозирования взаимодействия между малой молекулой и белковой мишенью и исследовать качество модели на ранее не встречавшихся соединениях и белках.

Возможные задачи:
выбор подмножества белковых мишеней;
очистка молекулярных структур;
нормализация белковых последовательностей;
анализ значений Ki, Kd, IC50 и EC50;
обработка повторных и противоречивых измерений;
изучение распределения активности;
получение молекулярных fingerprints;
получение эмбеддингов белковых последовательностей;
анализ сходства молекул и белков;
формирование различных схем разбиения данных;
визуализация пространства соединений и мишеней.

ML/DL-задачи:
классификация наличия взаимодействия;
регрессия величины аффинности;
сравнение классических моделей и нейронных сетей;
использование графовых представлений молекул;
использование предобученных моделей белковых последовательностей;
сравнение способов объединения признаков молекулы и белка;
оценка на случайном разбиении;
cold-drug validation для новых соединений;
cold-target validation для новых белковых мишеней;
оценка на одновременно новых соединениях и мишенях;
анализ неопределённости и интерпретируемости модели.

196. Поиск новых лекарственных мишеней и перепрофилирование существующих препаратов

Руководитель: Герасимова Мария
Датасеты: Open Targets Platform, ChEMBL, ClinicalTrials.gov
Уровень сложности: pro
Пререквизиты: основы ML/DL, работа с графами и табличными данными, Python; знакомство с графовыми нейронными сетями или рекомендательными системами будет преимуществом.

Существующие лекарственные препараты могут оказаться эффективными при заболеваниях, для которых они изначально не разрабатывались. Одновременно для многих заболеваний требуется определять наиболее

перспективные молекулярные мишени, воздействие на которые может иметь терапевтический эффект.

Цель проекта — построить модель, объединяющую сведения о препаратах, белковых мишенях, заболеваниях и биомедицинских доказательствах, и использовать её для ранжирования новых потенциальных связей.

Проект рекомендуется ограничить одним заболеванием или группой близких заболеваний.

Возможные задачи:

- выбор заболевания и группы потенциальных мишеней;
- извлечение связей «мишень — заболевание»;
- извлечение связей «препарат — мишень»;
- интеграция генетических, фармакологических и клинических доказательств;
- построение гетерогенного биомедицинского графа;
- анализ типов узлов и связей;
- оценка полноты и противоречивости источников;
- анализ уже одобренных и исследуемых препаратов; сопоставление результатов с данными клинических испытаний;
- визуализация локальных подграфов для отдельных препаратов и заболеваний.

ML/DL-задачи:

- ранжирование терапевтических мишеней; прогнозирование новых связей «мишень — заболевание»;
- прогнозирование новых показаний для существующих препаратов; link prediction в гетерогенном графе;
- сравнение эвристических графовых методов и машинного обучения; применение графовых нейронных сетей;
- обучение моделей ранжирования;
- анализ вклада разных типов биомедицинских доказательств; объяснение отдельных рекомендаций модели;
- проверка предсказаний по данным клинических исследований;
- исследование временного разбиения для предотвращения утечки информации.

197. AI-ассистент для Fantasy Football

Трек: ML
Уровень сложности: middle/pro

Руководитель: Николаев Михаил

Fantasy-футбол — игра, в которой пользователь формирует виртуальную команду из реальных футболистов и получает очки за их выступления во время реальных матчей. Успешная стратегия требует учитывать форму игроков, календарь, статистику, игровое время, травмы, силу соперников и другие факторы.

В рамках проекта предлагается разработать **AI-ассистента для прогнозирования результативности футболистов и помощи в формировании оптимальный состав и трансферах**. Система должна учитывать правила Fantasy: бюджет, ограничения на количество игроков из одной команды, позиции и доступное количество замен.

В расширенной постановке пользователь может выбрать один из трех риск-профилей — **защитный, умеренный или рискованный**. На их основе система должна предлагать разные стратегии состава и трансферов.

Итоговое решение должно представлять собой **веб-сервис или Telegram-бот**, который анализирует открытые футбольные данные и предоставляет рекомендации по составу перед каждым туром с объяснением причин выбора..

Задачи: сбор и анализ открытых футбольных данных, разработка признаков, построение модели прогнозирования Fantasy-очков, оценка неопределенности прогноза, алгоритм оптимизации состава с учетом ограничений, разработка сервиса.

Проект будет интересен тем, кто хочет погрузиться в спортивный **ML на реальной задаче, повысить свои знания в области спортивной аналитики**, а также получить опыт создания полноценного AI-продукта.

198 AI-сервис для автоматического создания хайлайтов спортивных матчей

Трек: DL
Уровень сложности: pro

Руководитель: Николаев Михаил

После матча по паделу или теннису зрителям, спортсменам и тренерам часто требуется короткая нарезка (хайлайты) наиболее интересных игровых эпизодов. Ручной монтаж занимает значительное время.

В рамках проекта предлагается разработать **CV-сервис, который автоматически анализирует видеозапись матча и формирует хайлайты**. На основе анализа движения мяча и игроков, игровых событий и других визуальных признаков система должна находить наиболее интересные эпизоды, классифицировать их и формировать итоговую видеонарезку.

Дополнительно можно реализовать поддержку нескольких камер: система должна выбирать наиболее подходящий ракурс для конкретного эпизода.

Задачи: обработка и синхронизация видео с нескольких камер, детекция объектов, temporal action recognition, классификация игровых событий, ранжирование эпизодов по зрелищности, автоматический монтаж видео.

Проект будет интересен тем, кто хочет попробовать **CV на спортивном видео, решать задачи распознавания и создать прикладной AI-продукта**.

199 Система обнаружения аномальных движений линии между букмекерами

Трек: ML / Data Science
Уровень сложности: middle

Руководитель: Николаев Михаил

Букмекерские конторы устанавливают коэффициенты независимо друг от друга, и линия постоянно "плывёт" — реагирует на новости, травмы, объёмы ставок и действия профессиональных игроков ("sharp money"). Резкое и синхронное движение линии сразу у нескольких букмекеров обычно означает появление значимой информации (например, стало известно о травме ключевого игрока), а несинхронное или локальное движение у одного букмекера — сигнал того, что через него прошёл крупный "умный" объём. Трейдеру важно быстро отличать одно от другого, чтобы вовремя скорректировать собственную линию и не потерять маржу.

В рамках проекта предлагается разработать систему мониторинга и классификации аномальных движений линии на основе открытых агрегаторов коэффициентов (Odds API, Oddsportal, Flashscore и аналоги, доступные бесплатно или по студенческой лицензии). Система должна в реальном времени сопоставлять котировки нескольких букмекеров по одному событию, выявлять статистически значимые расхождения и резкие скачки, и классифицировать причину движения: "рыночный шум", "вероятно, новостной фон" (сопоставление по времени с публикациями в СМИ/соцсетях) или "вероятно, целевой объём одного оператора". Итоговый продукт — дашборд или Telegram-алерт для трейдера с оценкой вероятной причины движения и рекомендацией, требует ли это реакции.

В расширенной постановке можно добавить бэктест: насколько выявленные "steam moves" действительно предсказывали дальнейшее движение линии или исход события, что даёт количественную оценку полезности сигналов.

Задачи: сбор исторических и потоковых данных по коэффициентам с нескольких открытых источников, построение признаков движения линии (скорость, синхронность между букмекерами, объём "виртуального" изменения маржи), детектор аномалий (статистические методы или ML-классификатор), сопоставление с новостным/событийным потоком по времени, бэктест сигналов на исторических данных, разработка дашборда/бота с алертами.

Проект будет интересен тем, кто хочет разобраться во внутренней механике беттинг-трейдинга, поработать с временными рядами и потоковыми данными, а также получить опыт построения системы алертов, применимой не только в беттинге, но и в финансовом трейдинге и маркет-мейкинге в целом.

200 Анализ ценообразование correlated bets в гемблинге

Трек: ML
Уровень сложности: middle/pro

Руководитель: Николаев Михаил

Экспресс-ставки на события одного матча (same-game parlay, "конструктор ставок") — один из самых быстрорастущих и маржинальных продуктов букмекеров. Их сложность в том, что события внутри одного матча коррелированы: если команда забивает, растёт вероятность угловых и жёлтых карточек соперника, форвард, забивший гол, с большей вероятностью получит "первый гоалскорер" и так далее. Наивное перемножение вероятностей отдельных исходов даёт неверную (обычно завышенную для игрока) итоговую котировку — букмекер либо теряет маржу, либо вынужден закладывать грубый защитный коэффициент, теряя в привлекательности продукта.

В рамках проекта предлагается построить модель совместного распределения ключевых внутриматчевых событий футбольного матча (голы, угловые, карточки, удары в створ, возможно — конкретные игроки-скореры) на основе открытых данных о событиях матчей (например, датасеты event-level статистики StatsBomb Open Data, Understat, Kaggle-датасеты с историей корнеров/карточек) и построить симуляцию матча (Monte Carlo на основе, например, Bivariate Poisson / Dixon-Coles с корреляционной поправкой или прямое сэмплирование сценариев матча), из которой корректно выводятся вероятности произвольных комбинаций событий, включая кросс-маркетные ("играть на победу команды А и тотал больше 2.5 углов").

В расширенной постановке система должна принимать на вход произвольный набор из 2-4 событий, выбранных "конструктором ставок", и выдавать корректную (с учётом корреляции) итоговую котировку в сравнении с наивной, показывая величину скрытого edge или недооценённого риска.

Задачи: сбор и обработка открытых event-level данных по матчам, построение статистической модели совместного распределения событий матча (с учётом корреляций), симуляция матчей и оценка вероятностей произвольных комбинаций, сравнение с наивным перемножением вероятностей и объяснение расхождений, разработка сервиса/API "конструктора ставок" с корректным ценообразованием.

Проект будет интересен тем, кто хочет углубиться в вероятностное моделирование и симуляции, разобраться в математике корреляционных ставок — теме, которая одинаково востребована и в спортивном беттинге, и в структурировании финансовых деривативов.

201 LLM/NLP-ассистент букмекерского трейдера

Трек: NLP / LLM
Уровень сложности: middle

Руководитель: Николаев Михаил

Перед принятием решения по цене на матч трейдеру нужно быстро свести воедино разрозненную информацию: заявленные составы, новости о травмах и дисквалификациях, заявления тренеров на пресс-конференциях, обсуждения в спортивных СМИ и соцсетях. Сейчас это делается вручную и отнимает время, особенно когда в один день проходит десятки матчей в разных лигах, а любое запаздывание с реакцией на новость — это риск ошибочной цены и потерь.

В рамках проекта предлагается разработать LLM-ассистента трейдера, который в режиме, близком к реальному времени, собирает открытые новостные ленты, RSS спортивных изданий, публичные посты в соцсетях и официальные объявления составов, извлекает из них релевантные для конкретного матча факты (травмы, ротации, дисциплинарные новости, погодные условия), оценивает их влияние на вероятный исход и формирует короткую структурированную сводку для трейдера с указанием источников и степени уверенности. Дополнительно ассистент должен уметь отвечать на уточняющие вопросы трейдера в чате ("почему в сводке упомянут этот игрок", "насколько надёжен источник") — то есть работать как RAG-система поверх собранного новостного корпуса.

В расширенной постановке можно добавить сопоставление появления новости по времени с последующим движением линии (используя открытые данные коэффициентов), чтобы количественно оценивать, насколько конкретный тип новостей исторически двигал рынок, и приоритизировать сводки по ожидаемой значимости.

Задачи: сбор открытых новостных, RSS- и соцсетевых данных по интересующим лигам, построение пайплайна извлечения сущностей и фактов, релевантных ставочным рынкам (NER, event extraction), разработка RAG-системы с оценкой достоверности и уверенности, сопоставление новостного потока с историческим движением линии, разработка интерфейса-ассистента (веб-сервис/бот) с генерацией сводок и чатом.

Проект будет интересен тем, кто хочет получить практический опыт построения RAG-систем и работы с LLM на реальных зашумлённых данных, а также разобраться, как информационный поток превращается в рыночный сигнал.

202 Экспансия беттинга в low-liquidity рынки (нижние лиги, женский спорт) через модели с ограниченными данными

Трек: ML
Уровень сложности: middle/pro

Руководитель: Николаев Михаил

Для топовых лиг (АПЛ, Ла Лига, РПЛ) у букмекеров накоплены огромные массивы данных и выстроенные модели ценообразования. Но в нижних лигах, в женском футболе, в киберспорте и во второстепенных турнирах данных на порядок меньше — команды играют мало матчей, составы часто меняются, статистика скудная. Из-за этого крупные букмекеры либо вообще не открывают на них линии, либо ставят их с широкой защитной маржой, теряя в привлекательности продукта и упуская сегмент рынка, интересный менее консервативным операторам.

В рамках проекта предлагается разработать модель прогнозирования исходов для турниров с ограниченным объёмом данных, которая использует информацию из смежных, более "богатых данными" соревнований. Модель должна не только выдавать вероятности исходов, но и явно оценивать свою неопределённость, чтобы букмекер мог понимать, где можно ставить конкурентную линию, а где нужна повышенная защитная маржа.

В расширенной постановке систему можно протестировать на нескольких типах нишевых соревнований (например, женский футбол и или данные нишевых лиг) и сравнить, насколько перенос данных между турнирами улучшает качество прогноза по сравнению с моделью, обученной только на данных самого нишевого турнира.

Задачи: сбор открытых данных по нишевым турнирам и структурно близким "донорским" соревнованиям, построение иерархической/transfer-learning модели прогнозирования исходов, разработка метода оценки неопределённости прогноза, перевод вероятностей в рекомендуемую линию с защитной маржой, оценка качества на исторических данных нескольких видов спорта/турниров.

Проект будет интересен тем, кто хочет разобраться в байесовских иерархических моделях и transfer learning на практике, а также получить опыт работы с "малыми данными" — навык, ценный далеко за пределами беттинга.

203 AI-консьерж для краткосрочной аренды и бутик-отелей

Трек: ML

Уровень сложности: middle

Руководитель: Николаев Михаил

Рынок краткосрочной аренды (посуточные квартиры, гостевые дома, бутик-отели) страдает от роста операционных издержек и нехватки персонала: хозяева объектов вручную отвечают на десятки однотипных сообщений от гостей, согласовывают заселение/выселение, решают бытовые проблемы и управляют ценами. Аналогичную задачу решает колумбийский стартап Hospy, который позиционирует свой продукт как «цифрового сотрудника» для отелей и апартаментов, забирающего на себя операционные и клиентские задачи.

В рамках проекта предлагается разработать AI-ассистента для хозяев объектов размещения, который автоматически ведёт переписку с гостями (на нескольких

языках), отвечает на типовые вопросы (правила заселения, Wi-Fi, транспорт, рекомендации), эскалирует нестандартные ситуации человеку и умеет проактивно подсказывать хозяину действия (когда стоит скорректировать цену, кого стоит попросить оставить отзыв, кто из гостей рискует остаться недоволен).

В расширенной постановке система должна на основе истории переписки и бронирований прогнозировать риск негативного отзыва и предлагать хозяину превентивные действия, а также давать рекомендации по динамическому ценообразованию на основе загрузки, сезонности и конкурентного окружения.

Итоговое решение — Telegram-бот или веб-панель для хозяина объекта, интегрированная с чатом гостя, с дашбордом по операционным метрикам.

Задачи: сбор/разметка диалоговых данных гостиничной тематики, построение RAG-системы поверх базы знаний объекта (правила, FAQ, локальные рекомендации), fine-tuning или промпт-инжиниринг диалоговой модели с поддержкой мультиязычности, модель прогнозирования риска негативного отзыва, модуль динамического ценообразования, разработка сервиса/бота.

Проект будет интересен тем, кто хочет попробовать себя в прикладном NLP и построении реального диалогового AI-продукта для конкретной бизнес-ниши (тревел- и proptech), а также разобраться в задачах RAG и multi-turn диалоговых систем.

204 Персонализированный AI-гид со сторителлингом

Трек: DL **Уровень сложности:** middle/pro

Руководитель: Николаев Михаил

Классические аудиогиды и экскурсии плохо адаптируются под конкретного посетителя: маршрут, язык повествования и глубина погружения фиксированы заранее. Израильский стартап Xsite решает эту проблему, создавая для музеев и туристических объектов AI-гидов с генеративным видео, закадровым текстом и адаптивной подачей истории под конкретного пользователя, а также инструменты для быстрого создания такого контента без больших продакшн-команд.

В рамках проекта предлагается разработать сервис, который по описанию объекта (музея, исторического центра, парка) и открытым источникам (Wikipedia, краеведческие тексты, архивы) автоматически генерирует персонализированный сценарий аудио/видео-экскурсии: подбирает факты и истории под интересы пользователя (история, архитектура, гастрономия, локальные легенды), выстраивает драматургию рассказа и адаптирует стиль повествования (детский, познавательный, атмосферный).

В расширенной постановке система должна уметь подстраивать маршрут и длительность рассказа под темп передвижения пользователя (геопозиция) и генерировать закадровую озвучку через TTS с эмоциональной интонацией, соответствующей содержанию истории.

Итоговое решение — мобильный веб-сервис или Telegram-мини-приложение, которое по выбранной локации и профилю интересов пользователя генерирует персонализированный аудиогид.

Задачи: сбор и структурирование фактического материала по объектам показа, построение пайплайна генерации сценария с учётом стиля и интересов пользователя (LLM + контроль фактологической точности), разработка модуля драматургии/сторителлинга (структура рассказа, кульминации, переходы между точками маршрута), интеграция TTS с эмоциональной окраской, привязка сценария к геопозиции.

Проект будет интересен тем, кто хочет поработать на стыке NLP-генерации, контроля галлюцинаций LLM (важна фактическая точность истории) и мультимодальной генерации (текст + аудио), а также получить опыт создания продукта в сфере travel-tech и культурных индустрий.

205 Маршрут путешествия из подборки Reels пользователя

Трек: research **Уровень сложности:** pro

Руководитель: Николаев Михаил

Идея: пользователь скидывает сервису ссылки на несколько роликов (Reels/TikTok/Shorts), которые ему понравились и вдохновили на путешествие. Сервис распознаёт в каждом ролике локацию (по подписи, аудиодорожке/субтитрам и/или визуальному контенту кадров), группирует ролики по географическим кластерам (страна/регион — «Япония», «Испания» и т.д.), а затем на основе получившегося пула мест строит маршрут путешествия с привязкой отелей, ресторанов и активностей рядом с распознанными точками.

Задачи: сбор датасета роликов с геопривязкой для оценки качества (например, по открытым туристическим тегам), пайплайн извлечения текста/аудио из видео (транскрибация, OCR подписей на кадрах), классификация/NER для извлечения локаций из текста, эксперимент с visual geolocation моделями и оценка их точности на реальных Reels, алгоритм кластеризации точек интереса по регионам, алгоритм построения оптимального маршрута с учётом кластеров и ограничений по времени, интеграция с API мест (отели/рестораны), разработка сервиса с шагом уточнения неопределённых локаций у пользователя.

Проект будет интересен тем, кто хочет поработать на стыке компьютерного зрения, NLP и мультимодальных моделей, честно разобраться в реальных пределах точности geolocation-моделей и получить опыт постановки research-эксперимента с последующей инженерной обвязкой в виде продукта.

---

206. Измерение экранного времени бренда на спортивной трансляции

Трек: DL **Уровень сложности:** middle/pro

Руководитель: Николаев Михаил

Спонсоры спортивных событий (клубов, лиг, отдельных матчей) размещают логотипы на форме игроков, рекламных щитах вдоль поля, экипировке и инфраструктуре арены, но объективно оценить, сколько времени и с какой заметностью бренд был виден зрителю во время трансляции, — нетривиальная задача. Решения такого рода (например, платформы для sponsorship intelligence) используют компьютерное зрение для детекции и трекинга логотипов на видео трансляции и переводят это в метрики экспозиции и медиа-ценности.

В рамках проекта предлагается разработать систему, которая по видеозаписи спортивной трансляции детектирует появления логотипов заданных брендов (на форме, рекламных щитах, инфраструктуре), трекает их на протяжении ролика и агрегирует метрики: суммарное время в кадре, доля площади кадра, средняя позиция (центр/край), количество отдельных появлений.

Итоговое решение — сервис, который принимает видеозапись трансляции и список брендов/логотипов, а на выходе отдаёт отчёт с метриками экспозиции по каждому бренду и таймлайн появлений.

Задачи: сбор и разметка датасета логотипов на спортивных трансляциях (детекция на форме, щитах, инфраструктуре), обучение/дообучение детектора объектов под специфику задачи (мелкие объекты, движение камеры, перекрытия), трекинг логотипов между кадрами, разработка метрики качества/ценности экспозиции с учётом видимости, агрегация и визуализация статистики по матчу, разработка сервиса.

Проект будет интересен тем, кто хочет получить практический опыт в детекции и трекинге объектов на видео, поработать с реальными сложностями компьютерного зрения (мелкие быстро движущиеся объекты, перекрытия, изменчивое освещение) и создать прототип решения для рынка спортивного маркетинга и sponsorship-аналитики.

207. Мультисистемный AI-астролог

Трек: ML **Уровень сложности:** junior/middle

Руководитель: Николаев Михаил

Существует устойчивый пользовательский спрос на персонализированные астрологические прогнозы, при этом большинство ботов работает только с одной системой (обычно западной астрологией) и часто выдаёт шаблонные, слабо персонализированные тексты. Идея проекта — Telegram-бот, который строит персональный прогноз сразу по нескольким системам: западной (знаки зодиака, натальная карта, транзиты планет), китайской (годовые животные, элементы, ба-цзы) и ацтекской/месоамериканской (тональпоуалли, дневные знаки).

В рамках проекта предлагается разработать сервис, который по дате (и по возможности времени/месту) рождения пользователя рассчитывает позиции в

каждой из систем на основе формальных правил и календарных алгоритмов, а затем с помощью языковой модели генерирует связный персонализированный текст прогноза, непротиворечиво объединяющий сигналы из разных систем и адаптированный по тону (шутливый/серьёзный/на день/на месяц).

В расширенной постановке система должна уметь сравнивать совместимость двух пользователей сразу по всем системам и объяснять, в чём системы «сходятся», а в чём дают разные акценты, а также обучаться на обратной связи пользователей (какие формулировки/темы прогноза им откликаются) для персонализации стиля.

Итоговое решение — Telegram-бот, рассчитывающий три системы и генерирующий персонализированный текст прогноза с возможностью выбора темы (любовь, карьера, здоровье) и тона.

Задачи: реализация календарной/астрономической логики трёх систем (западной, китайской, ацтекской), проектирование единого промежуточного представления «личного профиля» пользователя для передачи в LLM, разработка и тестирование промптов/шаблонов генерации для непротиворечивого объединения нескольких систем, эксперименты по контролю тона и стиля генерации, механизм сбора обратной связи для дальнейшей персонализации, разработка Telegram-бота.

Проект будет интересен тем, кто хочет получить опыт промпт-инжиниринга и контролируемой генерации текста, а также поработать с не самой типичной, но нишевой и понятной с точки зрения монетизации продуктовой областью.

208. AI-сценарист с адаптацией под формат и стиль

Трек: DL **Уровень сложности:** middle/pro

Руководитель: Николаев Михаил

Написание сценарных материалов сильно различается по формату: посерийный план сериала, логлайн с обзором сюжетных арок для фильма, короткая питчинг-заявка для питчинга проекта продюсерам, полноценный сценарий сцены с диалогами. Большинство существующих LLM-инструментов для сценаристов плохо различают эти форматы и выдают усреднённый по стилю текст независимо от задачи.

В рамках проекта предлагается разработать и обучить/дообучить модель (или систему промптинга с контролем формата), которая умеет генерировать сценарные тексты в разных заранее заданных форматах и стилях: посерийная разбивка сериала с сюжетными арками персонажей, обзорная синопсис-структура фильма, короткая заявка для питчинга (логлайн + синопсис + описание аудитории), развёрнутая сцена с диалогами в заданном жанре и авторском стиле.

В расширенной постановке система должна уметь сохранять консистентность персонажей и сюжетных линий между разными форматами одного и того же проекта (например, между посерийным планом и конкретной написанной сценой) и

адаптировать стиль под референсного автора/жанр по нескольким примерам текста.

Итоговое решение — веб-сервис, в котором сценарист выбирает формат и жанр, задаёт вводные (логлайн, персонажей, референсы стиля), и получает сгенерированный черновик в нужном формате с возможностью итеративной правки.

Задачи: сбор и разметка датасета сценарных текстов по форматам (посерийные планы, синопсисы, питчинг-заявки, сцены с диалогами), разработка представления сюжета/персонажей для контроля консистентности между форматами, fine-tuning или разработка few-shot/RAG-пайплайна для контролируемой генерации по формату и стилю, метрики оценки качества сгенерированного текста (структурная корректность формата, консистентность персонажей, стилистическое соответствие референсу), разработка сервиса с итеративным редактированием.

Проект будет интересен тем, кто хочет глубоко разобраться в контролируемой генерации текста (control over format/style), поработать с задачей сохранения долгосрочной консистентности в генеративных системах и получить опыт создания продукта для creative-индустрии.

209. Детекция автоматизированного ввода текста по поведенческой телеметрии

Трек: ML / Research

Уровень сложности: middle

Руководитель: Дубровин Владислав

С развитием LLM становится всё сложнее контролировать самостоятельность выполнения текстовых заданий: анализ готового текста не всегда позволяет надёжно определить способ его создания. Альтернативный подход — анализировать не сам текст, а процесс его написания: скорость и ритм набора, паузы между действиями, исправления, удаления, перемещения курсора и другие поведенческие признаки.

В рамках проекта предлагается разработать систему, которая по последовательности событий текстового редактора оценивает вероятность того, что текст вводился человеком естественным образом или с использованием автоматизации. Для этого предстоит исследовать существующие датасеты клавиатурного ввода, собрать собственные данные, разработать признаки, характеризующие поведение пользователя, и сравнить эвристические, классические ML и нейросетевые подходы.

В расширенной постановке можно исследовать устойчивость модели к различным стратегиям автоматизированного ввода и domain shift между пользователями, устройствами и типами текстов. Отдельный интерес представляет поиск признаков, которые позволяют отличать автоматизированный ввод от необычного, но естественного поведения

человека, а также калибровка модели для получения интерпретируемой оценки вероятности вместо бинарного решения.

Итоговое решение — прототип веб-сервиса для выполнения текстовых заданий с системой сбора телеметрии и ML-модулем, который оценивает характер ввода и предоставляет преподавателю результаты анализа.

Задачи: анализ существующих датасетов и исследований, сбор и разметка собственной телеметрии, EDA поведения пользователей, feature engineering временных и поведенческих признаков, разработка эвристического baseline, обучение и сравнение

210. Гендерное неравенство отдыха и повседневной заботы

Трек: RESEARCH

Уровень сложности: MIDDLE

Руководитель: Александр Карушев

Пререквизиты: уверенное владение python, pandas, numpy, scikit-learn. Знание основных методов классификации, регрессии и оценки качества моделей. Базовые навыки работы с PyTorch. Желательно знакомство с нейросетевыми моделями последовательностей, обучаемыми эмбеддингами и механизмом внимания. Готовность читать документацию и научные статьи на английском языке

Описание: проект посвящен моделированию последовательностей повседневных занятий и прогнозированию непрерывного отдыха по частично наблюдаемому дневнику дня. Предлагается сравнить два подхода: классический ML на агрегированных признаках и нейросетевые модели, учитывающие порядок, длительность и контекст занятий. Исследовательская часть включает разработку модификации последовательностной модели, эксперименты с представлением данных и оценку переноса между годами и социальными группами. Содержательная задача состоит в анализе гендерных различий в структуре отдыха с учетом занятости, состава домохозяйства и нагрузки по уходу за близкими

Цель проекта: разработать и экспериментально оценить метод прогнозирования непрерывного вечернего отдыха, объединяющий событийную последовательность занятий и табличные характеристики респондента. Определить, какие компоненты представления данных улучшают качество прогноза и насколько устойчивы результаты для разных социальных групп

Ожидаемые задачи:

1. Подготовить датасет и провести EDA
2. Формализовать прогнозную задачу и исключить утечки

3. Построить baseline
4. Разработать sequence model
5. Провести абляционные эксперименты
6. Оценить качество
7. Проанализировать устойчивость и воспроизводимость

Данные: Открытые микроданные American Time Use Survey за 2021–2025 годы, https://www.atusdata.org/atus/sample_summary.shtml

Ожидаемый результат: Воспроизводимый исследовательский pipeline подготовки данных, обучения и оценки моделей. Сравнение классических ML-подходов, базовой последовательностной модели и предложенной модификации на едином протоколе. Количественная оценка вклада порядка занятий, их длительности и контекста в прогноз непрерывного отдыха. Дополнительно ожидаются анализ ошибок по социальным группам и визуализация структуры дневников

211. ИИ-навыки как барьер входа на рынок труда

Трек: RESEARCH

Уровень сложности: MIDDLE

Руководитель: Александр Карушев

Пререквизиты: python, pandas, scikit-learn, основы машинного обучения и статистики. Базовое понимание NLP, текстовых эмбеддингов и архитектуры Transformer. Желательны опыт работы с PyTorch и готовность дообучать предобученные языковые модели. Готовность читать научные статьи и разбираться в предметной области

Цель проекта: разработать и экспериментально оценить методы автоматического извлечения и классификации требований работодателей. Сравнить их качество, устойчивость к смене профессиональной группы и периода публикации, а также зависимость от объема размеченных данных. Применить выбранный подход для исследования изменений требований в вакансиях

Ожидаемые задачи:

1. Подготовка корпуса и разметки
2. Построить baseline
3. Разработка и сравнение нейросетевых моделей
4. Эксперименты с обучением и архитектурой
5. Валидация и анализ ошибок
6. Моделирование структуры и динамики требований

Данные: открытый архив вакансий JobTech шведской государственной службы занятости Arbetsförmedlingen. Доступны исторические выгрузки,

включая 2025 год и первый и второй кварталы 2026 года, в том числе в формате JSONL, https://data.jobtechdev.se/annonser/historiska/

Ожидаемый результат: размеченный корпус вакансий, обученные модели и воспроизводимый пайплайн подготовки данных, обучения и инференса. Экспериментальное сравнение классических ML-моделей, трансформера и многозадачной архитектуры. Оценка переноса между профессиональными группами и временными периодами, анализ ошибок и зависимости качества от объёма разметки

212. Эмоциональный язык жалоб и реакция финансовых организаций

Трек: RESEARCH

Уровень сложности: MIDDLE

Руководитель: Александр Карушев

Пререквизиты: python, pandas, scikit-learn, основы статистики и машинного обучения. Базовые знания NLP, текстовых эмбеддингов и архитектуры Transformer. Знакомство с PyTorch, дообучением предобученных моделей и метриками классификации. Английский для работы с текстами жалоб и научными статьями. Готовность разбираться в предметной области

Цель проекта: разработать и экспериментально оценить многозадачную нейросетевую модель анализа жалоб. Исследовать качество распознавания, перенос между организациями и периодами, а также добавочную предиктивную ценность эмоциональных и аргументативных признаков

Ожидаемые задачи:

1. Подготовка корпуса и разметки
2. Построение baseline
3. Разработка многозадачной архитектуры
4. Моделирование исходов рассмотрения
5. Валидация и оценка качества
6. Исследовательские эксперименты и оценка воспроизводимости

Данные: архив Consumer Complaint Database CFPB. Источник для загрузки davidheineman/consumer-finance-complaints-large на Hugging Face в формате parquet, https://huggingface.co/datasets/davidheineman/consumer-finance-complaints-large

Ожидаемый результат: размеченный исследовательский корпус, многозадачная NLP-модель и модель классификации исходов обращений. Воспроизводимое сравнение классических и нейросетевых подходов,

результаты абляций, оценка переноса и зависимости качества от объема разметки

213. Выявление гендерной асимметрии в карьерных и семейных рекомендациях LLM с помощью парного и многозадачного обучения

Трек: RESEARCH

Уровень сложности: MIDDLE

Руководитель: Александр Карушев

Пререквизиты: python, основы машинного и глубокого обучения, навыки работы с pandas, scikit-learn и PyTorch. Базовое понимание NLP, текстовых эмбеддингов, архитектуры Transformer и дообучения предобученных моделей. Основы статистической проверки гипотез. Готовность читать научные статьи и разбираться в предметной области

Цель проекта: разработать и экспериментально проверить метод парного и многозадачного анализа рекомендаций LLM. Сравнить его с независимой классификацией ответов и использовать для оценки гендерной асимметрии с учетом случайной вариативности генерации

Ожидаемые задачи:

1. Подготовка экспериментального корпуса
2. Разработка схемы разметки
3. Построение baseline
4. Разработка парной многозадачной архитектуры
5. Сравнение моделей и
6. Проверка обобщающей способности
7. Анализ гендерной асимметрии

Данные: собственный экспериментальный корпус. Предварительный дизайн - 200 базовых сценариев * 2 гендера * 2 языка * 3 LLM * 5 повторных генераций = 12 000 ответов

Ожидаемый результат: двуязычный датасет со схемой разметки и протоколом сбора. Обученная модель-аудитор, выполняющая классификацию рекомендаций и парное сопоставление ответов